

中图分类号：V448.2

学 号： SY2103532

北京航空航天大學
硕士中期检查报告

分布式多目标鲁棒
跟踪方法研究

作者姓名 张毓杰

学科专业 控制理论与控制工程

指导教师 任章 教授

培养院系 自动化科学与电气工程学院

目录

1. 开题报告的论文研究方案	1
1.1 研究目标及研究内容	1
1.2 拟解决的关键问题及难点	2
1.2.1 分布式多目标跟踪多源信息融合策略研究	2
1.2.2 分布式传感器网络中探测精度下降传感器的判断方法研究	3
1.2.3 分布式传感器网络基于一致性的分布式融合策略设计	3
1.2.4 分布式多目标跟踪降带宽通信策略研究	3
1.3 拟采用的研究方法、技术路线、实验方案及预期的新意/创新	3
1.3.1 研究方法	3
1.3.2 技术路线	4
1.3.3 实验方案	13
1.3.4 创新点	14
2. 开题报告的论文工作计划	14
3. 已研究的内容和实现技术及关键技术的突破	15
3.1 单传感器多目标跟踪算法研究	15
3.1.1 跟踪系统建模	15
3.1.2 高斯混合概率假设密度算法	16
3.1.3 仿真	17
3.1.4 总结	21
3.2 分布式多目标跟踪算法研究	22
3.2.1 分布式多目标跟踪建模	22
3.2.2 基于交互式多模型的多目标状态融合算法	24
3.2.3 仿真	26
3.2.4 总结	32
3.3 基于密度聚类的分布式单目标鲁棒跟踪算法研究	32
3.3.1 跟踪模型建模	33
3.3.2 随机观测丢失的容积信息卡尔曼滤波器	35
3.3.3 改进的基于一致性的加权平均融合方法	37
3.3.4 稳定性分析	41
3.3.5 仿真	50
3.3.6 总结	53
3.4 基于密度聚类的分布式多目标鲁棒跟踪方法研究	54
3.4.1 问题描述	54
3.4.2 扩展高斯混合概率假设密度滤波器	57
3.4.3 核心 DBSCAN 聚类算法	58
3.4.4 改进的算数平均融合方法	61
3.4.5 一致性证明	63
3.4.6 仿真	65
3.4.7 总结	70
4. 已研究工作总结	70
5. 后续研究的内容和实现技术	71
6. 已发表的论文和取得的成果	74

7. 参考文献	74
---------------	----

1. 开题报告的论文研究方案

1.1 研究目标及研究内容

在对于多目标进行目标跟踪时，跟踪的精度与跟踪环境的复杂程度以及所用传感器的性能息息相关。环境中存在的各种电磁干扰以及物理遮挡等因素均会对于传感器对于目标的探测产生不利的影响。除此之外，由于传感器自身探测能力、计算能力和通信能力的限制，对于多目标跟踪算法的计算负担和通信负担提出了设计要求。本论文面向分布式多目标跟踪这个实际的工程应用问题，重点研究环境中恶意电磁干扰导致分布式传感器网络中部分传感器探测精度下降情况下的分布式多目标鲁棒跟踪问题。主要有三个研究内容：

1、探测精度对跟踪精度的影响研究和多源信息融合方法设计

为研究传感器探测精度对于多目标跟踪精度的影响，首先建立单传感器对多目标进行探测的场景，根据随机有限集理论设计多目标状态估计器，进而采用仿真和实物实验的方法研究传感器探测精度对多目标状态估计精度的影响。然后，将单传感器多目标跟踪场景扩充到分布式多传感器多目标跟踪场景，与单传感器对多目标跟踪不同，分布式多传感器多目标跟踪除了需要设计多目标状态估计器外，还需要对分布式传感器之间的信息通信策略以及信息融合方法进行研究。由于传感器通信能力和计算能力的限制，对于通信带宽和融合算法的计算复杂度提出了要求。因此，需要设计基于事件触发的通信策略对信息通信的内容、频率和次数进行限制，减轻通信负担。除此之外，还需要对多目标信息的融合方法进行研究，融合算法的优劣直接影响了分布式多目标状态估计的精度。采用交互式多模型的方法将算数平均融合方法和几何平均融合方法相结合，使得算法可以兼具算数平均融合方法不易丢失真实目标和几何平均融合方法不易受环境杂波影响的优点，获得更好的多目标状态估计结果。

2、探测精度下降情况下的分布式多目标鲁棒跟踪技术研究

完成上述基础研究工作后，将随机外界干扰引入，研究分布式传感器网络中部分传感器探测精度下降情况下的分布式多目标鲁棒跟踪问题。由上面的研究可以得到，探测精度下降的传感器的本地多目标状态估计精度也会下降，将精度下

降的多目标状态估计引入分布式融合中会影响融合精度。将探测精度下降的传感器节点挑选出来，不引入分布式融合可以提升状态估计的精度。首先，采用密度聚类算法设计探测精度下降传感器判断算法。然后，设计对应的基于一致性的分布式融合策略，在不改变分布式传感器网络通信拓扑的基础上，将探测精度下降传感器的本地状态估计剔除，提升分布式状态估计的精度。为验证探测精度下降传感器判断算法和设计的分布式融合策略的效果，首先在分布式单目标跟踪场景中进行应用。然后推广到分布式多目标跟踪场景中，采用仿真和实物实验验证算法对于提升多目标状态估计精度的有效性。

3、降带宽分布式多目标鲁棒跟踪技术研究

为了减小分布式传感器之间的通信带宽，从而进一步提高算法的鲁棒性，在分布式传感器网络中挑选完正常节点后，设计通信策略，使得传感器只和对于提升多目标状态估计精度有帮助的邻居节点进行信息交互。且采用事件触发方法对信息交互次数进行限制，进一步减小通信带宽，提升算法的鲁棒性。

1.2 拟解决的关键问题及难点

在随机干扰存在产生传感器精度下降和传感器本身通信能力限制的情况下保持多目标的精确状态估计对于多目标跟踪定位以及后续的决策控制至关重要。但是，干扰出现时间的不确定性以及受干扰传感器的不确定性给分布式多目标鲁棒跟踪方法设计带来了挑战。现阶段对于多传感器多目标跟踪方面的研究主要集中于滤波跟踪算法的设计、多传感器信息融合算法设计以及多传感器的最优位置分配等方面，对于传感器探测精度下降和通信受限等鲁棒算法的研究十分少见，因此对于传感器精度下降和传感器本身通信能力限制的情况下分布式多目标跟踪方面的研究十分重要。具体亟待解决的问题如下：

1.2.1 分布式多目标跟踪多源信息融合策略研究

现有的多目标状态估计融合方法主要有广义协方差交集（generalized covariance intersection, GCI）融合算法和最小信息损失（minimum information loss, MIL）融合算法。但是两种算法均有弊端，MIL 融合方法会受环境杂波影响，导致目标估计数目多于真实目标数目；GCI 融合方法会受传感器探测能力的影响导

致真实目标跟踪丢失。设计多目标状态估计融合方法将 MIL 融合方法和 GCI 融合方法相结合，获得两种算法的优势，削减劣势，提升分布式多目标状态估计的精度。

1.2.2 分布式传感器网络中探测精度下降传感器的判断方法研究

在随机传感器精度下降情况下分布式多目标鲁棒跟踪问题中，最核心的问题是受干扰传感器的判断与剔除，目前已有的研究判断计算量较大且集中于单目标对于多目标情况并没有进行考虑。改进的聚类算法可以自动实现对于异常数据的判断分类，为受干扰传感器回波的判断提供了新的工具，提升分布式多目标状态估计精度，从而提高跟踪算法的鲁棒性。

1.2.3 分布式传感器网络基于一致性的分布式融合策略设计

在挑选出分布式传感器网络中探测精度下降传感器后，设计对应的基于一致性的分布式融合策略，在不改变分布式传感器网络通信拓扑的基础上，将探测精度下降传感器的本地状态估计剔除，提升分布式状态估计的精度。

1.2.4 分布式多目标跟踪降带宽通信策略研究

由于传感器本身通信能力限制和外界恶意干扰对于通信通道的影响，需要对于分布式多目标跟踪技术中分布式融合方法的通信策略进行研究。通信策略需要解决通信信息的选择、通信的触发设计以及通信次数的寻优。

1.3 拟采用的研究方法、技术路线、实验方案及预期的新意/创新

1.3.1 研究方法

本研究采用的方法主要是模型构建法、研究设计法、理论证明法、仿真验证法和实物实验法。首先构建单传感器多目标跟踪模型，设计多目标状态估计器，采用数字仿真和实物实验研究并分析传感器探测精度对于多目标状态估计精度的影响。进一步扩展到分布式多目标跟踪模型，设计基于交互式多模型的多源信息融合策略，同时研究可以减小通信负担的基于事件触发的通信策略，为后续存

在探测精度下降传感器的降通信带宽分布式多目标鲁棒设计打下研究基础。然后将探测精度下降的传感器引入分布式多目标跟踪模型，利用密度聚类判断探测精度下降的传感器，并设计对应的基于一致性的分布式融合策略剔除探测精度下降的传感器的影响，采用理论证明法证明算法的一致性。最后，为减小部分传感器探测精度下降的分布式多目标跟踪算法的通信带宽，在挑选出的探测精度正常的邻居节点中再次挑选对于提升多目标状态估计精度有作用的邻居节点，同时采用事件触发方法限制数据传输次数，进一步降低通信负担。最后利用仿真验证法和实物验证法对所提分布式多目标鲁棒跟踪算法有效性进行仿真验证，直观展现算法的鲁棒性和可行性。

1.3.2 技术路线

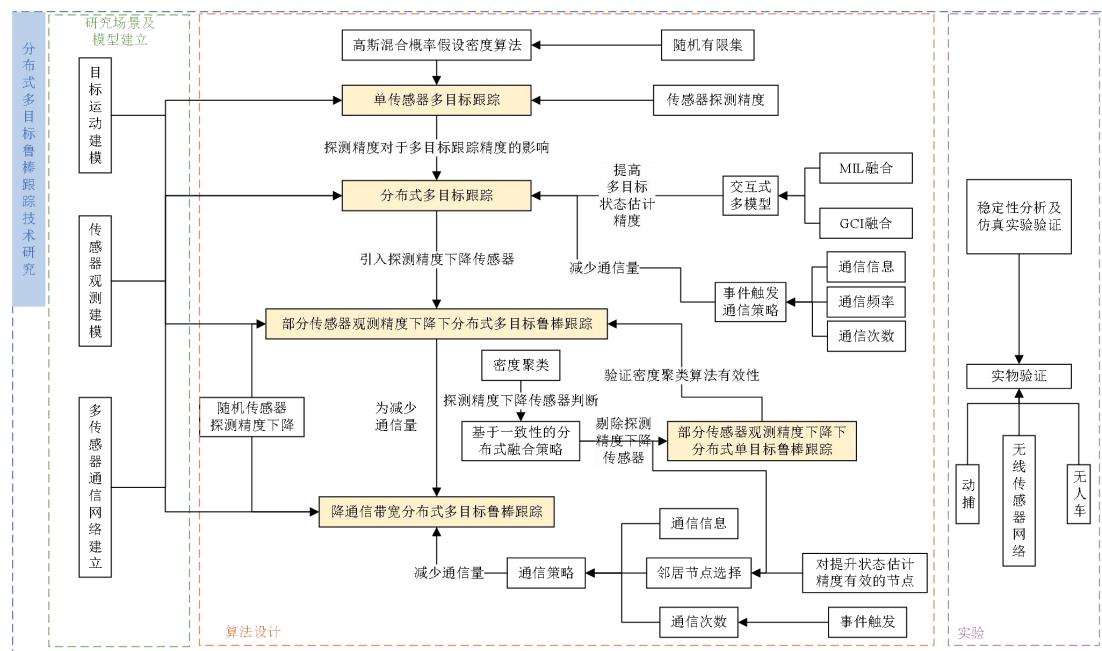


图 1.1 总体研究路线

本课题对于传感器精度下降和降通信带宽的分布式多目标鲁棒跟踪问题进行研究。主要集中于分布式多目标鲁棒跟踪算法的设计，同时利用理论知识对于所提算法进行稳定性证明，最后进行仿真实验和实物实验验证算法的可行性和有效性。总体研究路线图如图 1.1 所示。

1. 传感器探测精度对于多目标状态估计精度影响研究

采用单传感器多目标跟踪模型研究传感器探测精度对于多目标状态估计精

度影响。首先需要建立多目标的运动模型和传感器的观测模型。假设目标的运动模型为

$$x_t = F_{t-1}x_{t-1} + w_{t-1}, \quad (1.1)$$

其中, x_t 为目标在采样时刻 t 的状态向量, x_{t-1} 为目标在采样时刻 $t-1$ 的状态向量, F_{t-1} 表示目标的状态转移矩阵, $w_{t-1} \sim \mathcal{N}(\cdot; 0, Q_{t-1})$ 表示目标运动过程中的不确定性, 服从均值为 0, 方差为 Q_{t-1} 的高斯分布。

传感器的线性观测模型为

$$z_t = H_t x_t + v_t, \quad (1.2)$$

其中, z_t 表示传感器在采样时刻 t 的观测向量。 H_t 为传感器在采样时刻 t 的观测矩阵。 v_t 代表传感器的观测噪声, 服从均值为 0 的高斯分布, 方差为

$$R_t = E[v_t (v_t)^T].$$

然后利用基于随机有限集的多目标状态估计器, 高斯混合概率假设密度 (Gaussian mixture probability hypothesis density, GMMPHD) 算法, 对于多目标的状态和数目进行估计。

假设采样时刻 $t-1$ 传感器的多目标后验强度为

$$v_{t-1} = \sum_{j=1}^{J_{t-1}} w_{t-1}^j \mathcal{N}(x; x_{t-1}^j, P_{t-1}^j), \quad (1.3)$$

那么采样时刻 t 传感器的本地先验多目标强度为

$$v_{t|t-1}(x) = v_{S,t|t-1}(x) + v_{b,t}(x), \quad (1.4)$$

其中

$$\begin{aligned} v_{S,t|t-1}(x) &= P_{s,t} \sum_{j=1}^{J_{t-1}} w_{t-1}^j \mathcal{N}(x; x_{S,t|t-1}^j, P_{S,t|t-1}^j), \\ v_{b,t}(x) &= \sum_{j=1}^{J_{b,t}} w_{b,t}^j \mathcal{N}(x; x_{b,t}^j, P_{b,t}^j), \\ x_{S,t|t-1}^j &= F_{t-1} x_{t-1}^j, \\ P_{S,t|t-1}^j &= F_{t-1} P_{t-1}^j (F_{t-1})^T + Q_{t-1}. \end{aligned}$$

由 (4) 和采样时刻 t 传感器的观测随机有限集 Z_t 可以得到本地后验多目标强度为

$$v_{t|t}(x) = (1 - P_{D,t})v_{t|t-1}(x) + \sum_{z \in Z_t} \sum_{j=1}^{J_{t|t-1}} w_{t|t}^j(z) \mathcal{N}(x; x_{t|t}^j(z), P_{t|t}^j), \quad (1.5)$$

其中

$$\begin{aligned} w_{t|t}^j(z) &= \frac{P_{D,t} w_{t|t-1}^j q_t^j(z)}{\kappa_t + \sum_{k=1}^{J_{t|t-1}} P_{D,t} w_{t|t-1}^k q_t^k(z)}, \\ q_t^j(z) &= \mathcal{N}\left(z; H_t x_{t|t-1}^j, H_t P_{t|t-1}^j (H_t)^T + R_t\right), \\ x_{t|t}^j(z) &= x_{t|t-1}^j + K_t^j(z - H_t x_{t|t-1}^j), \\ P_{t|t}^j &= P_{t|t-1}^j - K_t^j H_t P_{t|t-1}^j, \\ K_t^j &= P_{t|t-1}^j (H_t)^T \left(H_t P_{t|t-1}^j (H_t)^T + R_t\right)^{-1}. \end{aligned}$$

改变传感器的观测噪声 v_t 的协方差矩阵 R_t 的值，用来代表观测精度的大小，研究多目标状态估计精度的变化。

2. 基于交互式多模型的多源信息融合方法研究

在分布式多目标跟踪算法研究中，除了多目标状态估计器的设计，另一个重要的步骤就是对来自于多个传感器的多目标状态估计结果进行融合进一步提高多目标状态估计的精度。现在最为主流的多目标多源信息融合方法主要为 GCI 融合和 MIL 融合，两者各有优缺点，且优缺点互补，因此拟采用交互式多模型将 GCI 融合和 MIL 融合结合在一起，从而提升多源信息融合结果的状态估计精度。

GCI 融合算法的融合公式为：

$$f_{GA}(\chi) = \frac{\prod_{i=1}^L (f_i(\chi))^{w_i}}{\int \prod_{i=1}^L (f_i(x))^{w_i} dx}. \quad (1.6)$$

MIL 融合算法的融合公式为：

$$f_{AA}(\chi) = \sum_{i=1}^L w_i f_i(\chi), \quad (1.7)$$

其中， w 为融合权重， f_i 为传感器的本地多目标状态强度函数。

交互式多模型算法（Interacting Multiple Model, IMM）就是一种可以将多个模型进行融合并自适应转换表征目标状态的方法，其通过马尔可夫转移矩阵来实

现自适应改变每个模型的占用概率来实现不同模型之间的转换，。

此场景有 2 个模型（GCI 和 MIL），马尔可夫转移矩阵则表示为：

$$P = \begin{bmatrix} P_{11} & P_{12} \\ P_{21} & P_{22} \end{bmatrix} \quad (1.8)$$

其中 P_{ij} 为模型 i 到模型 j 的转移概率。

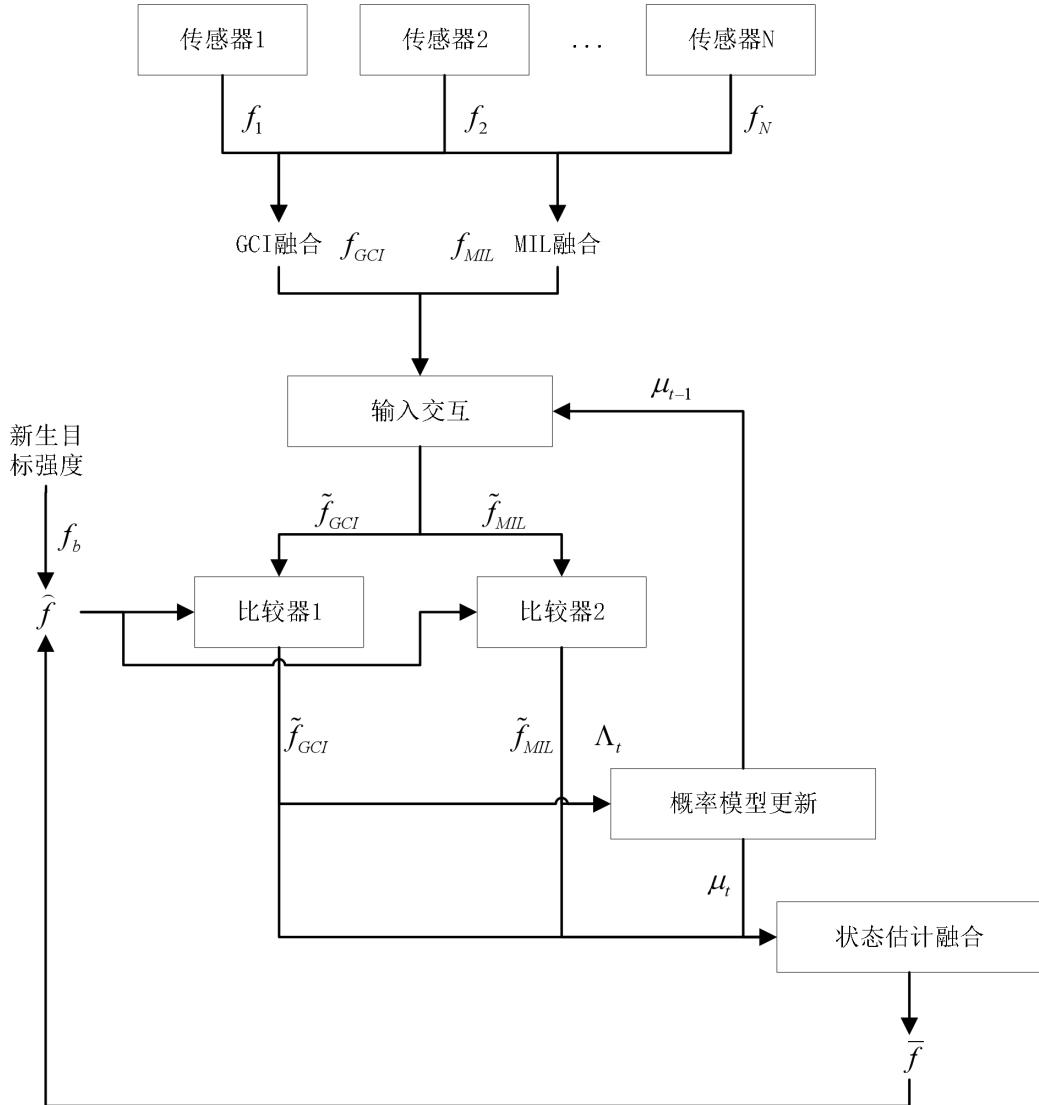


图 1.2 IMM 算法流程

① 输入交互

$$\tilde{f}_{GCI} = \mu_{11}f_{GCI} + \mu_{21}f_{MIL}, \quad (1.9)$$

$$\tilde{f}_{MIL} = \mu_{12}f_{GCI} + \mu_{22}f_{MIL}, \quad (1.10)$$

其中 $\mu_{ij} = \frac{P_{ij}\mu_i}{\sum_{k=1}^2 P_{kj}\mu_k}$, μ_i 为上一时刻模型 i 的概率。

② 比较器

使用 OSPA 方法计算估计多目标强度 \hat{f} 与 \tilde{f}_{GCI} 和 \tilde{f}_{ML} 之间的差距。

$$\hat{f} = \bar{f} + f_b.$$

② 模型概率更新

$$\mu_j = \frac{\Lambda_j \sum_{i=1}^2 P_{ij}\mu_i}{\sum_{k=1}^2 \Lambda_k \sum_{i=1}^2 P_{ik}\mu_i}, \quad (1.11)$$

其中 $\Lambda_i = \frac{e^{-\frac{OSPA_i}{2}}}{\sqrt{2\pi}}$ 。

③ 输出交互

$$\bar{f} = \mu_1 \tilde{f}_{GCI} + \mu_2 \tilde{f}_{ML}. \quad (1.12)$$

IMM 算法流程如图 1.2 所示。

3. 部分传感器探测精度下降下的分布式单目标鲁棒跟踪算法

分布式单目标跟踪算法的本地滤波算法拟采用容积信息卡尔曼滤波算法。与容积卡尔曼滤波算法基本流程相似，只是最后的状态表达形式不同。容积卡尔曼滤波结果 $P_{t|t}$, $x_{t|t}$ 与容积信息卡尔曼滤波算法结果 $Y_{t|t}$, $y_{t|t}$ 的转化关系为：

$$Y_{t|t} = (P_{t|t})^{-1}, \quad (1.13)$$

$$y_{t|t} = Y_{t|t} x_{t|t}. \quad (1.14)$$

得到估计状态后将属于同一目标的状态估计放在一起进行密度聚类，挑选出其中有问题的估计状态，由此可以得到故障传感器的编号，从而将故障传感器从通信网络中删除，输入基于一致性的分布式融合方法。拟采用的密度聚类算法是 DBSCAN 聚类算法，算法流程如算法 1 所示。拟对 DBSCAN 算法智能化改进，可以根据实际情况选择 ε 邻域范围以及核心点阈值 $MinPts$ 。

算法 1： DBSCAN 聚类算法

输入：采样点集 $D=\{x_1, x_2, \dots, x_M\}$ ；参数 ε 和 $MinPts$ 。

输出：聚类结果 $C = \{\{C_1\}, \{C_2\}, \dots, \{C_t\}\}$ 。

1. 初始化核心对象集合 $\Omega = \emptyset, i = 0$ 。

2. 重复

$$i = i + 1.$$

$$N_\varepsilon(x_i) = \left\{ x_j \mid if |x_i - x_j| < \varepsilon, x_j \in D \right\}.$$

如果 $|N_\varepsilon(x_i)| \geq MinPts$,

$$\Omega = \Omega \cup \{x_i\}.$$

直到 $i = M$ 。

3. 初始化 $t = 0, A = D$ 。

4. 重复

$$A_{now} = A,$$

从 Ω 中随机抽取出一个核心对象 x_o 放入 $Q = \{x_o\}$ ，且 $A = A / Q$ 。

当 $\Omega \neq \emptyset$:

$$任取 x_q \in Q,$$

$$Q = Q / x_q,$$

如果 $|N_\varepsilon(x_q)| \geq MinPts$:

$$\Lambda = A \cap N_\varepsilon(x_q),$$

$$Q = Q \cup \Lambda,$$

$$A = A / \Lambda.$$

$$t = t + 1.$$

$$C_t = A_{now} / A.$$

$$\Omega = \Omega / C_t.$$

直到 $\Omega = \emptyset$ 。

4. 部分传感器观测丢失下分布式多目标鲁棒跟踪技术研究

针对于部分传感器观测丢失下的多目标跟踪模型建立，使用观测概率 P_D 来表示传感器丢失观测的程度，即 $P_D \in [0, 1]$ ，

$$P_D = \begin{cases} 0, & \text{观测全部丢失} \\ (0,1), & \text{观测部分丢失。} \\ 1, & \text{观测不丢失} \end{cases} \quad (1.15)$$

拟采用的本地滤波算法为 GMPHD，此算法的核心在于多目标状态的预测更新迭代方程。

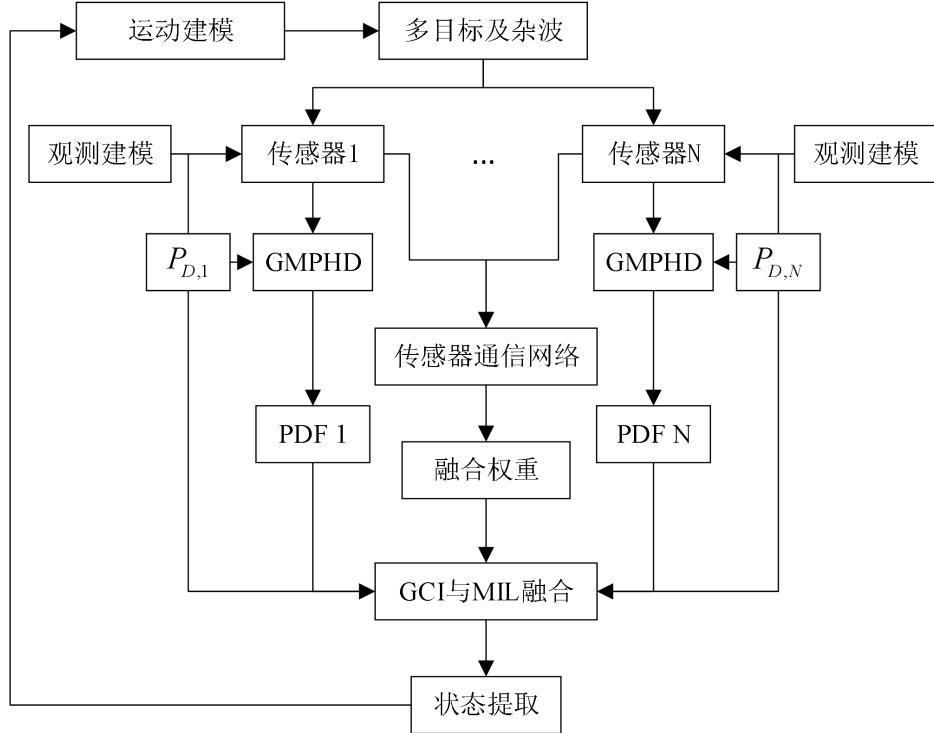


图 1.3 部分传感器观测丢失下分布式多目标鲁棒跟踪算法设计流程图

首先构建目标运动模型和传感器观测模型：

$$\boldsymbol{x}_t = f_{t-1}(\boldsymbol{x}_{t-1}) + \boldsymbol{w}_{t-1}, \quad (1.16)$$

$$\boldsymbol{z}_t^j = h_t^j(\boldsymbol{x}_t) + \boldsymbol{v}_t^j, \quad j = 1, 2, \dots, L, \quad (1.17)$$

其中， L 是传感器节点个数。

GMPHD 算法预测步为（不考虑衍生目标）：

$$D_{t|t-1}(\boldsymbol{x}) = b_t(\boldsymbol{x}) + D_{S,t|t-1}(\boldsymbol{x}), \quad (1.18)$$

其中， $D_{S,t|t-1} = P_{S,t} \sum_{i=1}^{J_{S,t-1}} w_{t-1}^i N(\boldsymbol{x}; \boldsymbol{m}_{S,t|t-1}^i, P_{S,t|t-1}^i)$ ， $b_t = \sum_{i=1}^{J_{b,t}} w_{b,t}^i N(\boldsymbol{x}; \boldsymbol{m}_{b,t}^i, P_{b,t}^i)$ 。 $P_{S,t}$ 为目标存活概率， J 为高斯项的个数， w 为高斯项的权重。

GMPHD 算法更新步为：

$$D_{t|t} = [1 - P_D(x)]D_{t|t-1} + \sum_{z \in Z_t} D_{g,t}(x; z), \quad (1.19)$$

其中, $D_{g,t}(x; z) = \sum_{i=1}^{J_{t|t}} w_{g,t}^i(z) N(x; m_{t|t}^i, P_{t|t}^i)$, $w_{g,t}^i(z) = \frac{P_{D,t} w_{t|t-1}^i q_{g,t}^i(z)}{\kappa_t(z) + P_{D,t} \sum_{j=1}^{J_{t|t-1}} w_{t|t-1}^j q_{g,t}^j(z)}$

$q_{g,t}^i(z) = N(z; H_t m_{t|t-1}^i, R_t + H_t P_{t|t-1}^i H_t^T)$, $P_{D,t}$ 表示目标探测概率, $\kappa_t(\cdot)$ 表示杂波的分布, H_t 为传感器观测矩阵。

最终实现传感器随机故障下的多目标鲁棒跟踪。

5. 降通信带宽分布式多目标鲁棒跟踪研究

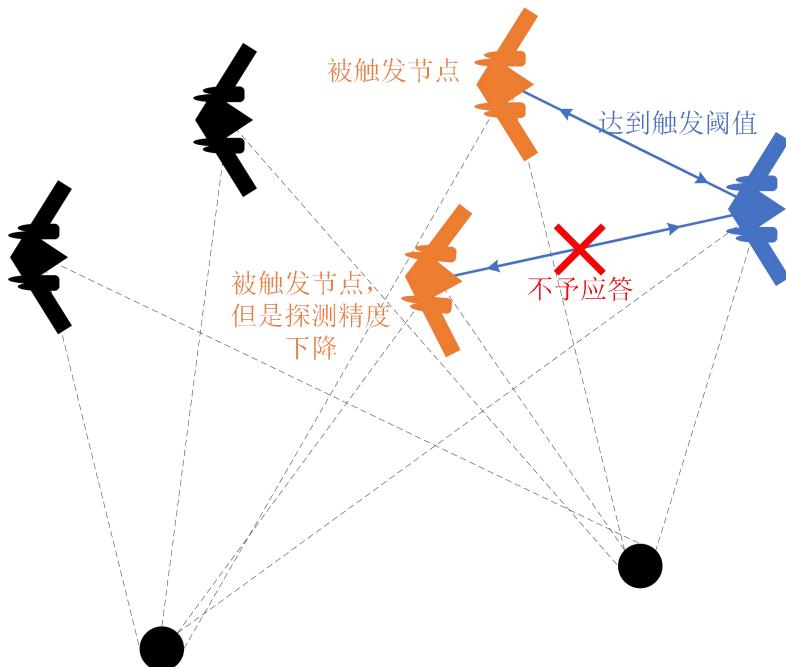


图 1.4 被触发传感器对于触发不予应答

组成无线传感器网络的传感器一般都为轻型、小成本传感器, 自身所能承担的通信带宽、计算能力以及通信能源有限。而对于传感器来说, 与外界进行通信交互是最耗费能量的工作, 为了让传感器能够工作更长的时间, 减少冗余信息的传递, 设计事件触发算法, 只有当前状态满足事件触发条件时, 才进行信息的交互传递。在设计事件触发策略时, 拟将传感器精度下降以及观测丢失条件引入, 设计被触发传感器的应答策略, 当此传感器精度下降时不予应答, 观测丢失时进行一步预测后进行应答。对于事件触发来说, 最重要的是对于事件触发阈值的设计。静态的事件触发阈值并不能反映数据的波动以及当前预测状态的性能, 因此

拟使用自适应事件触发阈值设计, 当数据的波动小以及当前预测状态的性能好时, 阈值基本保持不变, 维持当前的交互频率和滤波效力。当数据出现大波动或者滤波性能差时, 阈值下降, 增大交互频率, 改善滤波能力。仍旧使用 GMHD 算法进行本地多目标状态估计。完成本地状态估计之后, 依旧使用 IMM 融合算法进行多目标后验强度函数融合, 得到最终的多目标状态估计结果。相应的算法流程图如图 1.5 所示。

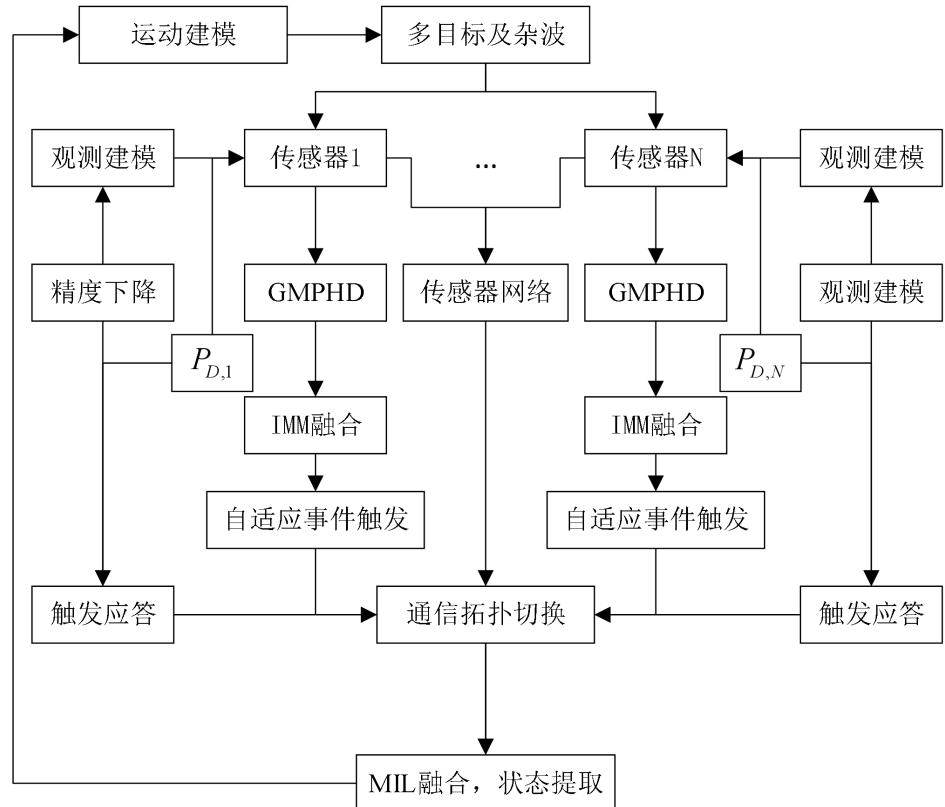


图 1.5 传感器网络通信能力受限下分布式多目标鲁棒跟踪技术设计流程图

设计自适应触发机制:

$$\begin{cases} e_i(t) = z_i(t) - H_i x_i(t), \\ g_i(t) = e_i(t_{l,i}) - e_i(t), \end{cases} \quad (1.20)$$

$$t_{l+1,i} = \inf \left\{ t \mid t > t_{l,i} \text{ 且 } g_i^T(t) g_i(t) - \alpha_i(t) e_i^T(t) e_i(t) > 0 \right\}, \quad (1.21)$$

其中, $t_{l,i}$ 是上一个触发时刻, $z_i(t)$ 是 t 时刻的观测值, $x_i(t)$ 是 t 时刻的状态预测值, H_i 为观测矩阵, $e_i(t)$ 表示当前 t 时刻的滤波能力, $g_i(t)$ 表示上一次触发传输数据与当前数据的波动。

设计自适应触发阈值:

$$\frac{1}{\alpha_i(t)} = \frac{1}{\alpha_i(t-1)} + \frac{e_i^T(t)e_i(t)g_i^T(t)g_i(t)}{1+g_i^T(t)g_i(t)}. \quad (1.22)$$

拟对于被触发传感器的应答情况也进行设置，进一步减小通信负担。如果被触发的传感器存在探测精度下降或者观测丢失的情况，那么与此被触发节点进行信息交互对于提升融合多目标状态估计精度帮助不大，那么此被触发节点不予应答。

1.3.3 实验方案

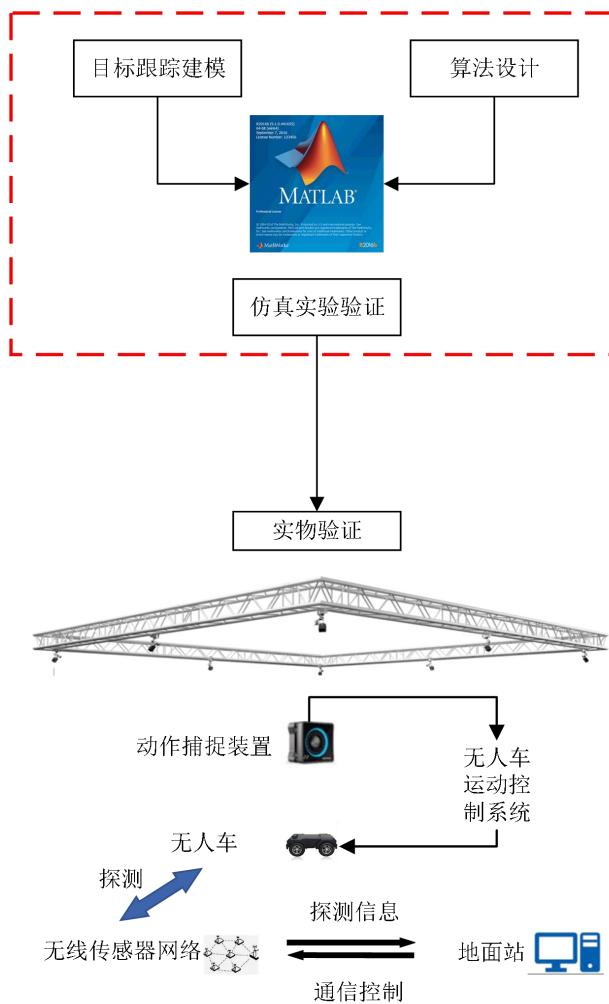


图 1.6 实验方案

本课题所提出的针对于传感器精度下降和降通信带宽所提出的分布式多目标鲁棒算法首先采用数字仿真实验进行验证。在 MATLAB 平台上进行仿真实验，对于目标运动模型进行设置，传感器观测模型设置为雷达观测模型，将精度下降

条件和观测随机丢失条件随机加入多传感器的观测模型，获得精度下降观测或丢失观测下的观测模型，然后使用提出的多目标鲁棒算法进行滤波跟踪，获得的跟踪效果使用最优次模式分配(OSPA)距离和多目标估计数目进行衡量。并且使用未加鲁棒措施的多目标跟踪算法与提出的算法进行对比，展示所提算法的有效性。对于实物实验，采用动捕系统获得当前无人车的运动状态以及位置信息，无人车的运动控制采用单片机写入的运动控制系统。无线传感器网络采用激光测距和红外测角传感器获得目标的探测信息，并将探测信息传入地面站，在地面站进行数据处理和算法验证，得到目标的状态估计结果，将此结果与动捕系统获得的目标实际状态进行对比，验证算法的有效性。

1.3.4 创新点

通过上述技术路线本课题预期实现以下几个创新点：

- (1) 针对于部分传感器精度下降的情况，将改进的密度聚类算法引入对于探测精度下降的传感器进行判断，应对传感器精度下降对于目标跟踪精度的影响。
- (2) 使用交互式多模型算法将 GCI 融合方法与 MIL 融合方法相结合，使得融合算法可以兼具两种算法的优点，提高多目标状态估计的精度。
- (3) 在挑选出分布式传感器网络中探测精度下降传感器后，设计对应的基于一致性的分布式融合策略，在不改变分布式传感器网络通信拓扑的基础上，将探测精度下降传感器的本地状态估计剔除，提升分布式状态估计的精度。
- (4) 针对于传感器节点通信能力受限情况，采用自适应事件触发策略，对于冗余信息传递进行限制，可以根据数据的波动情况以及滤波效果情况对于事件触发阈值进行调整，以达到更好的滤波效果。同时对于被触发节点的应答策略也进行了设计，从被触发节点的角度也对于传输数据的有效性进行评估，可以进一步减小通信负担。
- (5) 将仿真与实物实验相结合，验证算法的有效性。

2. 开题报告的论文工作计划

2022.09-2022.11：文献调研，确定研究计划，准备论文开题

2022.12-2023.02: 完成传感器观测精度下降对多目标状态估计精度影响的研究和数字仿真

2023.03-2023.04: 完成基于交互式多模型的分布式多目标状态融合方法研究和数字仿真

2023.05-2023.06: 整理成果，准备中期答辩

2023.07-2023.08: 完成部分传感器探测精度下降的分布式多目标鲁棒跟踪技术研究和数字仿真

2023.09-2023.10: 完成降通信带宽分布式多目标鲁棒跟踪研究、数字仿真和小论文编写

2023.11-2023.12: 进行实物实验证

2024.01-2024.02: 对于所提算法的稳定性证明进行整理

2024.03-2024.05: 整理相关成果，准备结题

3. 已研究的内容和实现技术及关键技术的突破

3.1 单传感器多目标跟踪算法研究

本章针对于单传感器对于多目标进行状态估计场景，研究传感器的探测精度对多目标状态估计精度的影响。首先建立多目标的运动模型和传感器观测模型，而后采用 GMPHD 算法对于多目标的状态和数目进行估计。在仿真场景中改变传感器探测精度，获得对应的多目标状态估计精度，分析传感器探测精度对多目标状态估计精度的影响。

3.1.1 跟踪系统建模

采用单传感器多目标跟踪模型研究传感器探测精度对于多目标状态估计精度影响。首先需要建立多目标的运动模型和传感器的观测模型。假设目标的运动模型为

$$x_t = F_{t-1}x_{t-1} + w_{t-1}, \quad (3.1)$$

其中， x_t 为目标在采样时刻 t 的状态向量， x_{t-1} 为目标在采样时刻 $t-1$ 的状态向量，

F_{t-1} 表示目标的状态转移矩阵， $w_{t-1} \sim \mathcal{N}(\cdot; 0, Q_{t-1})$ 表示目标运动过程中的不确定性，服从均值为 0，方差为 Q_{t-1} 的高斯分布。

传感器的线性观测模型为

$$z_t = H_t x_t + v_t, , \quad (3.2)$$

其中， z_t 表示传感器在采样时刻 t 的观测向量。 H_t 为传感器在采样时刻 t 的观测矩阵。 v_t 代表传感器的观测噪声，服从均值为 0 的高斯分布，方差为 $R_t = E[v_t (v_t)^T]$ 。

3.1.2 高斯混合概率假设密度算法

然后利用基于随机有限集的多目标状态估计器，高斯混合概率假设密度算法，对于多目标的状态和数目进行估计。

假设采样时刻 $t-1$ 传感器的多目标后验强度为

$$v_{t-1} = \sum_{j=1}^{J_{t-1}} w_{t-1}^j \mathcal{N}(x; x_{t-1}^j, P_{t-1}^j), \quad (3.3)$$

那么采样时刻 t 传感器的本地先验多目标强度为

$$v_{t|t-1}(x) = v_{S,t|t-1}(x) + v_{b,t}(x), \quad (3.4)$$

其中

$$\begin{aligned} v_{S,t|t-1}(x) &= P_{s,t} \sum_{j=1}^{J_{t-1}} w_{t-1}^j \mathcal{N}(x; x_{S,t|t-1}^j, P_{S,t|t-1}^j), \\ v_{b,t}(x) &= \sum_{j=1}^{J_{b,t}} w_{b,t}^j \mathcal{N}(x; x_{b,t}^j, P_{b,t}^j), \\ x_{S,t|t-1}^j &= F_{t-1} x_{t-1}^j, \\ P_{S,t|t-1}^j &= F_{t-1} P_{t-1}^j (F_{t-1})^T + Q_{t-1}. \end{aligned}$$

由(3.4)和采样时刻 t 传感器的观测随机有限集 Z_t 可以得到本地后验多目标强度为

$$v_{t|t}(x) = (1 - P_{D,t}) v_{t|t-1}(x) + \sum_{z \in Z_t} \sum_{j=1}^{J_{t|t}} w_{t|t}^j(z) \mathcal{N}(x; x_{t|t}^j(z), P_{t|t}^j), \quad (3.5)$$

其中

$$\begin{aligned}
w_{t|t}^j(z) &= \frac{P_{D,t} w_{t|t-1}^j q_t^j(z)}{\kappa_t + \sum_{k=1}^{J_{t|t-1}} P_{D,t} w_{t|t-1}^k q_t^k(z)}, \\
q_t^j(z) &= \mathcal{N}\left(z; H_t x_{t|t-1}^j, H_t P_{t|t-1}^j (H_t)^T + R_t\right), \\
x_{t|t}^j(z) &= x_{t|t-1}^j + K_t^j (z - H_t x_{t|t-1}^j), \\
P_{t|t}^j &= P_{t|t-1}^j - K_t^j H_t P_{t|t-1}^j, \\
K_t^j &= P_{t|t-1}^j (H_t)^T \left(H_t P_{t|t-1}^j (H_t)^T + R_t\right)^{-1}.
\end{aligned}$$

3.1.3 仿真

跟踪场景为一个 $[0m, 5000m] \times [0m, 5000m]$ 的二维平面如图 3.1 所示，其中存在 4 个出现和消亡时刻不同的目标，1 个传感器。目标的初始状态 $x_0 = [x_a, \dot{x}_a, y_a, \dot{y}_a]^T$ 和轨迹的开始结束时间分别如表 1 和表 2 所示。仿真总采样时长为 $100s$ ，采样间隔为 $T = 1s$ 。目标的运动模型为匀速直线模型

$$x_t = \begin{bmatrix} 1 & T & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & T \\ 0 & 0 & 0 & 1 \end{bmatrix} x_{t-1} + w_{t-1},$$

其中 $w_{t-1} \sim \mathcal{N}(\cdot; 0, Q)$ ， $Q = \text{diag}([4m^2, 0.2m^2/s^2, 4m^2, 0.2m^2/s^2])$ 。

表 1：目标的初始状态

	1	2	3	4
x_a / m	1000	500	1000	3500
$\dot{x}_a / (m/s)$	30	25	-5	15
y_a / m	1000	3000	1000	1000
$\dot{y}_a / (m/s)$	10	25	25	40

传感器的观测模型为非线性模型

$$z_t = \begin{bmatrix} \sqrt{(x_a - x_s)^2 + (y_a - y_s)^2} \\ \arctan \frac{y_a - y_s}{x_a - x_s} \end{bmatrix} + v_t,$$

其中传感器观测噪声的 $v_t \sim \mathcal{N}(\cdot; 0, R)$, R 代表传感器的探测精度, 与传感器的测距和测角误差有关, 设置的测距和测角误差如表 3 所示。

表 2: 目标轨迹的开始结束时间

	1	2	3	4
T_{start} / s	1	20	40	1
T_{end} / s	60	70	100	80

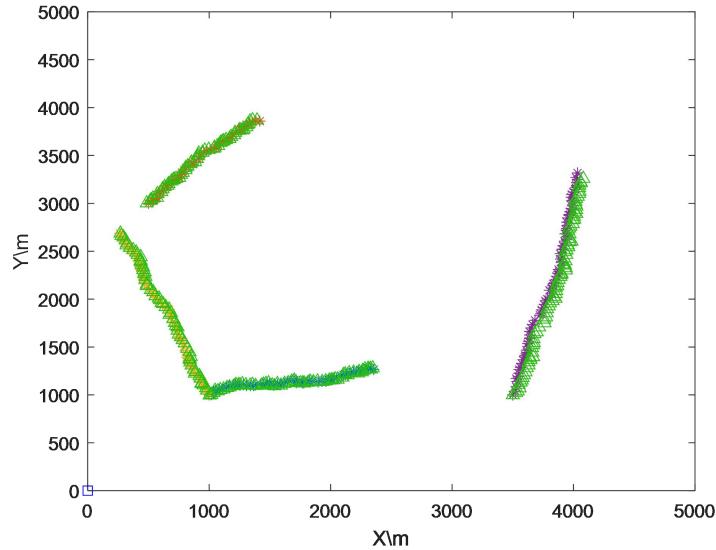


图 3.1 多目标跟踪场景

目标的存活概率为 $P_s = 0.99$, 传感器的探测概率为 $P_D = 1$ 。跟踪场景中的杂波数目服从均值为 1 的泊松分布。采用蒙特卡洛仿真重复 100 次。为了比较衡量多目标状态估计精度, 采用 OSPA ($c = 10, p = 2$), OSPA 的计算公式为

$$D_{p,c}(X, Y) = \begin{cases} \left[\frac{1}{n} \left(\min_{\pi \in \Pi_n} \sum_{i=1}^m (\tilde{d}(x_i, y_{\pi(i)}))^p + (n-m) \times c^p \right) \right]^{\frac{1}{p}}, & m \leq n \\ \left[\frac{1}{m} \left(\min_{\pi \in \Pi_m} \sum_{i=1}^n (\tilde{d}(x_{\pi(i)}, y_i))^p + (m-n) \times c^p \right) \right]^{\frac{1}{p}}, & m \geq n \end{cases},$$

其中 $X = [x_1, x_2, \dots, x_m]$ 表示估计的多目标状态的 RFS, $Y = [y_1, y_2, \dots, y_n]$ 为真实的多目标状态的 RFS, $\tilde{d}(x, y)$ 为 x 和 y 之间的欧氏距离。表 3 中列出的探测精度对应的平均 OSPA 如表 4 所示。

表 3: 测距测角误差

	1	2	3	4	5	6	7
测距 / m	0	10	20	30	40	0	0
测角 / 度	0	0	0	0	0	0.5	1
	8	9	10	11	12	13	
测距 / m	0	0	10	20	30	40	
测角 / 度	1.5	2	0.5	0.5	0.5	0.5	

表 4 探测精度对应的平均 OSPA

	1	2	3	4	5	6	7
OSPA / m	45.96	58.13	69.66	81.813	101.15	79.43	111.62
	8	9	10	11	12	13	
OSPA / m	142.59	179.789	83.49	89.74	104.95	125.06	

从图 3.2 和表 4 可以看出当测角误差为 0, 测距误差从 0 到 40 米时, 对应的多目标状态估计误差也在逐渐增大, 且增大的平均值也接近 10 米。从图 3.3 和表 4 可以看出当测距误差为 0, 测角误差从 0 到 2 度时, 对应的多目标状态估计误差也在逐渐增大, 且增大的平均值接近 30 米。从图 3.4 和表 4 可以看出当测角误差为 0.5 度, 测距误差从 0 到 40 米时, 对应的多目标状态估计误差也在逐渐增大。从仿真结果来看不论是测角误差还是测距误差增大, 均会引起多目标估计精度的下降, 其中角度变化的影响更大一些, 因为探测距离较远, 测角误差引起的探测误差较大。

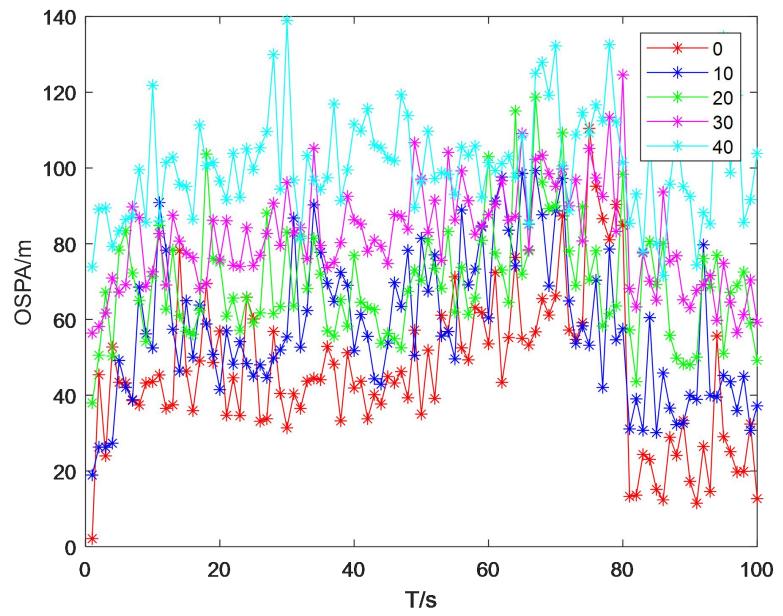


图 3.2 测角误差为 0, 测距误差从 0 到 40 米的 OSPA

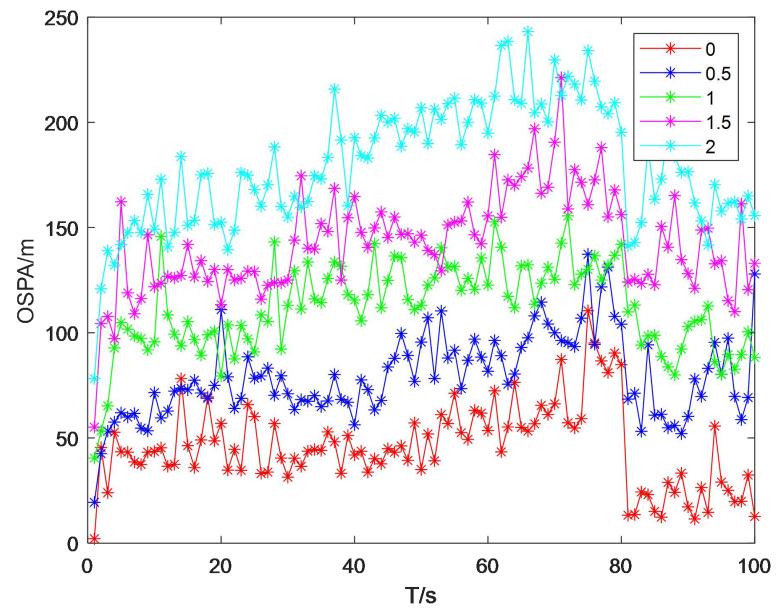


图 3.3 测距误差为 0, 测角误差从 0 到 2 度的 OSPA

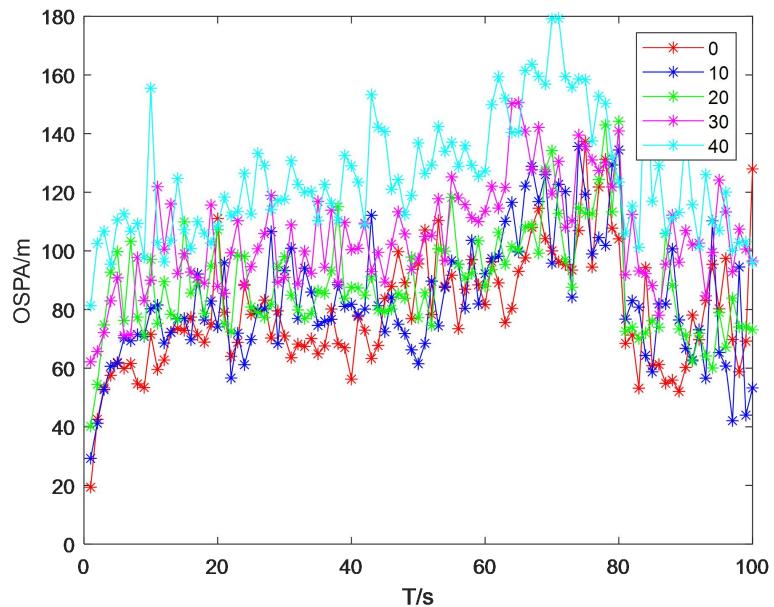


图 3.4 测角误差为 0.5, 测距误差从 0 到 40 米的 OSPA

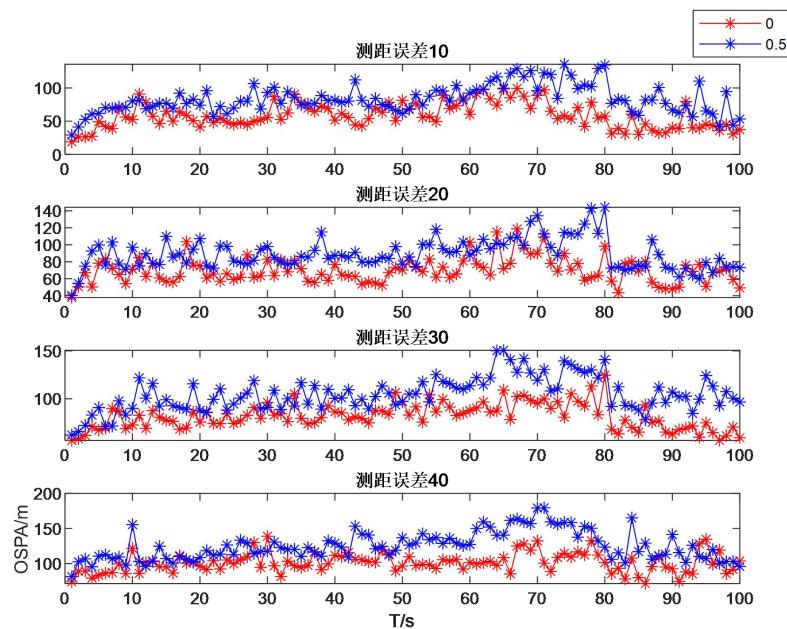


图 3.5 测角误差为 0.5 和 0, 测距误差从 0 到 40 米的 OSPA

3.1.4 总结

本章首先对于单传感器多目标跟踪场景进行建模, 然后采用高斯混合概率假设密度算法对于多目标状态和数目进行估计。使用仿真实验的方法, 验证多目标状态估计的精度与传感器的探测精度密切相关, 不论是传感器测角还是测距误差

增大，多目标状态估计的精度均会增大，证明了剔除精度下降传感器的必要性。此部分由论文《SOM neural network based Gaussian Mixture PHD algorithm for multi-sensor multi-target tracking》支撑。

3.2 分布式多目标跟踪算法研究

本章将单传感器多目标跟踪场景扩充到分布式多传感器多目标跟踪场景，与单传感器对多目标跟踪不同，分布式多传感器多目标跟踪除了需要设计多目标状态估计器外，还需要对分布式传感器之间信息融合方法进行研究。融合算法的优劣直接影响了分布式多目标状态估计的精度。采用交互式多模型的方法将算数平均融合方法和几何平均融合方法相结合，使得算法可以兼具算数平均融合方法不易丢失真实目标和几何平均融合方法不易受环境杂波影响的优点，获得更好的多目标状态估计结果。

3.2.1 分布式多目标跟踪建模

在利用目标的观测对于目标的状态进行估计时，需要获取目标状态的先验信息，这就需要建立目标的运动模型。使用线性函数来描述目标的运动

$$x_t = F_{t-1}x_{t-1} + w_{t-1}, \quad (3.6)$$

其中， x_t 为目标在采样时刻 t 的状态向量， x_{t-1} 为目标在采样时刻 $t-1$ 的状态向量， F_{t-1} 表示目标的状态转移矩阵， $w_{t-1} \sim \mathcal{N}(\cdot; 0, Q_{t-1})$ 表示目标运动过程中的不确定性，服从均值为 0，方差为 Q_{t-1} 的高斯分布。

在分布式目标跟踪中，WSN 中的传感器节点都会对于目标进行探测。传感器的非线性观测模型为

$$z_t^i = H_t^i x_t + v_t^i, i = 1, 2, \dots, N, \quad (3.7)$$

其中， z_t^i 表示第 i 个传感器在采样时刻 t 的观测向量。 H_t^i 为第 i 个传感器在采样时刻 t 的观测矩阵， N 是 WSN 中传感器的数目。 v_t^i 代表第 i 个传感器的观测噪声，服从均值为 0 的高斯分布，方差为 $R_t^i = E[v_t^i (v_t^i)^T]$ 。

在分布式目标跟踪过程中，由于传感器能力的限制和跟踪环境的影响，传感

器节点在对于目标进行探测的过程中会丢失对于目标的观测。此处，传感器的观测丢失用 γ_t^i 来建模， $\gamma_t^i = 1$ 表示第 i 个传感器在采样时刻 t 并没有丢失观测， $\gamma_t^i = 0$ 代表观测丢失，那么传感器的观测模型(3.7)可以改写为

$$z_t^i = \gamma_t^i H_t^i x_t + v_t^i, i = 1, 2, \dots, N. \quad (3.8)$$

在分布式目标跟踪中，WSN 中的传感器节点可以按照通讯拓扑与其邻居节点进行通信，交换信息。根据图论的相关知识[6][7][8]，使用 $G = \{V(G), E(G)\}$ 来描述 WSN 中传感器之间的通信关系。 $V(G) = \{v_1, v_2, \dots, v_N\}$ 代表 WSN 中传感器节点集合， $E(G) = \{(v_i, v_j), i \neq j, v_i, v_j \in V(G)\}$ 是边的集合。

$B_i = \{v_j, (v_j, v_i) \in E(G)\}$ 表示节点 v_i 的邻居节点集合，定义 T_i 为节点 v_i 及其邻居节点集合 B_i 组成的集合， $T_i = \{v_i\} \cup B_i$ 。WSN 的通信拓扑的连通性定义与图的连通性定义相同。在分布式目标跟踪中，需要进行一致性融合来获得更优的状态估计结果，当一致性融合结果为各个节点的状态估计的平均时，称此一致性融合系统满足平均一致性。当一致性融合权重矩阵 Π 为本原矩阵且双重随机时，此权重矩阵 Π 为平均一致性矩阵[9]。当 WSN 的通信拓扑为有向图时，一致性融合权重矩阵 Π 为本原矩阵的必要条件为通信拓扑是强联通的。当有向图满足强联通条件时，为了使得一致性融合权重矩阵 Π 满足双重随机，使用 Metropolis 权重法则设计一致性融合权重矩阵 Π ，使得 Π 为平均一致性矩阵。当 WSN 的通信拓扑为无向图时，采用 Metropolis 权重法则设计的一致性融合权重矩阵 Π 就是本原矩阵[10]。

Metropolis 权重法则设计方法如下

$$\pi^{i,j} = \begin{cases} \frac{1}{1 + \max\{|B_i|, |B_j|\}}, & i \neq j \\ 1 - \sum_{v_k \in B_i} \pi^{i,k}, & i = j \\ 0, & others \end{cases}, \quad (3.9)$$

其中， $\pi^{i,j}$ 为 Π 中第 i 行第 j 列的元素， $|\cdot|$ 为集合中元素的个数。

3.2.2 基于交互式多模型的多目标状态融合算法

首先，在 WSN 中的每个传感器节点处均使用高斯混合概率假设密度算法获得本地多目标状态估计强度。假设采样时刻 $t-1$ 传感器 i 的多目标后验强度为

$$v_{t-1}^i = \sum_{j=1}^{J_{t-1}} w_{t-1}^{i,j} \mathcal{N}(x; x_{t-1}^{i,j}, P_{t-1}^{i,j}), i = 1, 2, \dots, N_s, \quad (3.10)$$

那么采样时刻 t 传感器 i 的本地先验多目标强度为

$$v_{S,t|t-1}^i(x) = v_{S,t|t-1}^i(x) + v_{b,t}^i(x), i = 1, 2, \dots, N_s, \quad (3.11)$$

其中

$$\begin{aligned} v_{S,t|t-1}^i(x) &= P_{s,t} \sum_{j=1}^{J_{t-1}} w_{t-1}^{i,j} \mathcal{N}(x; x_{S,t|t-1}^{i,j}, P_{S,t|t-1}^{i,j}), \\ v_{b,t}^i(x) &= \sum_{j=1}^{J_{b,t}} w_{b,t}^{i,j} \mathcal{N}(x; x_{b,t}^{i,j}, P_{b,t}^{i,j}), \\ x_{S,t|t-1}^{i,j} &= F_{t-1} x_{t-1}^{i,j}, \\ P_{S,t|t-1}^{i,j} &= F_{t-1} P_{t-1}^{i,j} (F_{t-1})^T + Q_{t-1}^j. \end{aligned}$$

由(3.11)和采样时刻 t 传感器 i 的观测随机有限集 Z_t^i 可以得到本地后验多目标强度为

$$v_{t|t}^i(x) = (1 - P_{D,t}) v_{t|t-1}^i(x) + \sum_{z \in Z_t^i} \sum_{j=1}^{J_{t|t-1}} w_{t|t}^{i,j}(z) \mathcal{N}(x; x_{t|t}^{i,j}(z), P_{t|t}^{i,j}), i = 1, 2, \dots, N_s, \quad (3.12)$$

其中

$$\begin{aligned} w_{t|t}^{i,j}(z) &= \frac{P_{D,t} w_{t|t-1}^{i,j} q_t^{i,j}(z)}{\kappa_t + \sum_{k=1}^{J_{t|t-1}} P_{D,t} w_{t|t-1}^{i,k} q_t^{i,k}(z)}, \\ q_t^{i,j}(z) &= \mathcal{N}\left(z; H_t^i x_{t|t-1}^{i,j}, H_t^i P_{t|t-1}^{i,j} (H_t^i)^T + R_t^i\right), \\ x_{t|t}^{i,j}(z) &= x_{t|t-1}^{i,j} + K_t^{i,j}(z - H_t^i x_{t|t-1}^{i,j}), \\ P_{t|t}^{i,j} &= P_{t|t-1}^{i,j} - K_t^{i,j} H_t^i P_{t|t-1}^{i,j}, \\ K_t^{i,j} &= P_{t|t-1}^{i,j} (H_t^i)^T \left(H_t^i P_{t|t-1}^{i,j} (H_t^i)^T + R_t^i\right)^{-1}. \end{aligned}$$

然后，将各个传感器的本地后验多目标强度根据传感器通信拓扑与其邻居节点进行交互，再采用 GCI 融合公式以及 MIL 融合公式对于传感器的本地后验多

目标强度和其邻居节点后验多目标强度进行融合得到各个节点的 GCI 后验目标强度 $v_{t,GCI}^i(x)$ 和 MIL 后验目标强度 $v_{t,MIL}^i(x)$ 。

$$v_{t,GCI}^i(x) = \frac{\prod_{j=1}^{N_s} (v_{t|t}^j(x))^{\pi_{i,j}}}{\int \prod_{j=1}^{N_s} (v_{t|t}^j(\chi))^{\pi_{i,j}} d\chi} \quad (3.13)$$

$$v_{t,MIL}^i(x) = \sum_{j=1}^{N_s} \pi_{i,j} v_{t|t}^j(x) \quad (3.14)$$

用来作为标准的对比多目标强度 $\bar{v}_t(x)$ 由上一时刻的融合多目标强度 $\tilde{v}_{t-1}(x)$ 和新生目标强度 $v_b(x)$ 组成。

$$\bar{v}_t(x) = \tilde{v}_{t-1}(x) + v_b(x) \quad (3.15)$$

$$\text{其中 } \tilde{v}_{t-1}(x) = \sum_{i=1}^{J_{t-1}} \tilde{w}_{t-1}^i \mathcal{N}\left(x; F_{t-1} \tilde{x}_{t-1}^i, F_{t-1} \tilde{P}_{t-1}^i F_{t-1}^T + Q^i\right).$$

此场景有 2 个模型 (GCI 和 MIL)，马尔可夫转移矩阵则表示为：

$$P = \begin{bmatrix} P_{11} & P_{12} \\ P_{21} & P_{22} \end{bmatrix},$$

其中 P_{ij} 为模型 i 到模型 j 的转移概率。

① 输入交互

$$\tilde{v}_{t,GCI}^i(x) = \mu_{t|t-1,11}^i v_{t,GCI}^i(x) + \mu_{t|t-1,11}^i v_{t,MIL}^i(x), \quad (3.16)$$

$$\tilde{v}_{t,MIL}^i(x) = \mu_{t|t-1,12}^i v_{t,GCI}^i(x) + \mu_{t|t-1,22}^i v_{t,MIL}^i(x), \quad (3.17)$$

$$\text{其中 } \mu_{t|t-1,ij}^l = \frac{P_{ij} \mu_{t-1,i}^l}{\sum_{k=1}^2 P_{kj} \mu_{t-1,k}^l}, \quad \mu_{t-1,i}^l \text{ 为上一时刻模型 } i \text{ 的概率。}$$

② 比较器

使用 OSPA 方法计算估计多目标强度 $\bar{v}_t(x)$ 与 $\tilde{v}_{t,GCI}^i(x)$ 和 $\tilde{v}_{t,MIL}^i(x)$ 之间的差距。

$$OSPA_{i,1} = OSPA\left(\bar{v}_t(x), \tilde{v}_{t,GCI}^i(x)\right),$$

$$OSPA_{i,2} = OSPA\left(\bar{v}_t(x), \tilde{v}_{t,MIL}^i(x)\right).$$

③ 模型概率更新

$$\mu_{t,j}^i = \frac{\Lambda_j \sum_{k=1}^2 P_{kj} \mu_{t,k}^i}{\sum_{k=1}^2 \Lambda_k \sum_{l=1}^2 P_{lk} \mu_{t,l}^i}, \quad (3.18)$$

其中 $\Lambda_i = \frac{e^{-\frac{OSPA_i}{2}}}{\sqrt{2\pi}}$ 。

③ 输出交互

$$\tilde{v}_t^i(x) = \mu_{t,1}^i \tilde{v}_{t,GCI}^i(x) + \mu_{t,2}^i \tilde{v}_{t,MIL}^i(x). \quad (3.19)$$

经过多次迭代过程后可以使得各个传感器的融合结果趋于一致得到 $\tilde{v}_t(x)$ 。

3.2.3 仿真

本节构建了一个存在部分传感器探测精度下降的多目标跟踪仿真场景，对于所提的基于交互式多模型的分布式多目标跟踪算法的有效性进行展示，并与采用 MIL 融合方法的分布式 GMPHD (MIL-DGMMPHD) 和 GCI 融合方法的分布式 GMPHD (GCI-DGMMPHD) 的跟踪结果做对比。

跟踪场景为一个 $[0m, 5000m] \times [0m, 5000m]$ 的二维平面如图 3.6 所示，其中存在 4 个出现和消亡时刻不同的目标，10 个分布式分布的传感器。目标的初始状态 $x_0 = [x_a, \dot{x}_a, y_a, \dot{y}_a]^T$ 和轨迹的开始结束时间分别如表 5 和表 6 所示。表 7 记录了 10 个传感器的位置 (x_s, y_s) ，传感器之间的通信拓扑为无向全联通网络，如图 3.6 所示，其中虚线即为传感器之间的通信拓扑。仿真总采样时长为 $100s$ ，采样间隔为 $T = 1s$ 。目标的运动模型为匀速直线的线性模型

$$x_t = \begin{bmatrix} 1 & T & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & T \\ 0 & 0 & 0 & 1 \end{bmatrix} x_{t-1} + w_{t-1},$$

其中 $w_{t-1} \sim \mathcal{N}(\cdot; 0, Q)$ ， $Q = diag([4m^2, 0.2m^2/s^2, 4m^2, 0.2m^2/s^2])$ 。传感器的观测模型为非线性模型

$$z_t = \begin{bmatrix} \sqrt{(x_a - x_s)^2 + (y_a - y_s)^2} \\ \arctan \frac{y_a - y_s}{x_a - x_s} \end{bmatrix} + v_t,$$

其中传感器观测噪声的 $v_t \sim \mathcal{N}(\cdot; 0, R)$, $R = \text{diag}([1m^2, 4.87 \times 10^{-5} rad^2 / s^2])$ 。

表 5: 目标的初始状态

	1	2	3	4
x_a / m	1000	500	2500	3500
$\dot{x}_a / (m/s)$	30	25	10	15
y_a / m	1000	3000	3500	1000
$\dot{y}_a / (m/s)$	10	25	-15	40

表 6: 目标轨迹的开始结束时间

	1	2	3	4
T_{start} / s	1	20	40	1
T_{end} / s	60	70	100	80

表 7: 传感器位置

	1	2	3	4	5	6	7	8	9	10
x_s / m	0	2500	250	5000	5000	2000	1250	100	3500	4750
y_s / m	0	0	500	5000	0	3000	2500	250	3500	4500

从仿真结果可以看出，基于 MIL 的多目标状态估计 OSPA 在 20 米以下，基于 GCI 的多目标状态估计 OSPA 在 100 米以下，而基于 IMM 的多目标状态估计 OSPA 在 15 米以下。且在对于多目标数目的估计上，相比于基于 MIL 和 GCI 的多目标状态估计算法，基于 IMM 的多目标状态估计算法更加接近真实值，实现了采用 IMM 方法融合两者优势的目的。相比于基于 MIL 和 GCI 的多目标状态

估计精度，基于 IMM 的多目标状态估计精度较高，且可以实现 WSN 中传感器多目标估计趋于一致。

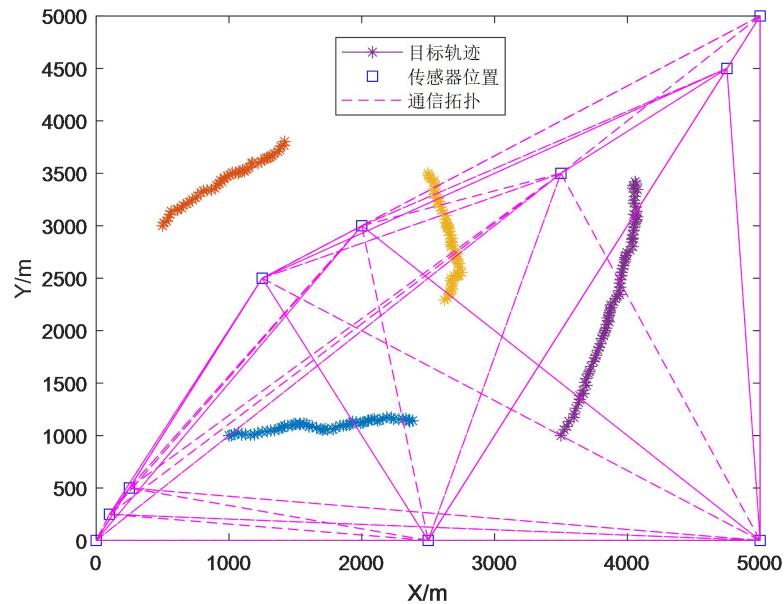


图 3.6 跟踪场景

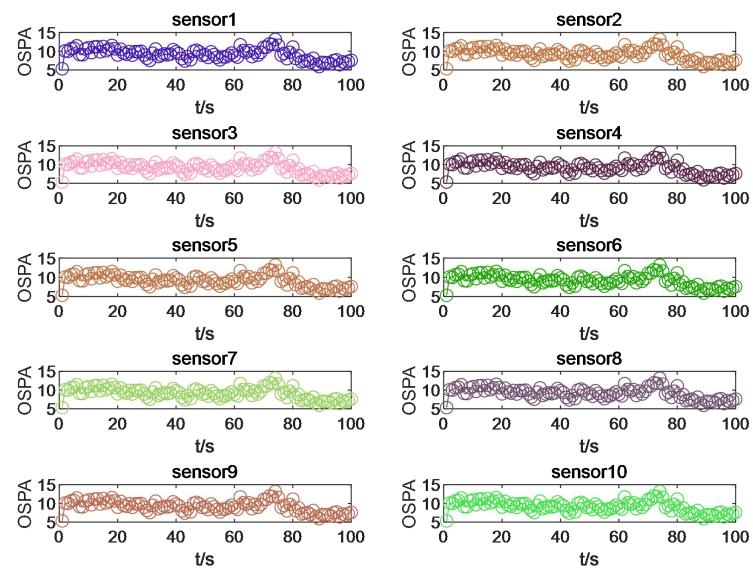


图 3.7 基于 IMM 多目标状态估计 OSPA

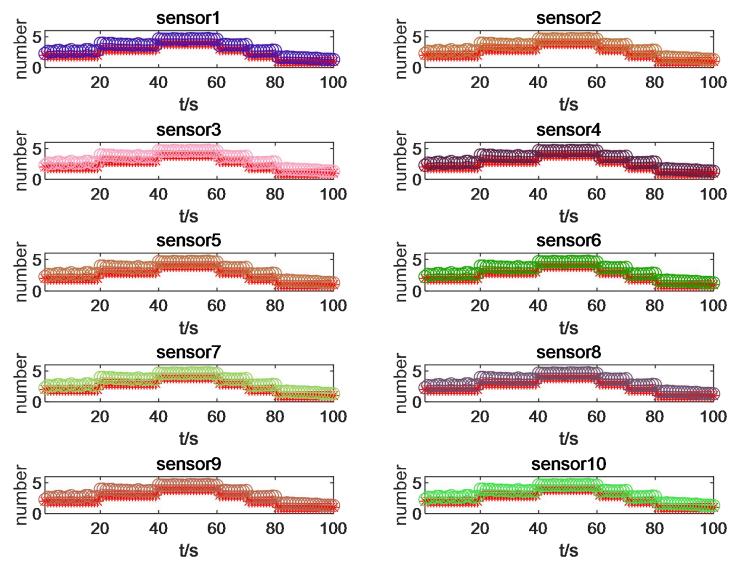


图 3.8 基于 IMM 多目标估计数目

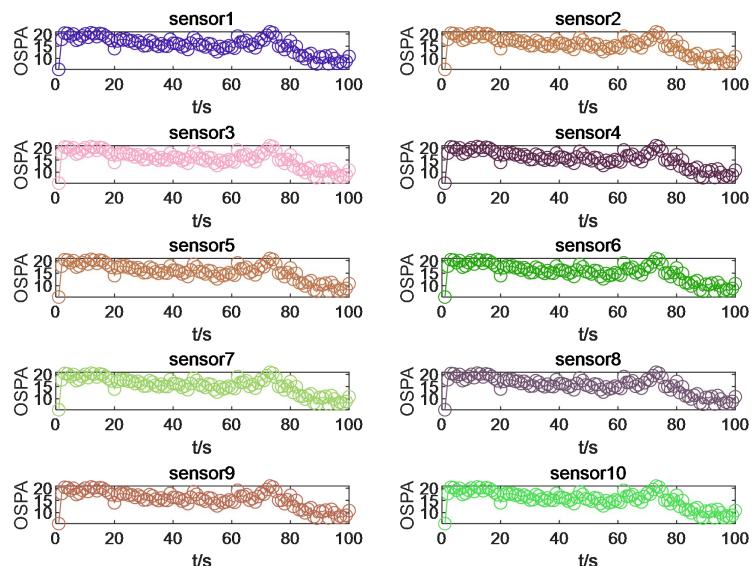


图 3.9 基于 MIL 多目标状态估计 OSPA

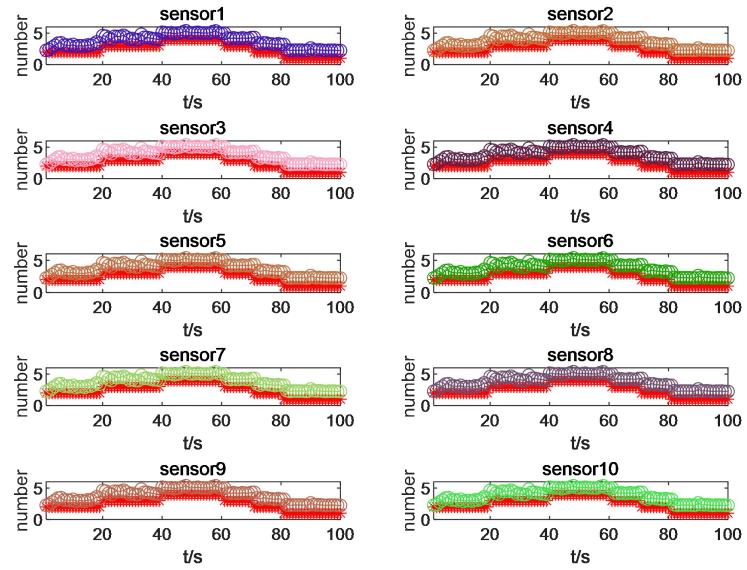


图 3.10 基于 MIL 多目标估计数目

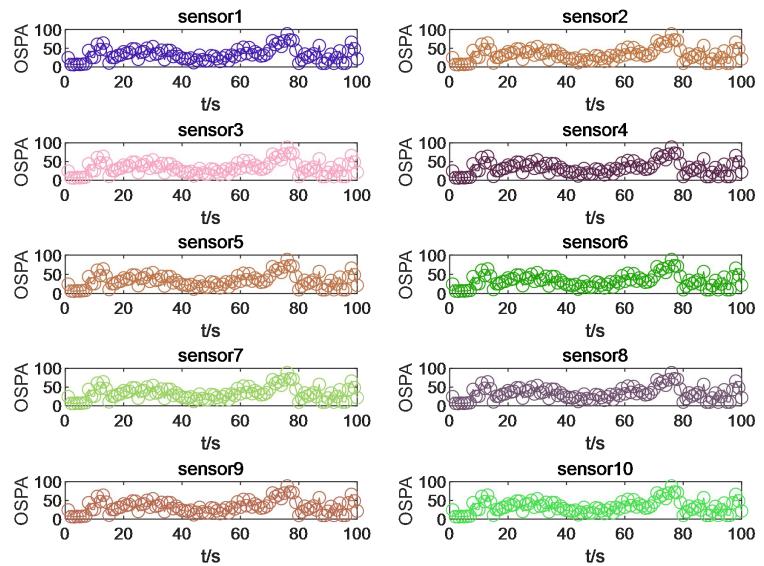


图 3.11 基于 GCI 多目标状态估计 OSPA

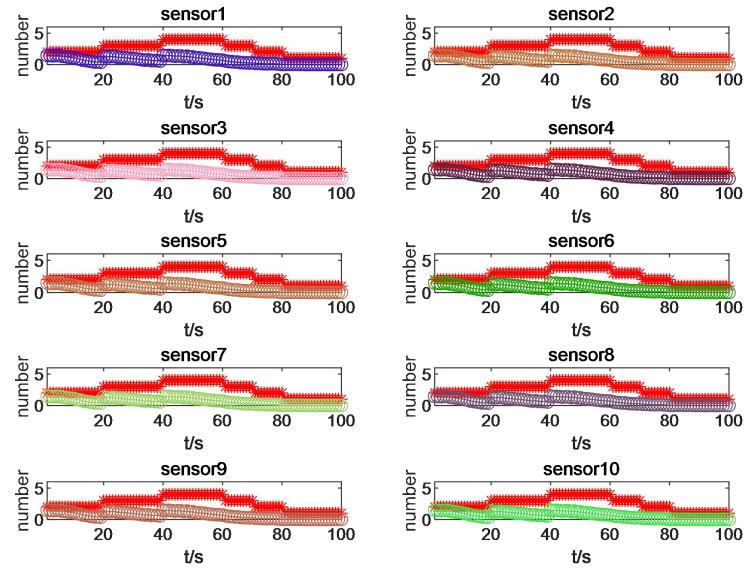


图 3.12 基于 GCI 多目标估计数目

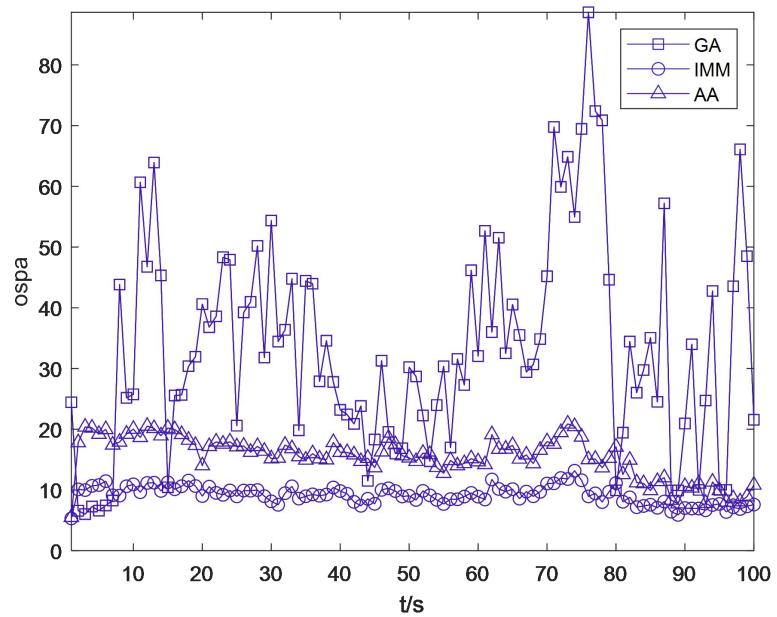


图 3.13 OSPA 对比

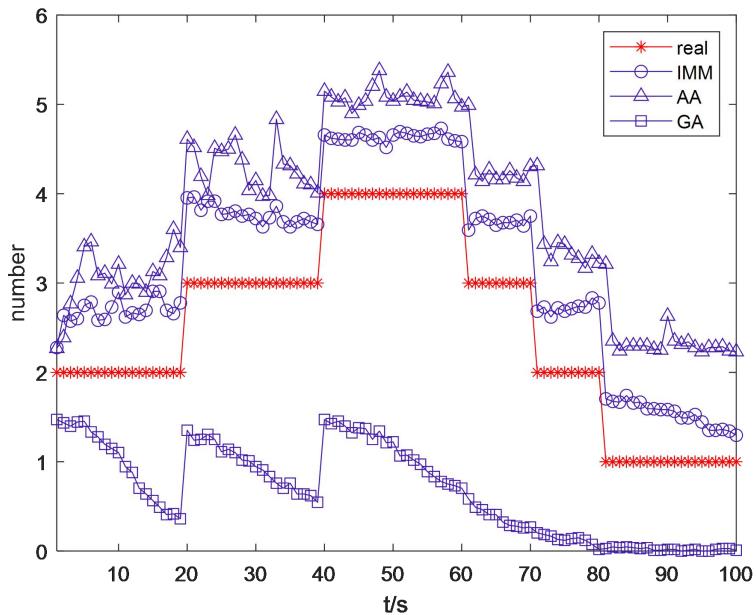


图 3.14 目标估计数目对比

3.2.4 总结

本章将单传感器多目标跟踪场景扩充到分布式多传感器多目标跟踪场景，首先对于分布式多目标跟踪场景进行建模，然后介绍本地多目标状态估计器设计，以及基于交互式多模型的多目标状态融合算法设计。最后采用仿真实验证明了所提基于交互式多模型的多目标状态融合算法的有效性。所提的基于交互式多模型的多目标状态融合算法可以兼具 GCI 融合方法和 MIL 融合方法的优点，在减少杂波检出的同时保留真实目标，提升了多目标状态估计的精度，可以根据实际的滤波情况和对于实际多目标状态分布的估计迭代实现多目标鲁棒持续跟踪。此部分由论文《Measurement based dimension descent association algorithm for OTHR multi-detection multi-target tracking》支撑。

3.3 基于密度聚类的分布式单目标鲁棒跟踪算法研究

本章针对于无线传感器网络（wireless sensor network, WSN）中存在部分传感器探测精度下降的情况，对于单目标的分布式鲁棒跟踪算法进行研究。首先采用容积信息卡尔曼滤波器（cubature Information filter, CIF）[1]进行本地状态估

计，然后利用密度聚类算法（density based spatial clustering of application with noise, DBSCAN）[2][3][4]将探测精度下降的传感器节点挑选出来。此外，还提出了一种新颖的基于加权平均一致性融合方法[1][5]，叫做改进的基于一致性的融合（improved consensus based fusion, ICF）方法。此方法可以将精度下降的错误节点的滤波结果删去，利用正常节点的滤波结果进行一致性融合。对于所提的基于 DBSCAN 的分布式容积信息卡尔曼滤波器（distributed cubature Information filter, DCIF）算法的稳定性进行了分析，通过理论分析证明所提算法估计误差的有界性。

3.3.1 跟踪模型建模

在利用目标的观测对于目标的状态进行估计时，需要获取目标状态的先验信息，这就需要建立目标的运动模型。使用非线性函数来描述目标的运动

$$x_t = f_{t-1}(x_{t-1}) + w_{t-1}, \quad (3.20)$$

其中， x_t 为目标在采样时刻 t 的状态向量， x_{t-1} 为目标在采样时刻 $t-1$ 的状态向量， $f_{t-1}(\cdot)$ 表示目标的状态转移函数， $w_{t-1} \sim \mathcal{N}(\cdot; 0, Q_{t-1})$ 表示目标运动过程中的不确定性，服从均值为 0，方差为 Q_{t-1} 的高斯分布。

在分布式目标跟踪中，WSN 中的传感器节点都会对于目标进行探测。传感器的非线性观测模型为

$$z_t^i = h_t^i(x_t) + v_t^i, i = 1, 2, \dots, N, \quad (3.21)$$

其中， z_t^i 表示第 i 个传感器在采样时刻 t 的观测向量。 $h_t^i(x_t)$ 为第 i 个传感器在采样时刻 t 的观测方程， N 是 WSN 中传感器的数目。 v_t^i 代表第 i 个传感器的观测噪声，服从均值为 0 的高斯分布，方差为 $R_t^i = E[v_t^i(v_t^i)^T]$ 。

在分布式目标跟踪过程中，由于传感器能力的限制和跟踪环境的影响，传感器节点在对于目标进行探测的过程中会丢失对于目标的观测。此处，传感器的观测丢失用 γ_t^i 来建模， $\gamma_t^i = 1$ 表示第 i 个传感器在采样时刻 t 并没有丢失观测， $\gamma_t^i = 0$ 代表观测丢失，那么传感器的观测模型(3.21)可以改写为

$$z_t^i = \gamma_t^i h_t^i(x_t) + v_t^i, i = 1, 2, \dots, N. \quad (3.22)$$

在分布式目标跟踪中，WSN 中的传感器节点可以按照通讯拓扑与其邻居节点进行通信，交换信息。根据图论的相关知识[6][7][8]，使用 $G = \{V(G), E(G)\}$ 来描述 WSN 中传感器之间的通信关系。 $V(G) = \{v_1, v_2, \dots, v_N\}$ 代表 WSN 中传感器节点集合， $E(G) = \{(v_i, v_j), i \neq j, v_i, v_j \in V(G)\}$ 是边的集合。 $B_i = \{v_j, (v_j, v_i) \in E(G)\}$ 表示节点 v_i 的邻居节点集合，定义 T_i 为节点 v_i 及其邻居节点集合 B_i 组成的集合， $T_i = \{v_i\} \cup B_i$ 。WSN 的通信拓扑的连通性定义与图的连通性定义相同。

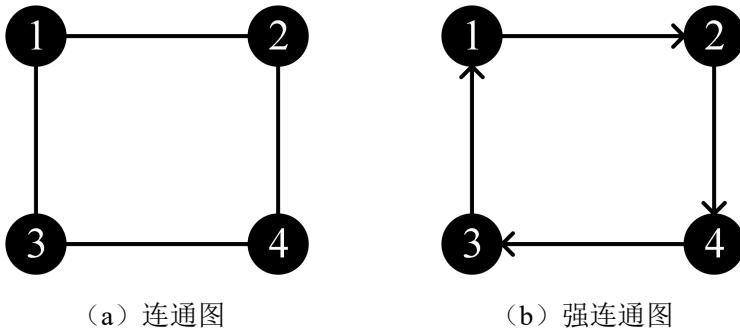


图 3.15 图的连通性

定义 1：在无向图 G 中，如果对于任意的两个节点 v_i, v_j ，均存在一条从 v_i 到 v_j 的路径，那么称图 G 为连通图。

定义 2：在有向图 G 中，如果对于任意的两个节点 v_i, v_j ，均存在一条从 v_i 到 v_j 的路径和一条从 v_j 到 v_i 的路径，那么称图 G 为强连通图。

在分布式目标跟踪中，需要进行一致性融合来获得更优的状态估计结果，当一致性融合结果为各个节点的状态估计的平均时，称此一致性融合系统满足平均一致性。当一致性融合权重矩阵 Π 为本原矩阵且双重随机时，此权重矩阵 Π 为平均一致性矩阵[9]。当 WSN 的通信拓扑为有向图时，一致性融合权重矩阵 Π 为本原矩阵的必要条件为通信拓扑是强联通的。当有向图满足强联通条件时，为了使得一致性融合权重矩阵 Π 满足双重随机，使用 Metropolis 权重法则设计一致性融合权重矩阵 Π ，使得 Π 为平均一致性矩阵。当 WSN 的通信拓扑为无向图时，采用 Metropolis 权重法则设计的一致性融合权重矩阵 Π 就是本原矩阵[10]。

Metropolis 权重法则设计方法如下

$$\pi^{i,j} = \begin{cases} \frac{1}{1 + \max\{|B_i|, |B_j|\}}, & i \neq j \\ 1 - \sum_{v_k \in B_i} \pi^{i,k}, & i = j \\ 0, & others \end{cases}, \quad (3.23)$$

其中， $\pi^{i,j}$ 为 Π 中第 i 行第 j 列的元素， $|\cdot|$ 为集合中元素的个数。

3.3.2 随机观测丢失的容积信息卡尔曼滤波器

分布式目标跟踪需要在各个传感器节点进行本地状态估计。卡尔曼滤波器[11]利用目标状态的先验信息和当前的观测信息对目标的当前状态做出精确估计，但是当系统不确定性很高时，会导致误差协方差矩阵趋于无穷大，进而出现滤波发散等情况。CIF 作为容积卡尔曼滤波器[12][13]的对偶形式，当系统不确定性很高时，信息误差协方差矩阵会趋于 0，保持滤波跟踪的稳定。因此，本文采取 CIF 作为本地滤波器。

估计状态向量 \hat{x}_t 、误差协方差矩阵 P_t 、信息状态向量 \hat{y}_t 和信息矩阵 Y_t 之间的转换关系[14]如下

$$\begin{cases} Y_t = (P_t)^{-1} \\ \hat{y}_t = Y_t \hat{x}_t \end{cases}. \quad (3.24)$$

1) 随机观测丢失的容积信息卡尔曼滤波器的预测步

假设节点 v_i 在采样时刻 $t-1$ 的估计状态向量和误差协方差矩阵分别为 $\hat{x}_{t-1|t-1}^i$ 和 $P_{t-1|t-1}^i$ 。使用球-径向容积理论采样得到采样点为

$$x_{t-1|t-1}^{i,j} = \hat{x}_{t-1|t-1}^i + S_{t-1|t-1}^i \xi_j, \quad j = 1, 2, \dots, 2n, \quad (3.25)$$

其中， $P_{t-1|t-1}^i = S_{t-1|t-1}^i (S_{t-1|t-1}^i)^T$ 。 $\xi_j = \begin{cases} \sqrt{n} e_j, & j = 1, 2, \dots, n \\ -\sqrt{n} e_{j-n}, & j = n+1, n+2, \dots, 2n \end{cases}$ ， e_j 为第 j 维

元素为 1 的 n 维单位向量。根据(3.20)定义的目标的运动模型，得到每个采样点的预测状态为

$$x_{t|t-1}^{i,j} = f_{t-1}(x_{t-1|t-1}^{i,j}), \quad j = 1, 2, \dots, 2n. \quad (3.26)$$

由(3.26)可知先验估计目标状态可表示为

$$\hat{x}_{t|t-1}^i = \frac{1}{2n} \sum_{j=1}^{2n} x_{t|t-1}^{i,j}. \quad (3.27)$$

根据(3.20)、(3.26)和(3.27)，可得到先验误差协方差为

$$P_{t|t-1}^i = \frac{\sum_{j=1}^{2n} x_{t|t-1}^{i,j} (x_{t|t-1}^{i,j})^T}{2n} - \hat{x}_{t|t-1}^i (\hat{x}_{t|t-1}^i)^T + Q_{t-1}. \quad (3.28)$$

由(3.24)可得先验信息状态向量和先验信息矩阵为

$$\begin{cases} Y_{t|t-1}^i = (P_{t|t-1}^i)^{-1} \\ \hat{y}_{t|t-1}^i = Y_{t|t-1}^i \hat{x}_{t|t-1}^i \end{cases}. \quad (3.29)$$

2) 随机观测丢失的容积信息卡尔曼滤波器的更新步

与预测步相同，CIF 的更新步首先利用先验状态向量 $\hat{x}_{t|t-1}^i$ 和先验误差协方差矩阵 $P_{t|t-1}^i$ 获取采样点

$$\chi_{t|t-1}^{i,j} = \hat{x}_{t|t-1}^i + S_{t|t-1}^i \xi_j, j = 1, 2, \dots, 2n, \quad (3.30)$$

其中， $P_{t|t-1}^i = S_{t|t-1}^i (S_{t|t-1}^i)^T$ 。由传感器的观测方程(3.22)可得各个采样点的观测为

$$z_{t|t-1}^{i,j} = \gamma_t^i h_t^i (\chi_{t|t-1}^{i,j}). \quad (3.31)$$

由(3.31)可知采样点的估计观测向量为

$$\hat{z}_{t|t-1}^i = \frac{\sum_{j=1}^{2n} z_{t|t-1}^{i,j}}{2n}. \quad (3.32)$$

根据(3.30)、(3.31)和(3.32)可以得到量测误差协方差矩阵 $P_{zz,t|t-1}^i$ 和交叉协方差矩阵 $P_{xz,t|t-1}^i$ 为

$$\begin{cases} P_{zz,t|t-1}^i = \frac{\sum_{j=1}^{2n} z_{t|t-1}^{i,j} (z_{t|t-1}^{i,j})^T}{2n} - \hat{z}_{t|t-1}^i (\hat{z}_{t|t-1}^i)^T + R_t^i \\ P_{xz,t|t-1}^i = \frac{\sum_{j=1}^{2n} \chi_{t|t-1}^{i,j} (z_{t|t-1}^{i,j})^T}{2n} - \hat{x}_{t|t-1}^i (\hat{z}_{t|t-1}^i)^T \end{cases}. \quad (3.33)$$

信息增益向量和信息增益矩阵为

$$\begin{cases} I_t^i = \mathcal{A} (R_t^i)^{-1} \mathcal{A}^T \\ i_t^i = \mathcal{A} (R_t^i)^{-1} (z_t^i - \hat{z}_{t|t-1}^i + \mathcal{A}^T \hat{x}_{t|t-1}^i) \end{cases}, \quad (3.34)$$

其中, $\mathcal{A} = Y_{t|t-1}^i P_{xz,t|t-1}^i$ 。由(3.31)- (3.34)可以看出, 如果 v_i 的观测丢失, 那么 $\mathcal{A} = \mathbf{0}^{n \times m}$, $I_t^i = \mathbf{0}^{n \times n}$, $i_t^i = \mathbf{0}^n$, m 为观测向量的维数, 即观测丢失的节点更新步的信息增益为 0, 为了更加显式的表现观测丢失对于信息增益的影响将(3.34)改写为

$$\begin{cases} I_t^i = \gamma_t^i \mathcal{A} (R_t^i)^{-1} \mathcal{A}^T \\ i_t^i = \gamma_t^i \mathcal{A} (R_t^i)^{-1} (z_t^i - \hat{z}_{t|t-1}^i + \mathcal{A}^T \hat{x}_{t|t-1}^i) \end{cases} \circ \quad (3.35)$$

根据(3.29)和(3.35)得到后验信息状态向量和后验信息矩阵为

$$\begin{cases} Y_{t|t}^i = Y_{t|t-1}^i + I_t^i \\ \hat{y}_{t|t}^i = \hat{y}_{t|t-1}^i + i_t^i \end{cases} \circ \quad (3.36)$$

WSN 中的传感器存在随机观测丢失, 在每个采样时刻传感器都可能会丢失观测, 观测丢失后无法利用观测对于先验估计状态进行修正, 因此观测丢失的节点的后验估计目标状态和后验误差协方差矩阵就是先验估计目标状态和先验误差协方差矩阵, 并利用观测标志 γ_t^i 显式表示出来。

3.3.3 改进的基于一致性的加权平均融合方法

WSN 中的传感器节点进行本地 CIF 滤波获得本地估计后, 由于部分传感器节点存在观测精度下降的情况, 得到的本地估计的精度也会下降, 直接进行分布一致性融合, 会导致融合精度下降。为了提升分布一致性融合的精度, 需要将观测精度下降的传感器节点的本地估计结果剔除。首先需要从 WSN 中挑选出精度下降的传感器。根据传感器的观测特性, 量测映射到目标状态空间后会聚集在目标真实状态的周围, 而精度下降的量测映射到目标状态空间后会孤立地分布在聚集簇的外围, 如图 3.16 所示。因此采用 DBSCAN 聚类方法, 可以区分密集聚集的正常量测和孤立分布的精度下降量测。需要注意的是, 这种方法具有一定的局限性, 要求 WSN 的传感器节点为相同的传感器, 即精度不下降时的观测方差相同, 且为了保证 DBSCAN 算法的顺利实施, 要求至少一半传感器节点的探测精度正常。这些要求在实际的应用中容易满足, 是合理的假设。

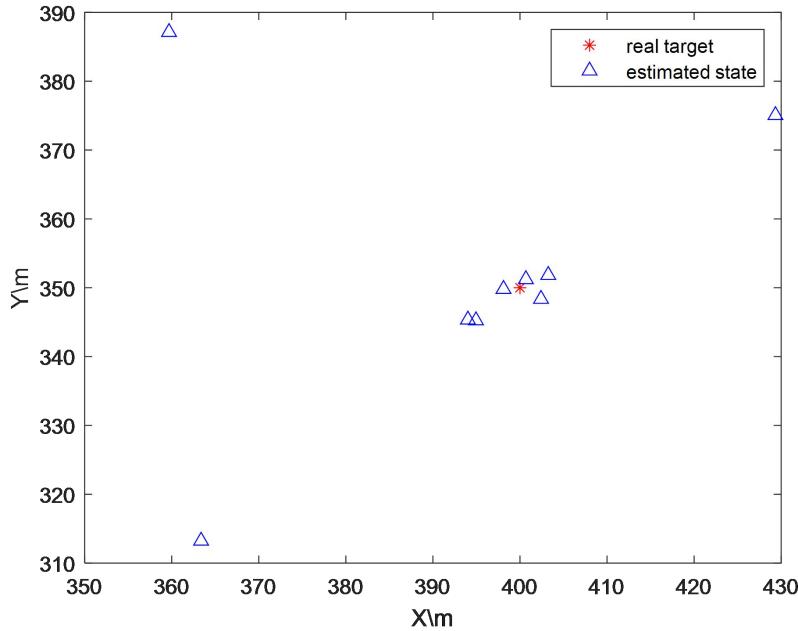


图 3.16 传感器观测特性示意图

1) DBSCAN 聚类判断精度下降节点

首先, WSN 中的节点根据通信拓扑传递各个节点的带有节点 ID 编号的本地信息滤波结果。初始时第 i 个传感器节点的信息集为

$$M_0^i = \{i, Y_{t|t}^i, \hat{y}_{t|t}^i\}, i = 1, 2, \dots, N. \quad (3.37)$$

第 λ 次通信迭代时第 i 个传感器节点的信息集为

$$M_\lambda^i = M_{\lambda-1}^i \cup O_\lambda^i, \lambda = 1, 2, \dots, \quad (3.38)$$

其中, $O_\lambda^i = \left\{ \left\{ k, Y_{t|t}^k, \hat{y}_{t|t}^k \right\} \middle| \pi^{i,j} \neq 0, \left\{ k, Y_{t|t}^k, \hat{y}_{t|t}^k \right\} \notin M_{\lambda-1}^i, \left\{ k, Y_{t|t}^k, \hat{y}_{t|t}^k \right\} \in M_{\lambda-1}^j \right\}$ 。迭代直到 WSN 中出现某个传感器节点 r 收集到了 WSN 中所有节点的本地信息滤波结果, 即

$$|M_\lambda^r| = N, \quad (3.39)$$

其中 $|M_\lambda^r|$ 表示集合 M_λ^r 中元素的个数。在节点 r 处进行 DBSCAN 聚类, 聚类的参数 ε -邻域的聚类半径 ε 和 ε -邻域最小元素个数 (MinPts), 根据实际的跟踪场景选取。首先, 将估计的信息对转换为估计的状态对

$$\bar{M}^r = \left\{ \left(i, \hat{x}_{t|t}^i, P_{t|t}^i \right) \middle| \hat{x}_{t|t}^i = \left(P_{t|t}^i \right)^{-1} \hat{y}_{t|t}^i, P_{t|t}^i = \left(Y_{t|t}^i \right)^{-1}, i = 1, \dots, N \right\}. \quad (3.40)$$

然后计算每个估计状态向量的 ε -邻域

$$N_\varepsilon(\hat{x}_{t|t}^i) = \left\{ (j, \hat{x}_{t|t}^j, P_t^j) \mid i \neq j, \left| \hat{x}_{t|t}^i - \hat{x}_{t|t}^j \right| < \varepsilon \right\}, i = 1, \dots, N. \quad (3.41)$$

根据每个估计状态向量的 ε -邻域挑选核心点

$$\Omega = \left\{ (i, \hat{x}_{t|t}^i, P_t^i) \mid \left| N_\varepsilon(\hat{x}_{t|t}^i) \right| \geq \text{MinPts}, i = 1, \dots, N \right\}. \quad (3.42)$$

聚类核心点

$$\begin{aligned} \Omega_{\text{now}} &= \Omega, \\ Q &= \left\{ (k, \hat{x}_t^k, P_t^k) \mid (k, \hat{x}_t^k, P_t^k) \in \Omega \right\}. \end{aligned} \quad (3.43)$$

Repeat

$$\begin{aligned} \Lambda &= \Omega \cap N_\varepsilon(\hat{x}_t^p), \forall (p, \hat{x}_t^p, P_t^p) \in \Omega, \\ Q &= Q / (p, \hat{x}_t^p, P_t^p), \\ Q &= Q \cup \Lambda, \\ \Omega &= \Omega / \Lambda. \end{aligned}$$

Until $Q = \emptyset$

$$\begin{aligned} C &= \Omega_{\text{now}} / \Omega, \\ L_t &= \left\{ q \mid (q, \hat{x}_t^q, P_t^q) \in C \right\}. \end{aligned} \quad (3.44)$$

挑选出正常精度的节点编号集合 L_t 。随后此节点将正常节点广播给其他节点，进入分布一致性融合。WSN 的通信拓扑为分布式，在进行 DBSCAN 聚类时采用分布式传播的形式，可以保持分布式结构的优势，没有唯一的中心节点，每个传感器都可以是中心节点，有较强的鲁棒性。同时只迭代传播到有一个节点获得所有本地滤波估计为止，又拥有集中式的优点，此节点成为 DBSCAN 聚类的中心，其他节点并不进行计算，且不再进行迭代传播，减少了通信负担和能量消耗。因此，这种分布式的信息传播和集中式的信息处理在增强鲁棒性的同时减小了通信负担。

2) 改进的基于一致性的加权平均融合

i. 初始化

由于故障节点的探测精度下降导致本地滤波估计的精度也要低于正常节点，因此要提升分布一致性融合的精度要将精度下降节点的本地滤波估计剔除。正常节点会接收其正常邻居节点的信息并按照融合权重进行融合，不接收错误邻居节点的信息。错误的节点会接收其正常邻居节点的信息并按照融合权重进行融合，

不接收错误邻居节点的信息。按照这种通信方式，融合权重矩阵变为

$$\bar{\Pi}_t = \Pi \times \mathcal{L}_t, \quad (3.45)$$

其中， $\mathcal{L}_t \in \mathbb{R}^{N \times N}$ 且

$$\mathcal{L}_t^{i,j} = \begin{cases} 1, & i \in L_t, i = j \\ 0, & others \end{cases} \circ \quad (3.46)$$

这就造成权重矩阵 $\bar{\Pi}_t$ 的行元素的和不为 1，因此进行行归一化处理

$$\tilde{\Pi}_t^{i,j} = \frac{\bar{\Pi}_t^{i,j}}{\sum_{k=1}^N \bar{\Pi}_t^{i,k}} \quad (3.47)$$

得到 $\tilde{\Pi}_t \in \mathbb{R}^{N \times N}$ 。因此，根据权重矩阵 $\tilde{\Pi}_t$ 得到各节点初始信息状态向量和信息矩阵

$$\begin{cases} Y_{t|t,0}^i = \sum_{j=1}^N \tilde{\pi}^{i,j} Y_{t|t}^j \\ \hat{Y}_{t|t,0}^i = \sum_{j=1}^N \tilde{\pi}^{i,j} \hat{Y}_{t|t}^j \end{cases}, i = 1, 2, \dots, N, \quad (3.48)$$

其中 $\tilde{\pi}^{i,j}$ 为 $\tilde{\Pi}_t$ 中第 i 行第 j 列的元素。

ii. 一致性迭代

定义 3:[15]当迭代次数 λ 趋近于 ∞ 时，如果每个节点的迭代信息对 $(\hat{Y}_{t|t,\lambda}^i, Y_{t|t,\lambda}^i)$ 满足

$$(\hat{Y}_{t|t}^*, Y_{t|t}^*) = \lim_{\lambda \rightarrow \infty} (\hat{Y}_{t|t,\lambda}^i, Y_{t|t,\lambda}^i) \quad (3.49)$$

那么称初始信息对 $(\hat{Y}_{t|t,0}^i, Y_{t|t,0}^i)$ 是加权平均一致的。

引理 1:[14]对于一个通信拓扑结构为 $G = \{V(G), E(G)\}$ 的传感器网络，如果一致性权重矩阵 Π 是原始的，那么那么初始信息对 $(\hat{Y}_{t|t,0}^i, Y_{t|t,0}^i)$ 是加权平均一致的，且一致

$$\begin{cases} \hat{Y}_{t|t}^* = \sum_{i=1}^N c^i \hat{Y}_{t|t,0}^i \\ Y_{t|t}^* = \sum_{i=1}^N c^i Y_{t|t,0}^i \end{cases}, \quad (3.50)$$

其中, $\lim_{\lambda \rightarrow \infty} \Pi^\lambda = \mathbf{1}\mathbf{c}^T$, $\mathbf{c} = [c^1, c^2, \dots, c^N]^T$ 。

因为在初始化的过程中已经将来自精度下降的本地滤波估计剔除, 因此在迭代过程中, 按照经典分布式一致性融合方法进行, 精度下降节点正常接收和发送融合结果。迭代方程[16][17]为

$$\begin{cases} Y_{t|t,\lambda}^i = \sum_{j=1}^N \pi^{i,j} Y_{t|t,\lambda-1}^j \\ \hat{y}_{t|t,\lambda}^i = \sum_{j=1}^N \pi^{i,j} \hat{y}_{t|t,\lambda-1}^j \end{cases}, i = 1, 2, \dots, N, \quad (3.51)$$

其中采用的一致性权重矩阵为 3.3.1 节定义的平均一致性矩阵 Π 。矩阵 Π 是原始的, 根据引理 1 可知 $(\hat{y}_{t|t}^*, Y_{t|t}^*)$ 可以由 $(\hat{y}_{t|t,0}^i, Y_{t|t,0}^i)$ 线性表示。在 L 次一致性迭代后得到各个节点的融合信息对 $(\hat{y}_{t|t,L}^i, Y_{t|t,L}^i)$, 则融合后的估计状态向量和误差协方差矩阵为

$$\begin{cases} P_{t|t}^i = (Y_{t|t,L}^i)^{-1} \\ \hat{x}_{t|t}^i = P_{t|t}^i \hat{y}_{t|t,L}^i \end{cases}. \quad (3.52)$$

3.3.4 稳定性分析

所提的基于 DBSCAN 的 DCIF 算法采用了改进的基于一致性的加权平均融合方法, 因此对于所提的基于 DBSCAN 的 DCIF 算法的稳定性分析除了要对于估计误差的有界性进行证明, 还要对于分布式加权平均融合的一致性进行证明。

1) 模型线性化

为了方便进行稳定性分析, 非线性化模型进行线性化处理[16][17], 为了进一步减小线性化带来的误差, 引入对角补偿矩阵 $\eta_{t-1}^i = \text{diag}([\eta_{t-1,1}^i, \eta_{t-1,2}^i, \dots, \eta_{t-1,n}^i])$ 和 $\mu_t^i = \text{diag}([\mu_{t,1}^i, \mu_{t,2}^i, \dots, \mu_{t,m}^i])$ 。线性化后的模型为

$$\begin{cases} x_t = \eta_{t-1}^i F_{t-1}^i x_{t-1} + w_{t-1}^i, i = 1, 2, \dots, N, \\ z_t^i = \gamma_t^i \mu_t^i H_t x_t + v_t^i \end{cases} \quad (3.53)$$

其中 F_{t-1}^i 和 H_t^i 分别为 $f_{t-1}(\cdot)$ 和 $h_t^i(\cdot)$ 的线性化矩阵,

$$F_{t-1}^i = \left. \frac{\partial f_{t-1}}{\partial x} \right|_{x=\hat{x}_{t-1|t-1}} = \left(Y_{t-1|t-1}^i P_{x_{t-1}, x_{t-1}}^i \right)^T, \quad (3.54)$$

$$H_t^i = \frac{\partial h_t^i}{x} \Bigg|_{x=\hat{x}_{t|t-1}^i} = \left(Y_{t|t-1}^i P_{xz,t|t-1}^i \right)^T, \quad (3.55)$$

其中 $P_{xz,t|t-1}^i$ 可以在 3.3.2 节的更新步中找到,

$$P_{xz,t|t-1}^i = \frac{\sum_{j=1}^{2n} (\hat{x}_{t-1|t-1}^i - x_{t-1|t-1}^{i,j}) (\hat{x}_{t|t-1}^i - x_{t|t-1}^{i,j})^T}{2n} \quad (3.56)$$

从[5]可以得到线性化后 $Y_{t|t}^i$, $Y_{t|t-1}^i$, $\hat{y}_{t|t}^i$ 和 $\hat{y}_{t|t-1}^i$ 之间的迭代方程为

$$\begin{cases} \hat{y}_{t|t}^i = \hat{y}_{t|t-1}^i + (\mu_t^i H_t^i)^T (R_t^i)^{-1} z_t^i \\ Y_{t|t}^i = Y_{t|t-1}^i + (\mu_t^i H_t^i)^T (R_t^i)^{-1} (\mu_t^i H_t^i) \\ \hat{y}_{t|t-1}^i = (\eta_{t-1}^i F_{t-1}^i)^{-T} \left[I_n - Y_{t-1|t-1}^i \left(Y_{t-1|t-1}^i + (\eta_{t-1}^i F_{t-1}^i)^T Q_{t-1}^{-1} \eta_{t-1}^i F_{t-1}^i \right)^{-1} \right] \hat{y}_{t-1|t-1}^i \\ Y_{t|t-1}^i = (\eta_{t-1}^i F_{t-1}^i)^{-T} \left[I_n - Y_{t-1|t-1}^i \left(Y_{t-1|t-1}^i + (\eta_{t-1}^i F_{t-1}^i)^T Q_{t-1}^{-1} \eta_{t-1}^i F_{t-1}^i \right)^{-1} \right] \times Y_{t-1|t-1}^i (\eta_{t-1}^i F_{t-1}^i)^{-1} \end{cases} \quad (3.57)$$

从(3.57)可以看出 $Y_{t-1|t-1}^i$ 和 $Y_{t|t-1}^i$ 之间存在函数关系

$$\begin{aligned} Y_{t|t-1}^i &= \Xi(Y_{t-1|t-1}^i) \\ &= (\eta_{t-1}^i F_{t-1}^i)^{-T} \left[I_n - Y_{t-1|t-1}^i \left(Y_{t-1|t-1}^i + (\eta_{t-1}^i F_{t-1}^i)^T Q_{t-1}^{-1} \eta_{t-1}^i F_{t-1}^i \right)^{-1} \right] \times (\eta_{t-1}^i F_{t-1}^i)^{-1} \end{aligned} \quad (3.58)$$

由[5]可知 $Y_{t|t-1}^i = \Xi(Y_{t-1|t-1}^i)$ 是单调不减函数。

2) 估计一致性分析

定义 4: [18]对于任意一个向量 x , 其估计向量为 \hat{x} , 误差协方差矩阵为 P , 如果 (\hat{x}, P) 满足 $P \geq E\{(x - \hat{x})(x - \hat{x})^T\}$, 那么估计对 (\hat{x}, P) 是一致的。其对偶形式, 对于任意一个信息向量 y , 如果其估计信息对为 (\hat{y}, Y) 且满足 $Y \leq E^{-1}\{(x - Y^{-1}\hat{y})(x - Y^{-1}\hat{y})^T\}$, 那么估计信息对 (\hat{y}, Y) 是一致的。

定理 1: 考虑(3.53)表示的线性化模型, 如果状态向量 x_1 的先验估计对 $(\hat{x}_{1|0}^i, P_{1|0}^i)$ 满足

$$P_{1|0}^i \geq E\{(x_1 - \hat{x}_{1|0}^i)(x_1 - \hat{x}_{1|0}^i)^T\}, \quad (3.59)$$

那么对于任意的 $t > 0$, 通过基于 DBSCAN 的 DCIF 算法得到的估计对 $(\hat{x}_{t|t-1}^i, P_{t|t-1}^i)$

和 $(\hat{x}_{t|t}^i, P_{t|t}^i)$ 均满足

$$\begin{cases} P_{t|t-1}^i \geq E \left\{ (x_t - \hat{x}_{t|t-1}^i) (x_t - \hat{x}_{t|t-1}^i)^T \right\}, \\ P_{t|t}^i \geq E \left\{ (x_t - \hat{x}_{t|t}^i) (x_t - \hat{x}_{t|t}^i)^T \right\} \end{cases}, \quad (3.60)$$

即估计对 $(\hat{x}_{t|t-1}^i, P_{t|t-1}^i)$ 和 $(\hat{x}_{t|t}^i, P_{t|t}^i)$ 是一致的。

证明：假设 $t > 0$ 的先验估计对 $(\hat{x}_{t|t-1}^i, P_{t|t-1}^i)$ 是一致的，即

$$P_{t|t-1}^i \geq E \left\{ (x_t - \hat{x}_{t|t-1}^i) (x_t - \hat{x}_{t|t-1}^i)^T \right\}. \quad (3.61)$$

定义 $\hat{P}_{t-1|t-1}^i = E \left\{ (x_{t-1} - \hat{x}_{t-1|t-1}^i) (x_{t-1} - \hat{x}_{t-1|t-1}^i)^T \right\}$, $\hat{P}_{t|t-1}^i = E \left\{ (x_t - \hat{x}_{t|t-1}^i) (x_t - \hat{x}_{t|t-1}^i)^T \right\}$ 。先验

估计对 $(\hat{x}_{t|t-1}^i, P_{t|t-1}^i)$ 经过更新步后可以得到后验估计对 $(\hat{x}_{t|t}^i, P_{t|t}^i)$ ，其中

$$\hat{x}_{t|t}^i = \hat{x}_{t|t-1}^i + K_t^i (z_t^i - \hat{z}_{t|t-1}^i), \quad K_t^i = P_{xz,t|t-1}^i (P_{zz,t|t-1}^i)^{-1}。那么$$

$$\begin{aligned} \hat{P}_{t|t}^i &= E \left\{ (x_t - \hat{x}_{t|t}^i) (x_t - \hat{x}_{t|t}^i)^T \right\} \\ &= E \left\{ (x_t - \hat{x}_{t|t-1}^i - K_t^i (z_t^i - \hat{z}_{t|t-1}^i)) (x_t - \hat{x}_{t|t-1}^i - K_t^i (z_t^i - \hat{z}_{t|t-1}^i))^T \right\}. \end{aligned} \quad (3.62)$$

根据(3.53)可知， $z_t^i = \gamma_t^i \mu_t^i H_t^i x_t + v_t^i$, $\hat{z}_{t|t-1}^i = \gamma_t^i \mu_t^i H_t^i \hat{x}_{t|t-1}^i$ 。那么(3.62)可以写为

$$\begin{aligned} \hat{P}_{t|t}^i &= E \left\{ (x_t - \hat{x}_{t|t-1}^i - K_t^i (\gamma_t^i \mu_t^i H_t^i x_t + v_t^i - \gamma_t^i \mu_t^i H_t^i \hat{x}_{t|t-1}^i)) \right. \\ &\quad \left. (x_t - \hat{x}_{t|t-1}^i - K_t^i (\gamma_t^i \mu_t^i H_t^i x_t + v_t^i - \gamma_t^i \mu_t^i H_t^i \hat{x}_{t|t-1}^i))^T \right\} \\ &= E \left\{ \left[(I_n - \gamma_t^i K_t^i \mu_t^i H_t^i) (x_t - \hat{x}_{t|t-1}^i) - K_t^i v_t^i \right] \left[(I_n - \gamma_t^i K_t^i \mu_t^i H_t^i) (x_t - \hat{x}_{t|t-1}^i) - K_t^i v_t^i \right]^T \right\} (3.63) \\ &= (I_n - \gamma_t^i K_t^i \mu_t^i H_t^i) \hat{P}_{t|t-1}^i (I_n - \gamma_t^i K_t^i \mu_t^i H_t^i)^T + K_t^i R_t^i (K_t^i)^T \\ &\leq P_{t|t}^i \end{aligned}$$

3)

将(3.63)求逆，可以得到 $Y_{t|t}^i \leq E^{-1} \left\{ (x_t - (Y_{t|t}^i)^{-1} \hat{y}_{t|t}^i) (x_t - (Y_{t|t}^i)^{-1} \hat{y}_{t|t}^i)^T \right\}$ 。在改进的基

于一致性的加权平均融合方法的初始化步中，

$$\begin{cases} Y_{t|t,0}^i = \sum_{j=1}^N \tilde{\pi}^{i,j} Y_{t|t}^j \\ \hat{y}_{t|t,0}^i = \sum_{j=1}^N \tilde{\pi}^{i,j} \hat{y}_{t|t}^j \end{cases} \quad (3.64)$$

需要证明初始融合信息对 $(\hat{y}_{t|t,0}^i, Y_{t|t,0}^i)$ 是一致的，即证明

$$(Y_{t|t,0}^i)^{-1} = P_{t|t,0}^i \geq E \left\{ \left(x_t - (Y_{t|t,0}^i)^{-1} \hat{y}_{t|t,0}^i \right) \left(x_t - (Y_{t|t,0}^i)^{-1} \hat{y}_{t|t,0}^i \right)^T \right\} = \hat{P}_{t|t,0}^i \text{ 成立。由(3.64)可得}$$

$$(P_{t|t,0}^i)^{-1} \hat{x}_{t|t,0}^i = \sum_{j=1}^N \tilde{\pi}^{i,j} (P_{t|t}^j)^{-1} \hat{x}_{t|t}^j, \quad (3.65)$$

$$(P_{t|t,0}^i)^{-1} = \sum_{j=1}^N \tilde{\pi}^{i,j} (P_{t|t}^j)^{-1}. \quad (3.66)$$

根据(3.64)、(3.65)和(3.66)可得

$$\begin{aligned} \hat{P}_{t|t,0}^i &= E \left\{ \left(x_t - (Y_{t|t,0}^i)^{-1} \hat{y}_{t|t,0}^i \right) \left(x_t - (Y_{t|t,0}^i)^{-1} \hat{y}_{t|t,0}^i \right)^T \right\} \\ &= E \left\{ \left(x_t - (P_{t|t,0}^i)^{-1} \sum_{j=1}^N \tilde{\pi}^{i,j} (P_{t|t}^j)^{-1} \hat{x}_{t|t}^j \right) \left(x_t - (P_{t|t,0}^i)^{-1} \sum_{j=1}^N \tilde{\pi}^{i,j} (P_{t|t}^j)^{-1} \hat{x}_{t|t}^j \right)^T \right\} \\ &= P_{t|t,0}^i \left[\sum_{j=1}^N \sum_{k=1}^N \tilde{\pi}^{i,j} \tilde{\pi}^{i,k} (P_{t|t}^j)^{-1} \hat{P}_{t|t}^{j,k} (P_{t|t}^k)^{-1} \right] P_{t|t,0}^i \end{aligned} \quad (3.67)$$

因为 $P_{t|t}^j \geq \hat{P}_{t|t}^j$, 则 $(P_{t|t}^j)^{-1} \geq (\hat{P}_{t|t}^j)^{-1}$, 由(3.66)可以得到

$$(P_{t|t,0}^i)^{-1} = \sum_{j=1}^N \tilde{\pi}^{i,j} (P_{t|t}^j)^{-1} \geq \sum_{j=1}^N \tilde{\pi}^{i,j} (P_{t|t}^j)^{-1} \hat{P}_{t|t}^j (P_{t|t}^j)^{-1}. \quad (3.68)$$

而

$$\begin{aligned} &(P_{t|t,0}^i)^{-1} - (P_{t|t,0}^i)^{-1} \hat{P}_{t|t,0}^i (P_{t|t,0}^i)^{-1} \\ &\geq \sum_{j=1}^N \tilde{\pi}^{i,j} (P_{t|t}^j)^{-1} \hat{P}_{t|t}^j (P_{t|t}^j)^{-1} - \sum_{j=1}^N \sum_{k=1}^N \tilde{\pi}^{i,j} \tilde{\pi}^{i,k} (P_{t|t}^j)^{-1} \hat{P}_{t|t}^{j,k} (P_{t|t}^k)^{-1} \\ &= \sum_{j=1}^N \sum_{\substack{k=1, k \neq j}}^N \tilde{\pi}^{i,j} \tilde{\pi}^{i,k} \left[(P_{t|t}^j)^{-1} \hat{P}_{t|t}^j (P_{t|t}^j)^{-1} - (P_{t|t}^j)^{-1} \hat{P}_{t|t}^{j,k} (P_{t|t}^k)^{-1} \right] \\ &= \frac{\sum_{j=1}^N \sum_{\substack{k=1, k \neq j}}^N \tilde{\pi}^{i,j} \tilde{\pi}^{i,k}}{2} E \left\{ \left((P_{t|t}^j)^{-1} (x_t - \hat{x}_{t|t}^j) - (P_{t|t}^k)^{-1} (x_t - \hat{x}_{t|t}^k) \right)^T \right. \\ &\quad \left. \left((P_{t|t}^j)^{-1} (x_t - \hat{x}_{t|t}^j) - (P_{t|t}^k)^{-1} (x_t - \hat{x}_{t|t}^k) \right) \right\} \\ &\geq 0 \end{aligned} \quad (3.69)$$

成立, 即 $(P_{t|t,0}^i)^{-1} \geq (P_{t|t,0}^i)^{-1} \hat{P}_{t|t,0}^i (P_{t|t,0}^i)^{-1}$ 成立, 不等式左右两端均乘 $P_{t|t,0}^i$ 可以得到

$$P_{t|t,0}^i \geq P_{t|t,0}^i \left[\sum_{j=1}^N \sum_{k=1}^N \tilde{\pi}^{i,j} \tilde{\pi}^{i,k} \left(P_{t|t}^j \right)^{-1} \hat{P}_{t|t}^{j,k} \left(P_{t|t}^k \right)^{-1} \right] P_{t|t,0}^i = \hat{P}_{t|t,0}^i, \quad \text{即 初 始 融 合 信 息 对}$$

$(\hat{y}_{t|t,0}^i, Y_{t|t,0}^i)$ 是一致的。在改进的基于一致性的加权平均融合方法的迭代融合中，与初始步不同的仅仅是一致性权重矩阵发生了变化，分析过程与上面相似，可以证明 $(\hat{y}_{t|t,\lambda}^i, Y_{t|t,\lambda}^i), \lambda = 1, 2, \dots, L$ 是一致的。 $(\hat{y}_{t|t}^i, Y_{t|t}^i) = (\hat{y}_{t|t,L}^i, Y_{t|t,L}^i)$ ，因此 $(\hat{y}_{t|t}^i, Y_{t|t}^i)$ 也是一致的。

因 为 $Y_{t+1|t}^i = \Xi(Y_{t|t}^i)$ ， $Y_{t|t}^i \leq \hat{Y}_{t|t}^i$ 且 函 数 $\Xi(\cdot)$ 单 调 不 减，则 $Y_{t+1|t}^i = \Xi(Y_{t|t}^i) \leq \Xi(\hat{Y}_{t|t}^i) = \hat{Y}_{t+1|t}^i$ ，即 $P_{t+1|t}^i \geq \hat{P}_{t+1|t}^i$ ，定理证明结束。对于基于 DBSCAN 的 DCIF 算法进行分布式加权平均融合的一致性证明时，除了对于 CIF 的先验估计对和后验估计对的一致性进行了证明，还对于分布式融合过程的初始及迭代估计对的一致性进行了证明。形成了基于 DBSCAN 的 DCIF 算法估计对一致性证明的闭环。

3) 估计误差有界性分析

在进行误差有界性分析之前首先引入 1 个必要的假设和 2 个重要的引理。

假设 1：考虑如(3.53)所示的线性系统，对于任意的 $t > 0$ ，存在非 0 实数 η_{min}, η_{max} ，

$\mu_{min}, \mu_{max}, f_{min}, f_{max}, h_{min}, h_{max}, q_{min}, q_{max}, r_{min}, r_{max}, s_{min}, s_{max}$ 使得

$$\begin{aligned} \eta_{min}^2 I_n &\leq \eta_t^i (\eta_t^i)^T \leq \eta_{max}^2 I_n, \\ \mu_{min}^2 I_r &\leq \mu_t^i (\mu_t^i)^T \leq \mu_{max}^2 I_r, \\ f_{min}^2 I_n &\leq F_t^i (F_t^i)^T \leq f_{max}^2 I_n, \\ h_{min}^2 I_r &\leq H_t^i (H_t^i)^T \leq h_{max}^2 I_r, \\ q_{min} I_n &\leq Q_t \leq q_{max} I_n, \\ r_{min} I_r &\leq R_t^i \leq r_{max} I_r, \\ s_{min} I_n &\leq Y_{t|t}^i \leq s_{max} I_n \end{aligned} \tag{3.70}$$

成立。

引理 2：考虑任意大于 1 的正整数 M ，对于正定矩阵 X_1, X_2, \dots, X_M 和向量 d_1, d_2, \dots, d_M

$$(\sum_{i=1}^M X_i d_i)^T (\sum_{i=1}^M X_i)^{-1} (\sum_{i=1}^M X_i d_i) \leq \sum_{i=1}^M (d_i)^T X_i d_i \tag{3.71}$$

成立。

引理 3: 对于一个随机过程 ζ_t , 如果存在随机函数 $V(\zeta_t)$, 标量 α_{\min} , α_{\max} , $\beta > 0$ 和 $0 < \tau < 1$ 使得

$$\begin{aligned} \alpha_{\min} \|\zeta_t\|^2 &\leq V(\zeta_t) \leq \alpha_{\max} \|\zeta_t\|^2 \\ E\{V(\zeta_t)|\zeta_{t-1}\} - V(\zeta_{t-1}) &\leq \beta - \tau V(\zeta_{t-1}) \end{aligned} \quad (3.72)$$

对任意 $t > 0$ 均成立, 那么 ζ_t 是均方指数有界的, 即

$$E\{\|\zeta_t\|^2\} \leq \frac{\alpha_{\max}}{\alpha_{\min}} E\{\|\zeta_0\|^2\} (1-\tau)^t + \frac{\beta}{\alpha_{\min}} \sum_{i=1}^{t-1} (1-\tau)^i. \quad (3.73)$$

定理 2: 考虑满足假设 1 的线性系统

$$\begin{cases} x_t = \eta_{t-1}^i F_{t-1}^i x_{t-1} + w_{t-1}, \\ z_t^i = \gamma_t^i \mu_t^i H_t^i x_t + v_t^i, \end{cases} i = 1, 2, \dots, N, \quad (3.74)$$

对于任意的 $t > 0$, 基于 DBSCAN 的 DCIF 算法得到的状态估计误差 $\tilde{x}_{t|t}$ 是均方指
数有界的。

证明: 定义节点 i 的状态估计误差为 $\tilde{x}_{t|t}^i = x_t - \hat{x}_{t|t}^i$, 而 $\tilde{x}_{t|t} = \text{col}(\tilde{x}_{t|t}^i), i = 1, 2, \dots, N$ 。

假设 $\mathbf{P} = [p_1, p_2, \dots, p_N]^T$ 是一致性权重矩阵 Π 的左特征向量, 即 $\mathbf{P}^T \Pi = \mathbf{P}^T$ 。定义

$$p_{\max} = \max\{p_1, p_2, \dots, p_N\}, \quad p_{\min} = \min\{p_1, p_2, \dots, p_N\}.$$

构建函数

$$V(\tilde{x}_{t|t-1}) = \sum_{i=1}^N p_i (\tilde{x}_{t|t-1}^i)^T Y_{t|t-1}^i \tilde{x}_{t|t-1}^i. \quad (3.75)$$

由 $Y_{t|t-1}^i = (P_{t|t-1}^i)^{-1} = \left[\eta_{t-1}^i F_{t-1}^i (Y_{t-1|t-1}^i)^{-1} (\eta_{t-1}^i F_{t-1}^i)^T + Q_{t-1} \right]^{-1}$ 和假设 1 可以得到 $Y_{t|t-1}^i$

的上下界为

$$\left(\frac{\eta_{\max}^2 f_{\max}^2}{S_{\min}} + q_{\max} \right)^{-1} I_n \leq Y_{t|t-1}^i \leq \left(\frac{\eta_{\min}^2 f_{\min}^2}{S_{\max}} + q_{\min} \right)^{-1} I_n. \quad (3.76)$$

由(3.75)和(3.76)进一步得到 $V(\tilde{x}_{t|t-1})$ 的上下界为

$$p_{\min} \left(\frac{\eta_{\max}^2 f_{\max}^2}{S_{\min}} + q_{\max} \right)^{-1} \|\tilde{x}_{t|t-1}\|^2 \leq V(\tilde{x}_{t|t-1}) \leq p_{\max} \left(\frac{\eta_{\min}^2 f_{\min}^2}{S_{\max}} + q_{\min} \right)^{-1} \|\tilde{x}_{t|t-1}\|^2. \quad (3.77)$$

对于线性系统(3.53), 由引理 1 可知, 节点 i 的状态估计误差为

$$\begin{aligned}
 & \tilde{x}_{t-1|t-1}^i \\
 &= x_{t-1} - \hat{x}_{t-1|t-1}^i \\
 &= \left(Y_{t-1|t-1}^i \right)^{-1} \left(Y_{t-1|t-1}^i x_{t-1} - \hat{y}_{t-1|t-1}^i \right) \\
 &= \left(Y_{t-1|t-1}^i \right)^{-1} \left[\sum_{j=1}^N c^j Y_{t-1|t-1,0}^j x_{t-1} - \sum_{j=1}^N c^j \hat{y}_{t-1|t-1,0}^j \right] \\
 &= \left(Y_{t-1|t-1}^i \right)^{-1} \left[\sum_{j=1}^N c^j \sum_{k=1}^N \tilde{\pi}^{j,k} \left(Y_{t-1|t-2}^k + I_{t-1}^k \right) x_{t-1} - \sum_{j=1}^N c^j \sum_{k=1}^N \tilde{\pi}^{j,k} \left(\hat{y}_{t-1|t-2}^k + i_{t-1}^k \right) \right] \\
 &= \left(Y_{t-1|t-1}^i \right)^{-1} \left[\sum_{j=1}^N c^j \sum_{k=1}^N \tilde{\pi}^{j,k} \left(Y_{t-1|t-2}^k + \left(\gamma_{t-1}^k \mu_{t-1}^k H_{t-1}^k \right)^T \left(R_{t-1}^k \right)^{-1} \left(\gamma_{t-1}^k \mu_{t-1}^k H_{t-1}^k \right) \right) x_{t-1} \right. \\
 &\quad \left. - \sum_{j=1}^N c^j \sum_{k=1}^N \tilde{\pi}^{j,k} \left(\hat{y}_{t-1|t-2}^k + \left(\gamma_{t-1}^k \mu_{t-1}^k H_{t-1}^k \right)^T \left(R_{t-1}^k \right)^{-1} \left(\gamma_{t-1}^k \mu_{t-1}^k H_{t-1}^k x_{t-1} + v_{t-1}^k \right) \right) \right] \\
 &= \left(Y_{t-1|t-1}^i \right)^{-1} \left[\sum_{j=1}^N c^j \sum_{k=1}^N \tilde{\pi}^{j,k} Y_{t-1|t-2}^k \left(x_{t-1} - \hat{x}_{t-1|t-2}^k \right) - \left(\gamma_{t-1}^k \mu_{t-1}^k H_{t-1}^k \right)^T \left(R_{t-1}^k \right)^{-1} v_{t-1}^k \right], \quad (3.78)
 \end{aligned}$$

$$\begin{aligned}
 & \tilde{x}_{t|t-1}^i \\
 &= x_t - \hat{x}_{t|t-1}^i \\
 &= \eta_{t-1}^i F_{t-1}^i \left(x_{t-1} - \hat{x}_{t-1|t-1}^i \right) + w_{t-1} \\
 &= \eta_{t-1}^i F_{t-1}^i \left(Y_{t-1|t-1}^i \right)^{-1} \left[\sum_{j=1}^N c^j \sum_{k=1}^N \tilde{\pi}^{j,k} Y_{t-1|t-2}^k \left(x_{t-1} - \hat{x}_{t-1|t-2}^k \right) - \left(\gamma_{t-1}^k \mu_{t-1}^k H_{t-1}^k \right)^T \left(R_{t-1}^k \right)^{-1} v_{t-1}^k \right] + w_{t-1} \\
 &= \sum_{j=1}^N \sum_{k=1}^N c^j \tilde{\pi}^{j,k} \eta_{t-1}^i F_{t-1}^i \left(Y_{t-1|t-1}^i \right)^{-1} Y_{t-1|t-2}^k \tilde{x}_{t-1|t-2}^k \\
 &\quad - \sum_{j=1}^N \sum_{k=1}^N c^j \tilde{\pi}^{j,k} \eta_{t-1}^i F_{t-1}^i \left(Y_{t-1|t-1}^i \right)^{-1} \left(\gamma_{t-1}^k \mu_{t-1}^k H_{t-1}^k \right)^T \left(R_{t-1}^k \right)^{-1} v_{t-1}^k + w_{t-1} \\
 &= \sum_{j=1}^N \sum_{k=1}^N \Phi_{t-1,i}^{j,k} \tilde{x}_{t-1|t-2}^k - \sum_{j=1}^N \sum_{k=1}^N \Theta_{t-1,i}^{j,k} v_{t-1}^k + w_{t-1}
 \end{aligned} \quad (3.79)$$

其中

$$\begin{aligned}
 \Phi_{t-1,i}^{j,k} &= c^j \tilde{\pi}^{j,k} \eta_{t-1}^i F_{t-1}^i \left(Y_{t-1|t-1}^i \right)^{-1} Y_{t-1|t-2}^k \\
 \Theta_{t-1,i}^{j,k} &= c^j \tilde{\pi}^{j,k} \eta_{t-1}^i F_{t-1}^i \left(Y_{t-1|t-1}^i \right)^{-1} \left(\gamma_{t-1}^k \mu_{t-1}^k H_{t-1}^k \right)^T \left(R_{t-1}^k \right)^{-1}
 \end{aligned} \quad (3.80)$$

由(3.75)可得

$$\begin{aligned}
 & E\left\{V\left(\tilde{x}_{t|t-1}\right) \middle| \tilde{x}_{t-1|t-2}\right\} \\
 &= E\left\{\sum_{i=1}^N p_i\left(\tilde{x}_{t|t-1}^i\right)^T Y_{t|t-1}^i \tilde{x}_{t|t-1}^i \middle| \tilde{x}_{t-1|t-2}\right\}, \\
 &= \Psi_{t|t-1}^x + \Psi_{t|t-1}^v + \Psi_{t|t-1}^w
 \end{aligned} \tag{3.81}$$

其中

$$\Psi_{t|t-1}^x = E\left\{\sum_{i=1}^N p_i\left(\sum_{j=1}^N \sum_{k=1}^N \Phi_{t-1,i}^{j,k} \tilde{x}_{t-1|t-2}^k\right)^T Y_{t|t-1}^i \left(\sum_{j=1}^N \sum_{k=1}^N \Phi_{t-1,i}^{j,k} \tilde{x}_{t-1|t-2}^k\right) \middle| \tilde{x}_{t-1|t-2}\right\}, \tag{3.82}$$

$$\Psi_{t|t-1}^v = E\left\{\sum_{i=1}^N p_i\left(\sum_{j=1}^N \sum_{k=1}^N \Theta_{t-1,i}^{j,k} v_{t-1}^k\right)^T Y_{t|t-1}^i \left(\sum_{j=1}^N \sum_{k=1}^N \Theta_{t-1,i}^{j,k} v_{t-1}^k\right) \middle| \tilde{x}_{t-1|t-2}\right\}, \tag{3.83}$$

$$\Psi_{t|t-1}^w = E\left\{\sum_{i=1}^N p_i\left(w_{t-1}\right)^T Y_{t|t-1}^i w_{t-1} \middle| \tilde{x}_{t-1|t-2}\right\} \circ \tag{3.84}$$

根据

$$\begin{aligned}
 Y_{t|t-1}^i &= \left(P_{t|t-1}^i\right)^{-1} \\
 &= \left[\eta_{t-1}^i F_{t-1}^i \left(Y_{t-1|t-1}^i\right)^{-1} \left(\eta_{t-1}^i F_{t-1}^i\right)^T + Q_{t-1}\right]^{-1} \\
 &= \tau \left(\eta_{t-1}^i F_{t-1}^i\right)^{-T} Y_{t-1|t-1}^i \left(\eta_{t-1}^i F_{t-1}^i\right)^{-1}
 \end{aligned} \tag{3.85}$$

其中 $0 < \tau < 1$ 。由引理 1 可知，

$$\begin{aligned}
 Y_{t-1|t-1}^i &= \sum_{j=1}^N c^j Y_{t-1|t-1,0}^i \\
 &= \sum_{j=1}^N c^j \sum_{k=1}^N \tilde{\pi}^{j,k} Y_{t-1|t-1}^i \\
 &\geq \sum_{j=1}^N c^j \sum_{k=1}^N \tilde{\pi}^{j,k} Y_{t-1|t-2}^i
 \end{aligned} \tag{3.86}$$

成立，化简 $\Psi_{t|t-1}^x$ 为

$$\begin{aligned}
 & \Psi_{t|t-1}^x \\
 &= E \left\{ \sum_{i=1}^N p_i \left(\sum_{j=1}^N \sum_{k=1}^N \Phi_{t-1,j}^{j,k} \tilde{x}_{t-1|t-2}^k \right)^T Y_{t|t-1}^i \left(\sum_{j=1}^N \sum_{k=1}^N \Phi_{t-1,j}^{j,k} \tilde{x}_{t-1|t-2}^k \right) \middle| \tilde{x}_{t-1|t-2} \right\} \\
 &= E \left\{ \sum_{i=1}^N p_i \left(\sum_{j=1}^N \sum_{k=1}^N \Phi_{t-1,j}^{j,k} \tilde{x}_{t-1|t-2}^k \right)^T Y_{t|t-1}^i \left(\sum_{j=1}^N \sum_{k=1}^N \Phi_{t-1,j}^{j,k} \tilde{x}_{t-1|t-2}^k \right) \middle| \tilde{x}_{t-1|t-2} \right\} \\
 &\leq \tau E \left\{ \sum_{i=1}^N p_i \left(\sum_{j=1}^N \sum_{k=1}^N c^j \tilde{\pi}^{j,k} Y_{t-1|t-2}^k \tilde{x}_{t-1|t-2}^k \right)^T \left(\sum_{j=1}^N \sum_{k=1}^N c^j \tilde{\pi}^{j,k} Y_{t-1|t-2}^k \right)^{-1} \right. \\
 &\quad \left. \left(\sum_{j=1}^N \sum_{k=1}^N c^j \tilde{\pi}^{j,k} Y_{t-1|t-2}^k \tilde{x}_{t-1|t-2}^k \right) \middle| \tilde{x}_{t-1|t-2} \right\} \\
 &\leq \tau E \left\{ \sum_{i=1}^N p_i \left(\sum_{j=1}^N \sum_{k=1}^N c^j \tilde{\pi}^{j,k} (\tilde{x}_{t-1|t-2}^k)^T Y_{t-1|t-2}^k \tilde{x}_{t-1|t-2}^k \right) \middle| \tilde{x}_{t-1|t-2} \right\} \\
 &= \tau E \left\{ \sum_{i=1}^N p_i \left(\tilde{x}_{t-1|t-2}^i \right)^T Y_{t-1|t-2}^i \tilde{x}_{t-1|t-2}^i \middle| \tilde{x}_{t-1|t-2} \right\} \\
 &= \tau V(\tilde{x}_{t-1|t-2}) \quad . \quad (3.87)
 \end{aligned}$$

根据(3.83) (3.84)和假设 1 可知

$$\begin{aligned}
 & \Psi_{t|t-1}^v + \Psi_{t|t-1}^w \\
 &= E \left\{ \sum_{i=1}^N p_i \left(\sum_{j=1}^N \sum_{k=1}^N \Theta_{t-1,j}^{j,k} v_{t-1}^k \right)^T Y_{t|t-1}^i \left(\sum_{j=1}^N \sum_{k=1}^N \Theta_{t-1,j}^{j,k} v_{t-1}^k \right) \middle| \tilde{x}_{t-1|t-2} \right\} \\
 &\quad + E \left\{ \sum_{i=1}^N p_i (w_{t-1})^T Y_{t|t-1}^i w_{t-1} \middle| \tilde{x}_{t-1|t-2} \right\} \\
 &\leq \left(\frac{\eta_{\min}^2 f_{\min}^2}{S_{\max}} + q_{\min} \right)^{-1} E \left\{ \sum_{i=1}^N p_i \left(\sum_{j=1}^N \sum_{k=1}^N c^j \tilde{\pi}^{j,k} \eta_{t-1}^i F_{t-1}^i (Y_{t-1|t-1}^i)^{-1} (\gamma_{t-1}^k \mu_{t-1}^k H_{t-1}^k)^T (R_{t-1}^k)^{-1} v_{t-1}^k \right)^T \right. \\
 &\quad \left. \left(\sum_{j=1}^N \sum_{k=1}^N c^j \tilde{\pi}^{j,k} \eta_{t-1}^i F_{t-1}^i (Y_{t-1|t-1}^i)^{-1} (\gamma_{t-1}^k \mu_{t-1}^k H_{t-1}^k)^T (R_{t-1}^k)^{-1} v_{t-1}^k \right) \middle| \tilde{x}_{t-1|t-2} \right\} \\
 &\quad + E \left\{ \sum_{i=1}^N p_i (w_{t-1})^T w_{t-1} \middle| \tilde{x}_{t-1|t-2} \right\} \\
 &\leq \left(\frac{\eta_{\min}^2 f_{\min}^2}{S_{\max}} + q_{\min} \right)^{-1} \left(m r_{\min}^{-1} \eta_{\max}^2 f_{\max}^2 s_{\min}^{-2} \mu_{\max}^2 h_{\max}^2 \sum_{i=1}^N \sum_{j=1}^N \sum_{k=1}^N p_i (c^j \tilde{\pi}^{j,k})^2 + n q_{\max} \sum_{i=1}^N p_i \right) \\
 &= \beta \quad . \quad (3.88)
 \end{aligned}$$

由(3.81) (3.87)和(3.88)可知 $E\{V(\tilde{x}_{t|t-1})|\tilde{x}_{t-1|t-2}\} \leq \tau V(\tilde{x}_{t|t-1}) + \beta$, 根据引理 3 可知 $\tilde{x}_{t|t-1}$

是均方有界的。而 $\tilde{x}_{t|t-1} = \eta_{t-1}^i F_{t-1}^i \tilde{x}_{t-1|t-1} + w_{t-1}$ ，可知

$$E\{\|\tilde{x}_{t-1|t-1}\|^2\} \leq \eta_{\min}^{-1} f_{\min}^{-1} E\{\|\tilde{x}_{t|t-1}\|^2\} - E\{\|w_{t-1}\|^2\}, \text{ 定理得证。}$$

3.3.5 仿真

构建一个目标跟踪场景，使用分布式容积信息滤波算法与所提的基于DBSCAN的分布式容积信息滤波鲁棒目标跟踪算法进行对比，验证所提算法的有效性。仿真场景中有1个目标和9个传感器。9个传感器同时观察目标。

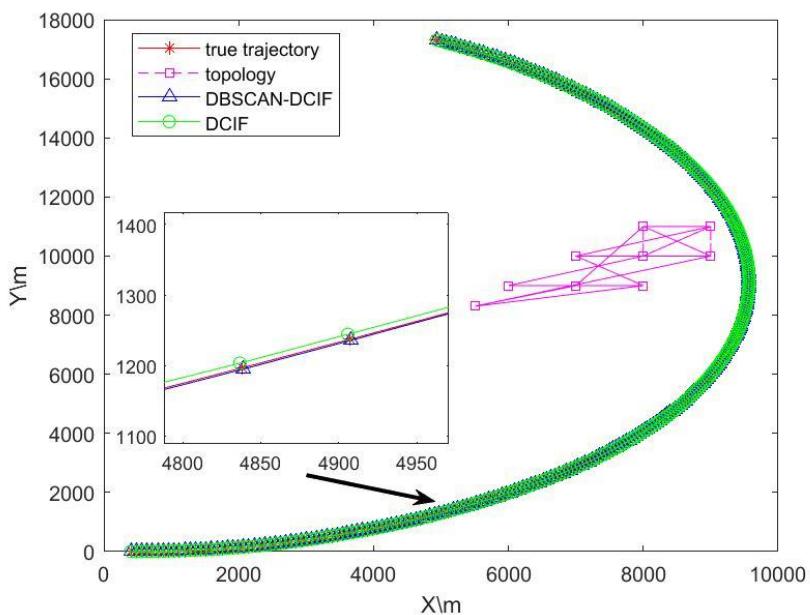


图 3.17 跟踪场景

目标运动做匀速转弯运动，运动模型为

$$\dot{x}_{t+1} = Fx_t + w_t,$$

$$F = \begin{bmatrix} 1 & \frac{\sin(\omega T)}{\omega} & 0 & \frac{\cos(\omega T) - 1}{\omega} \\ 0 & \cos(\omega T) & 0 & -\sin(\omega T) \\ 0 & \frac{1-\cos(\omega T)}{\omega} & 1 & \frac{\sin(\omega T)}{\omega} \\ 0 & \sin(\omega T) & 0 & \cos(\omega T) \end{bmatrix},$$

其中， $\omega = 0.5^\circ / s$ ，采样间隔时间为 $T = 1s$ ， w_t 服从均值为 0 的高斯分布 $\mathcal{N}(0; Q)$ ，方差矩阵为 $Q = \text{diag}([1m^2, 0.1rad^2 / s^2, 1m^2, 0.1rad^2 / s^2])$ 。目标的初始状态向量为

$$x_0 = [400, 80, 0.1, 0.1]^T。$$

第 i 个传感器的观测模型为

$$\begin{aligned} z_i &= \begin{bmatrix} \rho_i \\ \theta_i \end{bmatrix} + v_i, \\ \rho_i &= \sqrt{(x_o - x_b^i)^2 + (y_o - y_b^i)^2}, \\ \theta_i &= \arctan\left(\frac{y_o - y_b^i}{x_o - x_b^i}\right), \end{aligned}$$

其中, (x_o, y_o) 是目标的位置, (x_b^i, y_b^i) 是第 i 个传感器的位置, v_t^i 服从均值为 0 的高斯分布 $\mathcal{N}(\cdot; 0, R_i)$, 方差矩阵为 $R_i = \text{diag}([1m^2, 0.009rad^2])$ 。进行蒙特卡洛仿真实验 10 次。仿真实验总采样次数 300 次。DBSCAN 聚类的参数 $\varepsilon = 3m$, $MinPts = 3$ 。每个传感器在每个采样时刻均有 50% 的概率丢失观测值。传感器 1 和 5 会在仿真采样的部分时刻出现精度下降的情况, 精度下降开始时刻和结束时刻见表 8。

表 8: 精度下降开始和结束时刻

传感器	1	5
开始/s	20	50
结束/s	140	160

通过均方根误差 (RMSE) 来衡量算法的效果

$$RMSE = \left\{ \frac{1}{N} \sum_{i=1}^N [(x - \hat{x}^i)^2 + (y - \hat{y}^i)^2] \right\}^{\frac{1}{2}}。$$

表 9: 与单节点相比定位精度提升程度

算法	基于 DBSCAN 的分布式容积信息滤波鲁棒目标跟踪算法	分布式容积信息滤波
精度提升	79.73%	44.91%

单个节点的状态估计和所提出的基于 DBSCAN 的分布式容积信息滤波鲁棒目标跟踪算法得到的仿真结果如图 3.18 所示。图 3.19 和表 9 展示了该算法与不消除故障节点的分布式容积信息滤波算法的仿真结果。从图 3.18 可以看出，提出的基于 DBSCAN 的分布式容积信息滤波鲁棒目标跟踪算法不受单个故障传感器滤波结果的影响，保持了分布式融合算法的优势，可以减少目标跟踪误差。从图 3.19 可以看出，与单传感器滤波算法相比，由于采用了分布式一致性融合，正常传感器的滤波结果对故障传感器的滤波结果有修正作用，分布式容积信息滤波算法可以减少干扰的影响。然而，与所提出的基于 DBSCAN 的分布式容积信息滤波鲁棒目标跟踪算法相比，分布式容积信息滤波算法的跟踪误差更大。另外，随着故障传感器数量的增加，分布式容积信息滤波算法相比于基于 DBSCAN 的分布式容积信息滤波鲁棒目标跟踪算法的误差越大，如图 3.19 所示。当第一个故障传感器在 20 秒出现时，分布式容积信息滤波算法方法的误差开始大于所提出的基于 DBSCAN 的分布式容积信息滤波鲁棒目标跟踪算法的误差，但误差的差异不是很明显。在 50s 时出现第二个故障传感器，误差差距进一步扩大。此外，分布式容积信息滤波算法误差的变化趋势与故障传感器的滤波误差的变化趋势基本相同，这也表明分布式容积信息滤波算法方法受到故障传感器滤波结果的影响。

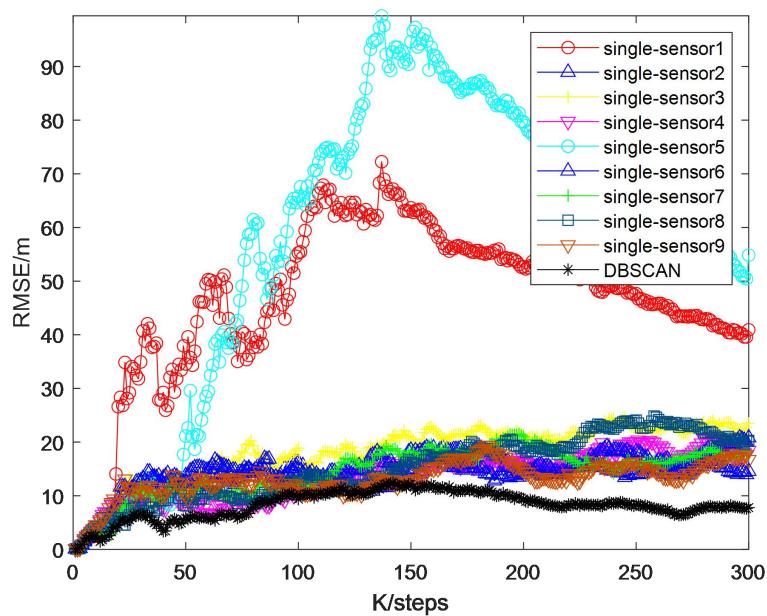


图 3.18 单个传感器和所提出的算法的 RMSE

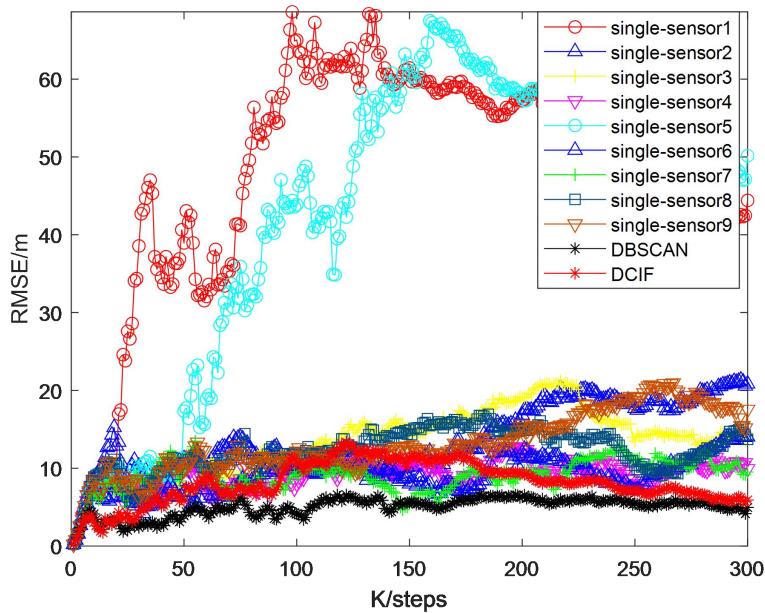


图 3.19 所提算法与分布式容积信息滤波方法的比较

结果表明，所提出的基于 DBSCAN 的分布式容积信息滤波鲁棒目标跟踪算法可以有效地降低故障传感器的影响，提高干扰环境下目标跟踪的精度。

3.3.6 总结

在存在部分传感器观测精度下降的情况下，提出了基于 DBSCAN 的 DCIF 算法。提出的基于 DBSCAN 的 DCIF 算法将 DBSCAN 密度聚类方法与 DCIF 算法相结合，能够对故障传感器进行判断和剔除。为了在分布式一致性迭代过程中保持 WSN 的通信拓扑结构，提出了 ICF 方法。在 ICF 方法的初始化步，使用初始融合权值矩阵剔除探测精度下降的传感器的本地状态估计结果。同时，精度下降节点的初始状态估计由正常探测精度的邻居提供，有效地提高了一致性融合的估计精度。所提出的基于 DBSCAN 的 DCIF 算法能够有效地判断并剔除探测精度下降的传感器，并且在存在干扰的情况下比 DCIF 算法的状态估计精度有明显的提高，在存在探测精度下降传感器的分布式目标跟踪中具有更强的鲁棒性。此部分由专利《基于 DBSCAN 的分布式容积信息滤波容错目标跟踪方法》支撑。

3.4 基于密度聚类的分布式多目标鲁棒跟踪方法研究

针对于分布式多目标跟踪过程中传感器网络中出现部分传感器探测精度下降的情况，提出了一种分布式多目标鲁棒跟踪（distributed multi-target tracking, DMTT）方法，提升目标跟踪的准确度。此分布式多目标鲁棒跟踪算法首先在每个传感器节点利用高斯混合概率假设密度算法[19]进行本地滤波得到由线性高斯组合表示的近似本地概率密度函数，然后利用 DBSCAN 聚类算法对于本地线性高斯组合中的高斯项进行聚类，判断出精度下降的传感器节点。最后采用改进的算数平均融合方法[20][21][22][23]将精度下降传感器节点的本地滤波剔除，并实现分布式融合。此改进的算数平均融合方法维持无线传感器网络的通信拓扑不变。对于改进的算数平均融合方法的保守性进行了证明。所提算法的有效性在数字仿真实验中进行展示。

3.4.1 问题描述

考虑一个非线性离散时间多目标跟踪系统

$$\begin{cases} \boldsymbol{x}_t^i = \theta_{t-1}^i(\boldsymbol{x}_{t-1}^i) + \boldsymbol{w}_{t-1}^i, i = 1, 2, \dots, N_t \\ \boldsymbol{z}_t^{i,j} = h_t^j(\boldsymbol{x}_t^i) + \boldsymbol{v}_t^j, j = 1, 2, \dots, N_s \end{cases}, \quad (3.89)$$

其中， \boldsymbol{x}_t^i 为第 i 个目标在采样时刻 t 的状态向量， $\theta_{t-1}^i(\cdot)$ 为第 i 个目标的状态转移函数， $\boldsymbol{z}_t^{i,j}$ 表示第 j 个传感器对第 i 个目标的观测向量， $h_t^j(\cdot)$ 表示第 j 个传感器的观测函数。 N_t 和 N_s 分别为目标个数和传感器个数。 \boldsymbol{w}_{t-1}^i 和 \boldsymbol{v}_t^j 分别表示第 i 个目标运动的不确定性和第 j 个传感器观测的不确定性，两者均服从均值为 0 的高斯分布，协方差为

$$\begin{cases} Q_{t-1}^i = E\left[\boldsymbol{w}_{t-1}^i(\boldsymbol{w}_{t-1}^i)^T\right] \\ R_t^j = E\left[\boldsymbol{v}_t^j(\boldsymbol{v}_t^j)^T\right] \end{cases}.$$

在多目标状态估计问题中，假设目标的状态服从状态空间 $\chi \in \mathbb{R}^n$ 中线性高斯转移密度为

$$f_{t|t-1}^i(x|\xi) = \mathcal{N}(x; F_{t-1}^i \xi, Q_{t-1}^i), i=1, 2, \dots, N_t \quad (3.90)$$

的马尔科夫过程[24], 其中 $F_{t-1}^i = \left. \frac{\partial \theta_{t-1}^i(\cdot)}{\partial x} \right|_{x=\xi}$ 为状态转移矩阵。对于采样时刻 $t-1$ 时的状态向量 x_{t-1} , 在下一个采样时刻 t 转移到状态 x_t 的概率为 $f_{t|t-1}^i(x_t|x_{t-1})$ 。此状态转移马尔科夫过程可以在观测空间 $\mathcal{Z} \in \mathbb{R}^m$ 中被观测到, 可以用线性高斯概率密度

$$g_t^j(z|x) = \mathcal{N}(z; H_t^j x, R_t^j), j=1, 2, \dots, N_s \quad (3.91)$$

来建模[24]。其中, $H_t^j = \left. \frac{\partial h_t^j(\cdot)}{\partial \xi} \right|_{\xi=x}$ 为传感器观测矩阵。对于状态 x_t , 得到观测 z_t 的概率密度为 $g_t^j(z_t|x_t)$ 。假设传感器 j 采样时刻 $1:t$ 的量测集合为 $z_{1:t}^j$, 那么在采样时刻 t 目标状态为 x_t 的概率密度为 $p_t^j(x_t|z_{1:t}^j)$ 。

假设采样时刻 t 的目标数目为 N_t , 目标状态为 $x_t^1, x_t^2, \dots, x_t^{N_t}$, 第 j 个传感器节点的观测个数为 M_t^j , 观测状态为 $z_t^1, z_t^2, \dots, z_t^{M_t^j}$ 。因为目标的状态和观测并没有特定的顺序, 因此可以自然的使用 RFS 理论来表示

$$\begin{cases} X_t = \{x_t^1, x_t^2, \dots, x_t^{N_t}\} \\ Z_t^j = \{z_t^1, z_t^2, \dots, z_t^{M_t^j}\}, j=1, 2, \dots, N_s \end{cases}, \quad (3.92)$$

其中, X_t 为采样时刻 t 的多目标状态 RFS, Z_t^j 表示采样时刻 t 第 j 个传感器的观测 RFS。在分布式多目标跟踪时, 伴随着新生目标的出现、现有目标的消亡和衍生目标的出现, 这些目标的状态均可以由 RFSs 来表示。假设采样时刻 $t-1$ 的多目标状态 RFS 为 X_{t-1} , 目标 $x_{t-1} \in X_{t-1}$ 以概率 $p_{s,t}(x_{t-1})$ 在采样时刻 t 存活, 以概率 $1-p_{s,t}(x_{t-1})$ 在采样时刻 t 消亡, $x_{t-1} \in X_{t-1}$ 在下一个采样时刻产生的 RFS 为 $S_{t|t-1}(x_{t-1})$, 如果此目标存活则 $S_{t|t-1}(x_{t-1})$ 为 $\{x_t\}$, 当目标消亡时为 \emptyset 。 $\bigcup_{x \in X_{t-1}} S_{t|t-1}(x)$ 表示从采样时刻 $t-1$ 到采样时刻 t 的存活目标 RFS, $\bigcup_{x \in X_{t-1}} B_{t|t-1}(x)$ 为衍生目标 RFS, Γ_t 表示新生目标 RFS。因此, 采样时刻 t 的目标状态 RFS 可以表示为

$$X_t = \left[\bigcup_{x \in X_{t-1}} S_{t|t-1}(x) \right] \cup \left[\bigcup_{x \in X_{t-1}} B_{t|t-1}(x) \right] \cup \Gamma_t. \quad (3.93)$$

WSN 中的传感器节点由于自身探测能力和探测位置的限制会出现目标漏检的情况，假设采样时刻 t 的多目标状态 RFS 为 X_t ，目标 $x_t \in X_t$ 以概率 $p_{D,t}(x_t)$ 在采样时刻 t 被传感器节点观测到，以 $1 - p_{D,t}(x_t)$ 的概率在采样时刻 t 被漏检，目标 $x_t \in X_t$ 产生的量测 RFS 为 $\vartheta_t(x_t)$ ，如果此目标被探测到那么 $\vartheta_t(x_t)$ 为 $\{z_t\}$ 而当目标漏检时为 \emptyset 。同时环境中杂波也会被传感器节点探测到，因此观测 RFS 也可以表示为

$$Z_t^j = C_t^j \cup \left[\bigcup_{x \in X_t} \vartheta_t^j(x) \right], \quad (3.94)$$

其中， C_t^j 表示采样时刻 t 第 j 个传感器的杂波观测 RFS， $\bigcup_{x \in X_t} \vartheta_t^j(x)$ 为该目标的观测 RFS。

根据图论的相关知识，使用 $G = \{V(G), E(G)\}$ 来描述 WSN 中传感器之间的通信关系。 $V(G) = \{v_1, v_2, \dots, v_N\}$ 代表 WSN 中传感器节点集合， $E(G) = \{(v_i, v_j), i \neq j, v_i, v_j \in V(G)\}$ 是边的集合。 $B_i = \{v_j, (v_j, v_i) \in E(G)\}$ 表示节点 v_i 的邻居节点集合，定义 T_i 为节点 v_i 及其邻居节点集合 B_i 组成的集合， $T_i = \{v_i\} \cup B_i$ 。假设 WSN 的通信拓扑为无向全联通网络，且一致性融合权重矩阵为 Metropolis 矩阵 $\Pi \in \mathbb{R}^{N \times N}$ ，设计方法如下

$$\pi^{i,j} = \begin{cases} \frac{1}{1 + \max\{|B_i|, |B_j|\}}, & i \neq j \\ 1 - \sum_{k \in B_i} \pi^{i,k}, & i = j \\ 0, & others \end{cases}, \quad (3.95)$$

其中 $\pi^{i,j}$ 为 Π 中第 i 行第 j 列的元素。

3.4.2 扩展高斯混合概率假设密度滤波器

为了得到概率假设密度滤波器的闭合形式的解，除了(3.90)- (3.91)表示的假设，还需要做出以下假设。

假设 2：目标的存活概率和探测概率与目标的状态无关，即

$$\begin{cases} P_{s,t}(x_t) = P_{s,t} \\ P_{D,t}(x_t) = P_{D,t} \end{cases} \circ \quad (3.96)$$

假设 3：为了简化多目标跟踪问题，此处并不考虑衍生目标，且存活目标以及新生目标的强度使用高斯混合近似为

$$\begin{cases} v_t(x) = \sum_{i=1}^{J_t} w_t^i \mathcal{N}(x; x_t^i, P_t^i) \\ b_t(x) = \sum_{i=1}^{J_{b,t}} w_{b,t}^i \mathcal{N}(x; x_{b,t}^i, P_{b,t}^i) \\ \beta_t(x) = 0 \end{cases} \quad (3.97)$$

基于以上假设和高斯混合概率假设密度算法[19]，假设采样时刻 $t-1$ 传感器 i 的多目标后验强度为

$$v_{t-1}^i = \sum_{j=1}^{J_{t-1}} w_{t-1}^{i,j} \mathcal{N}(x; x_{t-1}^{i,j}, P_{t-1}^{i,j}), i = 1, 2, \dots, N_s, \quad (3.98)$$

那么采样时刻 t 传感器 i 的本地先验多目标强度为

$$v_{t|t-1}^i(x) = v_{S,t|t-1}^i(x) + v_{b,t}^i(x), i = 1, 2, \dots, N_s, \quad (3.99)$$

其中

$$\begin{aligned} v_{S,t|t-1}^i(x) &= P_{s,t} \sum_{j=1}^{J_{t-1}} w_{t-1}^{i,j} \mathcal{N}(x; x_{S,t|t-1}^{i,j}, P_{S,t|t-1}^{i,j}), \\ v_{b,t}^i(x) &= \sum_{j=1}^{J_{b,t}} w_{b,t}^{i,j} \mathcal{N}(x; x_{b,t}^{i,j}, P_{b,t}^{i,j}), \\ x_{S,t|t-1}^{i,j} &= F_{t-1}^{i,j} x_{t-1}^{i,j}, \\ P_{S,t|t-1}^{i,j} &= F_{t-1}^{i,j} P_{t-1}^{i,j} (F_{t-1}^{i,j})^T + Q_{t-1}^i, \\ F_{t-1}^{i,j} &= \left. \frac{\partial \theta_{t-1}^i(\cdot)}{\partial x} \right|_{x=x_{t-1}^{i,j}}. \end{aligned}$$

由(3.99)和采样时刻 t 传感器 i 的观测随机有限集 Z_t^i 可以得到本地后验多目

标强度为

$$v_{t|t}^i(x) = (1 - P_{D,t}) v_{t|t-1}^i(x) + \sum_{z \in Z_t^i} \sum_{j=1}^{J_{t|t-1}^i} w_{t|t}^{i,j}(z) \mathcal{N}(x; x_{t|t}^{i,j}(z), P_{t|t}^{i,j}), i = 1, 2, \dots, N_s, \quad (3.100)$$

其中

$$\begin{aligned} w_{t|t}^{i,j}(z) &= \frac{P_{D,t} w_{t|t-1}^{i,j} q_t^{i,j}(z)}{\kappa_t + \sum_{k=1}^{J_{t|t-1}^i} P_{D,t} w_{t|t-1}^{i,k} q_t^{i,k}(z)}, \\ q_t^{i,j}(z) &= \mathcal{N}\left(z; H_t^{i,j} x_{t|t-1}^{i,j}, H_t^{i,j} P_{t|t-1}^{i,j} (H_t^{i,j})^T + R_t^i\right), \\ x_{t|t}^{i,j}(z) &= x_{t|t-1}^{i,j} + K_t^{i,j} (z - H_t^{i,j} x_{t|t-1}^{i,j}), \\ P_{t|t}^{i,j} &= P_{t|t-1}^{i,j} - K_t^{i,j} H_t^{i,j} P_{t|t-1}^{i,j}, \\ K_t^{i,j} &= P_{t|t-1}^{i,j} (H_t^{i,j})^T \left(H_t^{i,j} P_{t|t-1}^{i,j} (H_t^{i,j})^T + R_t^i \right)^{-1}, \\ H_t^{i,j} &= \left. \frac{\partial h_t^i(\cdot)}{\partial x} \right|_{x=x_{t|t-1}^{i,j}}. \end{aligned}$$

扩展高斯混合概率假设密度滤波器在高斯混合概率假设密度滤波器的基础上，将非线性多目标运动模型和传感器观测模型进行局部线性化处理，将高斯混合概率假设密度滤波器推广到非线性系统领域。相比于同样可以应用于非新型系统的贯序蒙特卡洛概率假设密度滤波器，扩展高斯混合概率假设密度滤波器原理简单，计算负担较小，且不需要进行重采样等操作。

3.4.3 核心 DBSCAN 聚类算法

由 3.4.2 节可以得到传感器经过本地滤波后得到的本地后验多目标强度是高斯混合的形式，即 $v_{t|t}^i = \sum_{j=1}^{J_{t|t}^i} w_{t|t}^{i,j} \mathcal{N}(x; x_{t|t}^{i,j}, P_{t|t}^{i,j})$, $i = 1, 2, \dots, N_s$ 。虽然目标以 $P_{D,t}$ 的概率被传感器探测到，但是对于拥有 N_s 个传感器节点的无线传感器网络来说，至少有两个节点探测到同一个目标的概率为 $1 - (1 - P_{D,t})^{N_s} - N_s P_{D,t} (1 - P_{D,t})^{N_s - 1}$ ，在实际的探测中 $P_{D,t}$ 不会很小，那么当 N_s 比较大时目标被至少两个传感器探测到的概率很大。而对于不同的传感器节点来说，探测到的杂波都是不同的，且经过本地滤波后，杂波观测对应的高斯成分的权重大大小于目标观测产生的高斯成分。首先

根据各传感器的本地后验多目标强度，提取其中权重不小于阈值的高斯成分的均值和协方差构成的状态对，很可能是目标对应的高斯成分，为后续挑选进行 DBSCAN 的状态对减小计算负担，可以表示为

$$y_t^i = \left\{ \left(x_{t|t}^{i,j}, P_{t|t}^{i,j} \right) \middle| \mathcal{N}(x; x_{t|t}^{i,j}, P_{t|t}^{i,j}) \in \mathcal{V}_{t|t}^i, w_{t|t}^{i,j} \geq \delta \right\}, i = 1, 2, \dots, N_s. \quad (3.101)$$

因为不同传感器得到的高斯成分的均值向量均属于目标的状态空间 $x \in \mathbb{R}^n$ ，在目标状态空间中来自不同传感器的属于同一目标的状态向量在空间中呈聚集状态，即属于同一目标的状态向量距离很近，对两个状态对 (x_1, P_1) 和 (x_2, P_2) 中的两个状态向量之间的距离定义为

$$d(x_1, x_2) = (x_1 - x_2)^T \tilde{P}_{1,2} (x_1 - x_2), \quad (3.102)$$

其中 $\tilde{P}_{1,2} = \frac{P_1 + P_2}{2}$ 。由前面的分析可知，目标状态的周围以很大的概率存在多个

来自不同传感器的估计状态，因此 $y_t^i, i = 1, 2, \dots, N_s$ 中对应各个目标的估计状态集合表示为

$$\Psi_t^u = \left\{ \left(i, x_{t|t}^{i,j}, P_{t|t}^{i,j} \right) \cup \psi_t^{i,j} \middle| \text{if } |\psi_t^{i,j}| \geq 2 \right\}, u = 1, 2, \dots, \bar{N}_t, \quad (3.103)$$

其中 $\psi_t^{i,j} = \left\{ \left(k, x_{t|t}^{k,l}, P_{t|t}^{k,l} \right) \middle| \text{if } \min(d(x_{t|t}^{i,j}, x_{t|t}^{k,l})) \leq \gamma, (x_{t|t}^{k,l}, P_{t|t}^{k,l}) \in y_t^k, k \neq i \right\}$ ， $|\cdot|$ 表示集合的元素个数， \bar{N}_t 为为目标的估计状态集合个数。每一个估计状态集合 Ψ_t^u 均可视为一个聚类样本点集，进行 DBSCAN 聚类。首先计算各个样本点的 ε -邻域

$$N_\varepsilon^{u,i}(x_{t|t}^{i,j}) = \left\{ \left(k, x_{t|t}^{k,l}, P_{t|t}^{k,l} \right) \middle| \text{if } d(x_{t|t}^{i,j}, x_{t|t}^{k,l}) < \varepsilon, (k, x_{t|t}^{k,l}, P_{t|t}^{k,l}), (i, x_{t|t}^{i,j}, P_{t|t}^{i,j}) \in \Psi_t^u \right\}, \quad (3.104)$$

其中 ε 为定义密度时的邻域半径。然后根据 ε -邻域从样本点集合中挑选核心物体，即

$$\Omega_u = \left\{ \left(i, x_{t|t}^{i,j}, P_{t|t}^{i,j} \right) \middle| \text{if } |N_\varepsilon^{u,i}(x_{t|t}^{i,j})| > MinPts, (i, x_{t|t}^{i,j}, P_{t|t}^{i,j}) \in \Psi_t^u \right\}, \quad (3.105)$$

其中 $MinPts$ 表示定义核心物体时的阈值，当一个采样点在其半径 ε 内含有的采样点数目的阈值，大于此值为核心物体。与传统的 DBSCAN 聚类方法不同的是，此处提出的核心 DBSCAN 聚类仅仅对于核心点进行聚类，具体步骤如下

$$\begin{aligned}
 \tilde{\Omega}_u &= \Omega_u, \\
 Q &= \left\{ \left(i, x_{t|t}^{i,j}, P_{t|t}^{i,j} \right) \right\}, \forall \left(i, x_{t|t}^{i,j}, P_{t|t}^{i,j} \right) \in \Omega_u, \\
 &\text{repeat} \\
 \Lambda &= \Omega_u \cap N_\varepsilon^{u,k} \left(x_{t|t}^{k,l} \right), \forall \left(k, x_{t|t}^{k,l}, P_{t|t}^{k,l} \right) \in Q, \\
 Q &= Q / \left(k, x_{t|t}^{k,l}, P_{t|t}^{k,l} \right), \\
 Q &= Q \cup \Lambda, \\
 \Omega_u &= \Omega_u / \Lambda, \\
 &\text{until } Q = \emptyset \\
 \Delta &= \tilde{\Omega}_u / \Omega_u, \\
 L_t^u &= \left\{ q \mid \left(q, x_{t|t}^{q,s}, P_{t|t}^{q,s} \right) \in \Delta \right\}.
 \end{aligned}$$

由于探测概率的影响，不是所有的传感器节点均可以观测到同一目标，因此估计状态集合 Ψ_t^u 中的状态对很难包含所有传感器。经过核心 DBSCAN 聚类后的聚类标签中也不会包含漏检的传感器，然而漏检传感器却有可能是正常传感器，因此此处认为漏检传感器也为正常传感器加入聚类标签集合

$$L_t^u = L_t^u \cup \left\{ a \mid \left(a, x_{t|t}^{a,j}, P_{t|t}^{a,j} \right) \in \mathcal{Y}_t^a, \forall \left(a, x_{t|t}^{a,k}, P_{t|t}^{a,k} \right) \notin \Psi_t^u \right\}, u = 1, 2, \dots, \bar{N}_t \quad . \quad (3.106)$$

各个目标估计状态集合经过核心 DBSCAN 聚类后得到的聚类标签集合 $L_t^u, u = 1, 2, \dots, \bar{N}_t$ 中存在漏检传感器，但是同一个传感器通过漏检进入 \bar{n} 个聚类标签集合的概率为 $(1 - P_{D,t})^{\bar{n}}$ ，而实际 MTT 场景中 $P_{D,t}$ 并不会很小，当 \bar{n} 的取值比较大时，传感器通过漏检进入 \bar{n} 个聚类标签集合的概率几乎为 0。从这个角度来看，如果一个传感器在不小于 \bar{n} 个聚类标签集合中出现，那么此传感器的本地估计多目标状态与真实目标状态差距较小，即此传感器为正常探测精度节点。从聚类标签集合 $L_t^u, u = 1, 2, \dots, \bar{N}_t$ 中确定正常探测精度的传感器的策略如下

$$\begin{aligned}
 \hat{N}_t^i &= \left\{ j \mid i \in L_t^j, j = 1, 2, \dots, \bar{N}_t \right\}, i = 1, 2, \dots, N_s, \\
 \bar{L}_t &= \left\{ i \mid \left| \hat{N}_t^i \right| \geq \bar{n}, i = 1, 2, \dots, N_s \right\}
 \end{aligned} \quad , \quad (3.107)$$

其中 \bar{L}_t 为采样时刻 t 的正常探测精度传感器标签集合。

3.4.4 改进的算数平均融合方法

通过核心 DBSCAN 聚类算法获得正常探测精度传感器标签集合 \bar{L}_t 后，需要融合正常探测精度传感器的本地后验强度。为了在不改变传感器通信拓扑的前提下，剔除探测精度下降传感器的本地后验强度，同时实现分布一致性，提出的改进的算数平均（improved arithmetic average, IAA）融合方法改进了算数平均（arithmetic average, AA）融合方法的初始步。在 IAA 融合方法的初始步，探测精度下降的传感器接收其探测精度正常邻居节点的本地后验强度，并在本地将其探测精度正常邻居节点的本地后验强度采用 AA 融合方法进行融合。同时，探测精度正常的传感器接收其探测精度正常邻居节点的本地后验强度，并在本地将其探测精度正常邻居节点的本地后验强度与此节点的本地后验强度采用 AA 融合方法进行融合。AA 融合后的多目标强度作为分布式融合的初始融合强度。IAA 融合方法的初始步可以不改变 WSN 的通信拓扑，只是需要对于融合权重矩阵进行修正。

首先根据正常探测精度传感器标签集合 \bar{L}_t 建立修正矩阵 $E_t \in \mathbb{R}^{N_s \times N_s}$ 为

$$E_t^{i,j} = \begin{cases} 1, & i = j, i \in \bar{L}_t \\ 0, & others \end{cases}, \quad (3.108)$$

其中 $E_t^{i,j}$ 为修正矩阵 E_t 第 i 行第 j 列的元素。使用修正矩阵 E_t 对建立的 Metropolis 矩阵 Π 进行修正

$$\tilde{\Pi}_t = \Pi \times E_t. \quad (3.109)$$

修正后的矩阵 $\tilde{\Pi}_t$ 的行和并不为 1，因此需要进行行归一化处理得到初始化权重矩阵 $\bar{\Pi}_t$

$$\bar{\Pi}_t^{i,j} = \frac{\tilde{\Pi}_t^{i,j}}{\sum_{k=1}^{N_s} \tilde{\Pi}_t^{i,k}}. \quad (3.110)$$

使用初始化权重矩阵 $\bar{\Pi}_t$ 获得各个传感器的初始融合强度为

$$v_{t,0}^i(x) = \sum_{j=1}^{N_s} \bar{\Pi}_t^{i,j} v_{t|t}^j(x), i = 1, 2, \dots, N_s. \quad (3.111)$$

初始化后各个节点的初始融合强度均与探测精度下降节点的本地后验强度无关，因此在一致性融合迭代时，定义的 Metropolis 矩阵 Π 作为一致性权重矩阵

$$v_{t,l+1}^i(x) = \sum_{j=1}^{N_s} \pi^{i,j} v_{t,l}^j(x), i = 1, 2, \dots, N_s. \quad (3.112)$$

同时在各个节点处进行高斯项的融合和剪枝只保留权重大于 λ 的高斯项进行下一次一致性融合迭代。假设 $v_{t,l+1}^i(x) = \sum_{j=1}^{J_{t,l+1}} \bar{w}_{t,l+1}^{i,j} \mathcal{N}(x; \bar{x}_{t,l+1}^{i,j}, P_{t,l+1}^{i,j})$, 那么融合和剪枝步为

$$\Phi_{t,l+1}^i = \left\{ \left(\bar{w}_{t,l+1}^{i,j}, \bar{x}_{t,l+1}^{i,j}, P_{t,l+1}^{i,j} \right) \middle| \bar{w}_{t,l+1}^{i,j} \mathcal{N}(x; \bar{x}_{t,l+1}^{i,j}, P_{t,l+1}^{i,j}) \in v_{t,l+1}^i(x) \right\},$$

$$s = 0,$$

Repeat

$$s = s + 1,$$

$$\Theta_{t,l+1}^{i,s} = \left\{ \left(\bar{w}_{t,l+1}^{i,k}, \bar{x}_{t,l+1}^{i,k}, P_{t,l+1}^{i,k} \right) \right\}, \max \bar{w}_{t,l+1}^{i,k}, \left(\bar{w}_{t,l+1}^{i,k}, \bar{x}_{t,l+1}^{i,k}, P_{t,l+1}^{i,k} \right) \in \Phi_{t,l+1}^i,$$

$$\Theta_{t,l+1}^{i,s} = \Theta_{t,l+1}^{i,s} \cup \left\{ \left(\bar{w}_{t,l+1}^{j,p}, \bar{x}_{t,l+1}^{j,p}, P_{t,l+1}^{j,p} \right) \middle| \text{if } d(\bar{x}_{t,l+1}^{i,k}, \bar{x}_{t,l+1}^{j,p}) < \beta, k \neq p \right\}$$

$$= \left\{ \left(\hat{w}_{t,l+1}^{i,1}, \hat{x}_{t,l+1}^{i,1}, \hat{P}_{t,l+1}^{i,1} \right) \right\} \cup \dots \cup \left\{ \left(\hat{w}_{t,l+1}^{i,|\Theta_{t,l+1}^{i,s}|}, \hat{x}_{t,l+1}^{i,|\Theta_{t,l+1}^{i,s}|}, \hat{P}_{t,l+1}^{i,|\Theta_{t,l+1}^{i,s}|} \right) \right\},$$

$$\Phi_{t,l+1}^i = \Phi_{t,l+1}^i / \Theta_{t,l+1}^{i,s},$$

$$c_{t,l+1}^{i,s}(x) = \begin{cases} \tilde{w}_{t,l+1}^{i,s} \mathcal{N}(x; \tilde{x}_{t,l+1}^{i,s}, \tilde{P}_{t,l+1}^{i,s}), & \text{if } \tilde{w}_{t,l+1}^{i,s} > \lambda \\ 0, & \text{others} \end{cases}$$

其中

$$\tilde{w}_{t,l+1}^{i,s} = \sum_{j=1}^{|\Theta_{t,l+1}^{i,s}|} \hat{w}_{t,l+1}^{i,j},$$

$$\tilde{x}_{t,l+1}^{i,s} = \frac{\sum_{j=1}^{|\Theta_{t,l+1}^{i,s}|} \hat{w}_{t,l+1}^{i,j} \hat{x}_{t,l+1}^{i,j}}{\sum_{j=1}^{|\Theta_{t,l+1}^{i,s}|} \hat{w}_{t,l+1}^{i,j}}, \quad (3.113)$$

$$\tilde{P}_{t,l+1}^{i,s} = \frac{\sum_{j=1}^{|\Theta_{t,l+1}^{i,s}|} \hat{w}_{t,l+1}^{i,j} \left[\hat{P}_{t,l+1}^{i,j} + (\hat{x}_{t,l+1}^{i,j} - \tilde{x}_{t,l+1}^{i,s})(\hat{x}_{t,l+1}^{i,j} - \tilde{x}_{t,l+1}^{i,s})^T \right]}{\sum_{j=1}^{|\Theta_{t,l+1}^{i,s}|} \hat{w}_{t,l+1}^{i,j}}, \quad (3.114)$$

Until $\Phi_{t,l+1}^i = \emptyset$

$$v_{t,l+1}^i(x) = \sum_{j=1}^s c_{t,l+1}^{i,j}(x). \quad (3.115)$$

这样就形成了一致性融合迭代的闭合形式。因为在一致性融合时节点只保留和传递了权重值较大的高斯成分，因此此处实现的为“部分一致性”，只对于很可能来自目标高斯成分进行融合和传递，减小了计算负担和通信负担。

3.4.5 一致性证明

由于在进行一致性融合的过程中引入了融合和剪枝步，因此需要证明算法的一致性。这就需要引入一致性的定义。

定义 5：考虑一个估计对 (\tilde{x}, P) ， \tilde{x} 是向量 x 的估计向量，那么估计对 (\tilde{x}, P) 被称为具有一致性，如果

$$P \geq E\left\{(\tilde{x} - \tilde{x})(\tilde{x} - \tilde{x})^T\right\} \quad (3.116)$$

成立。

定理 3：针对于(3.111)-(3.115)所组成的 IAA 融合算法，如果各传感器的本地后验

强度 $v_{t|t}^i = \sum_{j=1}^{J_{t|t}^i} w_{t|t}^{i,j} \mathcal{N}\left(x; x_{t|t}^{i,j}, P_{t|t}^{i,j}\right)$, $i = 1, 2, \dots, N_s$ 中的估计对 $(x_{t|t}^{i,j}, P_{t|t}^{i,j})$ 是具有一致性的，

那么一致性融合初始化和迭代的融合强度，

$v_{t,l}^i(x) = \sum_{j=1}^{J_{t,l}^i} \tilde{w}_{t,l}^{i,j} \mathcal{N}\left(x; \tilde{x}_{t,l}^{i,j}, \tilde{P}_{t,l}^{i,j}\right)$, $i = 1, 2, \dots, N_s, l = 0, 1, \dots$ 的估计对 $(\tilde{x}_{t,l}^{i,j}, \tilde{P}_{t,l}^{i,j})$ 也是具

有一致性的。

证明：由于各传感器的本地后验强度 $v_{t|t}^i = \sum_{j=1}^{J_{t|t}^i} w_{t|t}^{i,j} \mathcal{N}\left(x; x_{t|t}^{i,j}, P_{t|t}^{i,j}\right)$, $i = 1, 2, \dots, N_s$ 中的

估计对 $(x_{t|t}^{i,j}, P_{t|t}^{i,j})$ 是具有一致性的， $x_{t|t}^{i,j}$ 是 x_t 的估计向量，即

$P_{t|t}^{i,j} \geq E\left\{(x_t - x_{t|t}^{i,j})(x_t - x_{t|t}^{i,j})^T\right\}$ 成立。由(3.111)可知一致性融合初始化仅仅是对于

传感器的本地后验强度进行了线性加权，并没有改变估计对 $(x_{t|t}^{i,j}, P_{t|t}^{i,j})$ ，因此很

轻易的可以得到初始融合强度的估计对 $(\tilde{x}_{t,0}^{i,j}, \tilde{P}_{t,0}^{i,j})$ 是具有一致性的。

在一致性融合迭代时采用(3.113)-(3.115), 估计对发生了改变, 假设第 l 次迭代后的融合强度 $v_{t,l}^i(x) = \sum_{j=1}^{J_{t,l}} \tilde{w}_{t,l}^{i,j} \mathcal{N}(x; \tilde{x}_{t,l}^{i,j}, \tilde{P}_{t,l}^{i,j})$, $i = 1, 2, \dots, N_s$ 的估计对 $(\tilde{x}_{t,l}^{i,j}, \tilde{P}_{t,l}^{i,j})$ 是

具有一致性的, 即满足 $\tilde{P}_{t,l}^{i,j} \geq E\left\{\left(x_t - \tilde{x}_{t,l}^{i,j}\right)\left(x_t - \tilde{x}_{t,l}^{i,j}\right)^T\right\}$ 。假设 $v_{t,l+1}^i(x) = \sum_{j=1}^{J_{t,l+1}} \tilde{w}_{t,l+1}^{i,j} \mathcal{N}(x; \tilde{x}_{t,l+1}^{i,j}, \tilde{P}_{t,l+1}^{i,j})$, $i = 1, 2, \dots, N_s$ 中的高斯成分 $\tilde{w}_{t,l+1} \mathcal{N}(x; \tilde{x}_{t,l+1}, \tilde{P}_{t,l+1})$ 是由高斯成分 $\tilde{w}_{t,l}^1 \mathcal{N}(x; \tilde{x}_{t,l}^1, \tilde{P}_{t,l}^1), \dots, \tilde{w}_{t,l}^{N_m} \mathcal{N}(x; \tilde{x}_{t,l}^{N_m}, \tilde{P}_{t,l}^{N_m})$ 经过融合步得到的, 即

$$\begin{cases} \tilde{x}_{t,l+1} = \frac{\sum_{i=1}^{N_m} \tilde{w}_{t,l}^i \tilde{x}_{t,l}^i}{\sum_{i=1}^{N_m} \tilde{w}_{t,l}^i}, \\ \tilde{P}_{t,l+1} = \frac{\sum_{i=1}^{N_m} \tilde{w}_{t,l}^i \tilde{P}_{t,l}^i}{\sum_{i=1}^{N_m} \tilde{w}_{t,l}^i}, \end{cases} \quad (3.117)$$

其中 $\tilde{P}_{t,l}^i = \tilde{P}_{t,l}^i + (\tilde{x}_{t,l+1} - \tilde{x}_{t,l}^i)(\tilde{x}_{t,l+1} - \tilde{x}_{t,l}^i)^T$ 。由于高斯成分

$\tilde{w}_{t,l}^1 \mathcal{N}(x; \tilde{x}_{t,l}^1, \tilde{P}_{t,l}^1), \dots, \tilde{w}_{t,l}^{N_m} \mathcal{N}(x; \tilde{x}_{t,l}^{N_m}, \tilde{P}_{t,l}^{N_m})$ 来自于第 l 次迭代后的融合强度, 那么

$\tilde{P}_{t,l}^k \geq E\left\{\left(x_t - \tilde{x}_{t,l}^k\right)\left(x_t - \tilde{x}_{t,l}^k\right)^T\right\}, k = 1, 2, \dots, N_m$ 成立。融合后的高斯成分

$\tilde{w}_{t,l+1} \mathcal{N}(x; \tilde{x}_{t,l+1}, \tilde{P}_{t,l+1})$ 的估计误差协方差为

$$\begin{aligned} & E\left\{\left(x_t - \tilde{x}_{t,l+1}\right)\left(x_t - \tilde{x}_{t,l+1}\right)^T\right\} \\ &= E\left\{\left(x_t - \tilde{x}_{t,l}^k + \tilde{x}_{t,l}^k - \tilde{x}_{t,l+1}\right)\left(x_t - \tilde{x}_{t,l}^k + \tilde{x}_{t,l}^k - \tilde{x}_{t,l+1}\right)^T\right\} \\ &= E\left\{\left(x_t - \tilde{x}_{t,l}^k\right)\left(x_t - \tilde{x}_{t,l}^k\right)^T\right\} + E\left\{\left(x_t - \tilde{x}_{t,l}^k\right)\left(\tilde{x}_{t,l}^k - \tilde{x}_{t,l+1}\right)^T\right\} \\ & \quad + E\left\{\left(\tilde{x}_{t,l}^k - \tilde{x}_{t,l+1}\right)\left(x_t - \tilde{x}_{t,l}^k\right)^T\right\} + E\left\{\left(\tilde{x}_{t,l}^k - \tilde{x}_{t,l+1}\right)\left(\tilde{x}_{t,l}^k - \tilde{x}_{t,l+1}\right)^T\right\}. \quad (3.118) \\ &= E\left\{\left(x_t - \tilde{x}_{t,l}^k\right)\left(x_t - \tilde{x}_{t,l}^k\right)^T\right\} + \left(\tilde{x}_{t,l}^k - \tilde{x}_{t,l+1}\right)\left(\tilde{x}_{t,l}^k - \tilde{x}_{t,l+1}\right)^T \\ &\leq \tilde{P}_{t,l}^k + \left(\tilde{x}_{t,l}^k - \tilde{x}_{t,l+1}\right)\left(\tilde{x}_{t,l}^k - \tilde{x}_{t,l+1}\right)^T \\ &= \tilde{P}_{t,l}^k \end{aligned}$$

给(3.118)左右两侧乘以 $\tilde{w}_{t,l}^i, i = 1, 2, \dots, N_m$, 得到

$$\tilde{w}_{t,l}^i E \left\{ (x_t - \tilde{x}_{t,l+1}) (x_t - \tilde{x}_{t,l+1})^T \right\} \leq \tilde{w}_{t,l}^i \tilde{P}_{t,l}^i, i = 1, 2, \dots, N_m, \quad (3.119)$$

加和得到 $\sum_{i=1}^{N_m} \tilde{w}_{t,l}^i E \left\{ (x_t - \tilde{x}_{t,l+1}) (x_t - \tilde{x}_{t,l+1})^T \right\} \leq \sum_{i=1}^{N_m} \tilde{w}_{t,l}^i \tilde{P}_{t,l}^i$, 即

$$E \left\{ (x_t - \tilde{x}_{t,l+1}) (x_t - \tilde{x}_{t,l+1})^T \right\} \leq \frac{\sum_{i=1}^{N_m} \tilde{w}_{t,l}^i \tilde{P}_{t,l}^i}{\sum_{i=1}^{N_m} \tilde{w}_{t,l}^i} = \tilde{P}_{t,l+1}, \quad (3.120)$$

融合后的高斯成分的估计对 $(\tilde{x}_{t,l+1}, \tilde{P}_{t,l+1})$ 是具有一致性的, 定理得证。由定理 3 的证明可以得到(3.117)中估计对 $(\tilde{x}_{t,l+1}, \tilde{P}_{t,l+1})$ 中估计向量 $\tilde{x}_{t,l+1}$ 使用的融合权重与 $\tilde{P}_{t,l+1}$ 的融合权重并没有关系, 对于任意的 $\tilde{P}_{t,l+1}$ 的融合权重均有估计对 $(\tilde{x}_{t,l+1}, \tilde{P}_{t,l+1})$ 是具有一致性的结论。

3.4.6 仿真

本节构建了一个存在部分传感器探测精度下降的多目标跟踪仿真场景, 对于所提的基于 DBSCAN 的 DMTT 算法在部分传感器探测精度下降的多目标跟踪的有效性进行展示, 并与采用 AA 融合方法的分布式 GMPHD (AA-DGMPHD) 和几何平均 (geometric average, GA) 融合方法的分布式 GMPHD (GA-DGMPHD) 的跟踪结果做对比。

跟踪场景为一个 $[-1000m, 1000m] \times [-1000m, 1000m]$ 的二维平面如图 3.20 所示, 其中存在 6 个出现和消亡时刻不同的目标, 10 个分布式分布的传感器。目标的初始状态 $x_0 = [x_a, \dot{x}_a, y_a, \dot{y}_a]^T$ 和轨迹的开始结束时间分别如表 10 和表 11 所示。表 12 记录了 10 个传感器的位置 (x_s, y_s) , 传感器之间的通信拓扑为无向全联通网络, 传感器可以与其距离不超过 $2000m$ 的传感器进行通信, 如图 3.20 所示, 其中虚线即为传感器之间的通信拓扑。仿真总采样时长为 $100s$, 采样间隔为 $T = 1s$ 。目标的运动模型为匀速转弯的线性模型

$$x_t = \begin{bmatrix} 1 & \frac{\sin \omega T}{\omega} & 0 & \frac{\cos \omega T - 1}{\omega} \\ 0 & \cos \omega T & 0 & -\sin \omega T \\ 0 & \frac{1 - \cos \omega T}{\omega} & 1 & \frac{\sin \omega T}{\omega} \\ 0 & \sin \omega T & 0 & \cos \omega T \end{bmatrix} x_{t-1} + w_{t-1},$$

其中 $\omega = -0.02 s^{-1}$, $w_{t-1} \sim \mathcal{N}(\cdot; 0, Q)$, $Q = \text{diag}([4m^2, 0.2m^2/s^2, 4m^2, 0.2m^2/s^2])$ 。

表 10: 目标的初始状态

	1	2	3	4	5	6
x_a / m	-700	-800	-700	-500	-500	500
$\dot{x}_a / (m/s)$	13	4	5	3	13	3
y_a / m	-800	0	700	-100	200	-500
$\dot{y}_a / (m/s)$	3	10	-13	-15	5	13

表 11: 目标轨迹的开始结束时间

	1	2	3	4	5	6
T_{start} / s	1	1	61	51	41	26
T_{end} / s	25	50	100	100	80	75

传感器的观测模型为非线性模型

$$z_t = \begin{bmatrix} \sqrt{(x_a - x_s)^2 + (y_a - y_s)^2} \\ \arctan \frac{y_a - y_s}{x_a - x_s} \end{bmatrix} + v_t,$$

其中观测精度正常的传感器的 $v_t \sim \mathcal{N}(\cdot; 0, R_n)$, 探测精度下降的传感器的

$$v_t \sim \mathcal{N}(\cdot; 0, R_d), \quad R_n = \text{diag}([0.25m^2, 3 \times 10^{-6} rad^2/s^2]),$$

$R_d = \text{diag}([4m^2, 4.87 \times 10^{-5} rad^2/s^2])$ 。精度下降传感器的编号及其对应的精度下降的时刻如表 13 所示。

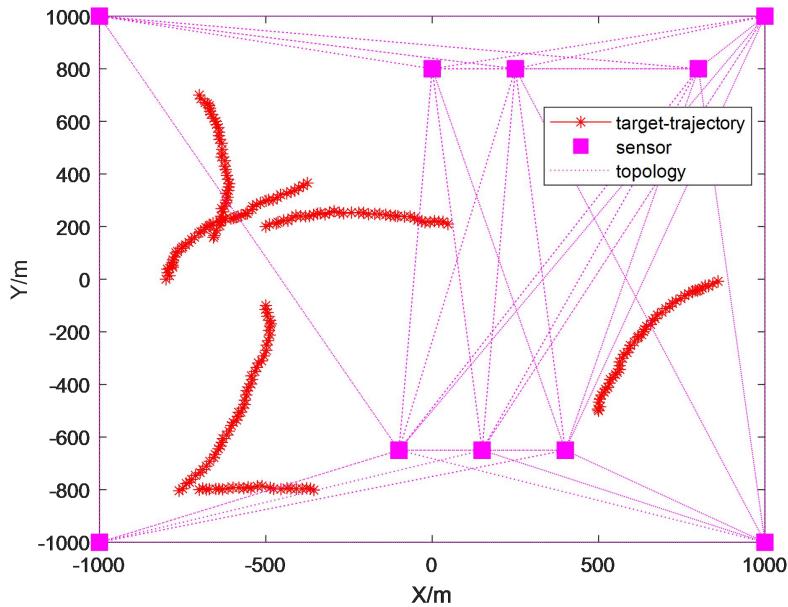


图 3.20 多目标跟踪场景

表 12: 传感器位置

	1	2	3	4	5	6	7	8	9	10
x_s / m	-1000	-1000	1000	1000	0	800	-100	150	250	400
y_s / m	-1000	1000	-1000	1000	800	800	-650	-650	800	-650

目标的存活概率为 $P_s = 0.99$ ，不同传感器的探测概率相同为 $P_D = 0.6$ 。融合步中的参数 $\beta = 30, \lambda = 0.8$ 。DBSCAN 聚类的参数 $\varepsilon = 15, MinPts = 3$ 。跟踪场景中的杂波数目服从均值为 2 的泊松分布。采用蒙特卡洛仿真重复 100 次。为了比较衡量三种算法的效果，采用目标估计数目以及 OSPA ($c = 10, p = 2$) 两种衡量手段，OSPA 的计算公式为

$$D_{p,c}(X, Y) = \begin{cases} \left[\frac{1}{n} \left(\min_{\pi \in \Pi_n} \sum_{i=1}^m (\tilde{d}(x_i, y_{\pi(i)})^p + (n-m) \times c^p) \right) \right]^{\frac{1}{p}}, & m \leq n \\ \left[\frac{1}{m} \left(\min_{\pi \in \Pi_m} \sum_{i=1}^n (\tilde{d}(x_{\pi(i)}, y_i)^p + (m-n) \times c^p) \right) \right]^{\frac{1}{p}}, & m \geq n \end{cases},$$

其中 $X = [x_1, x_2, \dots, x_m]$ 表示估计的多目标状态的 RFS， $Y = [y_1, y_2, \dots, y_n]$ 为真实

的多目标状态的 RFS, $\tilde{d}(x, y)$ 为 x 和 y 之间的欧氏距离。所提出的基于 DBSCAN 的 DMTT 算法、AA-DGMHD 和 GA-DGMHD 的估计目标数目和 OSPA 分别如图 3.21、图 3.22 所示。

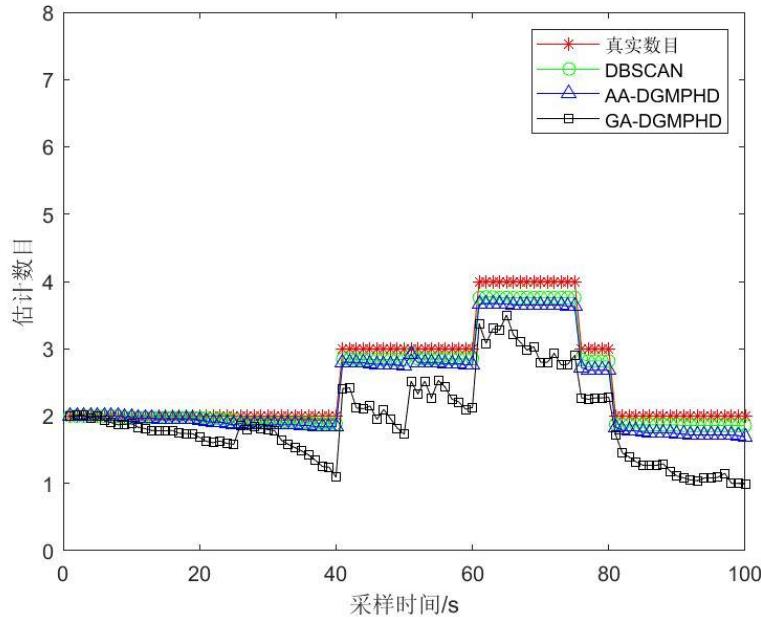


图 3.21 估计数目

从三种 DMTT 算法的估计目标数目仿真结果可知, 所提的基于 DBSCAN 的 DMTT 算法的效果要好于 AA-DGMHD 和 GM-DGMHD。在部分传感器出现探测精度下降情况之前, 基于 DBSCAN 的 DMTT 算法与 AA-DGMHD 的估计目标数目几乎相同, 两者差别的增大出现在部分传感器出现探测精度下降之后, 这是因为传感器探测精度下降后对应的本地估计强度与正常精度节点的本地估计强度差别较大, 将这些本地估计强度引入分布式一致性融合相当于变相的降低了真实目标对应的高斯项的权重, 在经过融合和剪枝之后得到的目标估计数目要低于删去探测精度下降节点的本地估计强度的 IAA 融合方法。而与基于 DBSCAN 的 DMTT 算法和 AA-DGMHD 相比, GM-DGMHD 得到的估计目标数目与真实的目标数目差异较大, 且绝大部分时间低于真实目标数目, 这是因为 GA 融合方法的特性决定的, 会增强估计强度相同的部分, 极大地削减不同的部分, 这就导致漏检目标的强度在 GA 融合后会大大减小, 从而导致估计数目小于真实值。

表 13: 精度下降传感器的编号及对应的精度下降的时刻

	1	3	5	7	10
T_{start} / s	30	30	30	30	30
T_{end} / s	50	50	50	50	50

三种算法在 OSPA 方面的表现与估计目标数目基本一致，从图 3.22 可以看出，传感器探测精度下降与否对于基于 DBSCAN 的 DMTT 算法的 OSPA 几乎没有影响，基于 DBSCAN 的 DMTT 算法的 OSPA 在整个跟踪过程中几乎没有变化。而 AA-DGMHD 和 GM-DGMHD 的 OSPA 都受到了不同程度的影响，AA-DGMHD 相比于 GM-DGMHD 所受的影响比较小，这是因为 AA-DGMHD 相比于 GM-DGMHD 的估计目标数目更为接近真实值，AA 融合丢失的目标更少。

综上所述，提出的基于 DBSCAN 的 DMTT 算法可以在部分传感器出现探测精度下降情况下，相比于 AA-DGMHD 和 GM-DGMHD 算法保持较好的 MTT 跟踪效果。

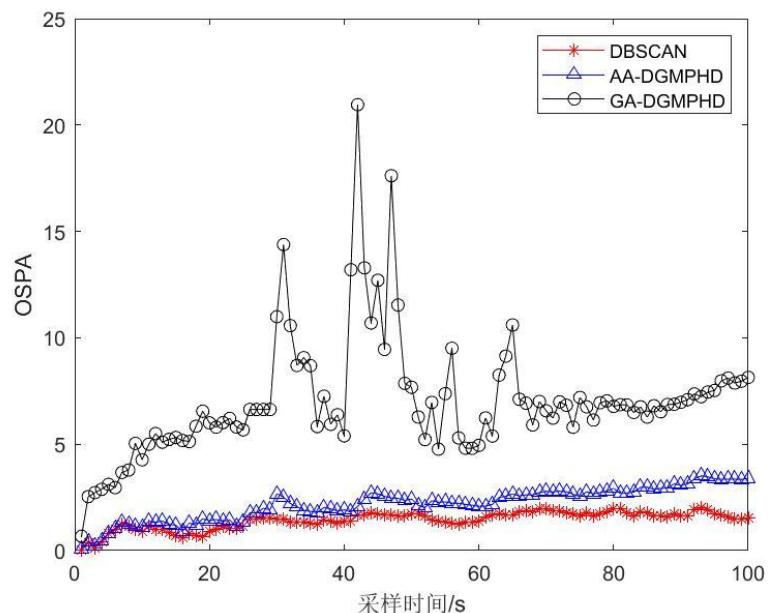


图 3.22 OSPA

3.4.7 总结

提出了一种针对于部分传感器探测精度下降情况的多目标跟踪算法，基于 DBSCAN 的 DMTT 算法。为了减轻探测精度下降传感器对于融合结果准确度的影响，基于 DBSCAN 的 DMTT 算法利用核心 DBSCAN 聚类挑选探测精度正常传感器同时相较于 DBSCAN 聚类减轻了聚类的计算负担。基于 DBSCAN 的 DMTT 算法在融合步采用 IAA 融合方法，在分布式融合的同时进行融合剪枝，只保留权重高的高斯项，减轻了分布式融合的通信和计算负担。IAA 融合方法的一致性也进行了理论证明。最后，通过仿真实验展示了所提算法的有效性。所提的基于 DBSCAN 的 DMTT 算法可以有效的判断并剔除掉探测精度下降的传感器节点，在不改变传感器的通信拓扑的基础上，通过改变一致性融合权重的设计实现一致性融合估计精度的提升，在存在探测精度下降的传感器的分布式多目标跟踪中提升了算法的鲁棒性。此部分由专利《部分传感器探测精度下的分布式多目标容错跟踪方法》支撑。

4. 已研究工作总结

从开题后至今按照计划对于研究内容稳步推进。

为研究传感器探测精度对于多目标跟踪精度的影响，首先建立单传感器对多目标进行探测的场景，根据随机有限集理论设计多目标状态估计器，进而采用仿真方法研究传感器探测精度对多目标状态估计精度的影响。然后，将单传感器多目标跟踪场景扩充到分布式多传感器多目标跟踪场景，与单传感器对多目标跟踪不同，分布式多传感器多目标跟踪除了需要设计多目标状态估计器外，还需要对分布式传感器之间的信息融合方法进行研究。采用交互式多模型的方法将算数平均融合方法和几何平均融合方法相结合，使得算法可以兼具算数平均融合方法不易丢失真实目标和几何平均融合方法不易受环境杂波影响的优点，获得了更好的多目标状态估计结果。

进一步研究了针对于部分传感器探测精度下降情况下的分布式单目标鲁棒跟踪方法。将密度聚类算法引入到分布式目标跟踪中，改进了一致性融合方法，使其可以适应部分传感器探测精度下降情况，提高状态估计的精度。同时，对于

所提算法的稳定性利用随机稳定性定理进行了证明，从理论的角度证明了算法的有效性。

然后将针对于部分传感器探测精度下降情况下的分布式单目标鲁棒跟踪方法推广到多目标鲁棒跟踪领域，使用基于随机有限集的高斯混合概率假设密度算法、密度聚类算法和算数平均融合方法实现部分传感器探测精度下降情况下的分布式多目标鲁棒跟踪。并且从理论证明的角度证明了算法的一致性。

与开题的计划相比，除了完成开题计划的传感器观测精度下降对多目标状态估计精度影响的研究和基于交互式多模型的分布式多目标状态融合方法研究之外，还实现了针对于部分传感器探测精度下降情况下的分布式单目标鲁棒跟踪方法研究以及针对于部分传感器探测精度下降情况下的分布式多目标鲁棒跟踪方法的研究，超额完成了开题计划的研究内容，为后续的实物验证争取到了充足的研究时间。

5. 后续研究的内容和实现技术

1. 降通信带宽分布式多目标鲁棒跟踪研究

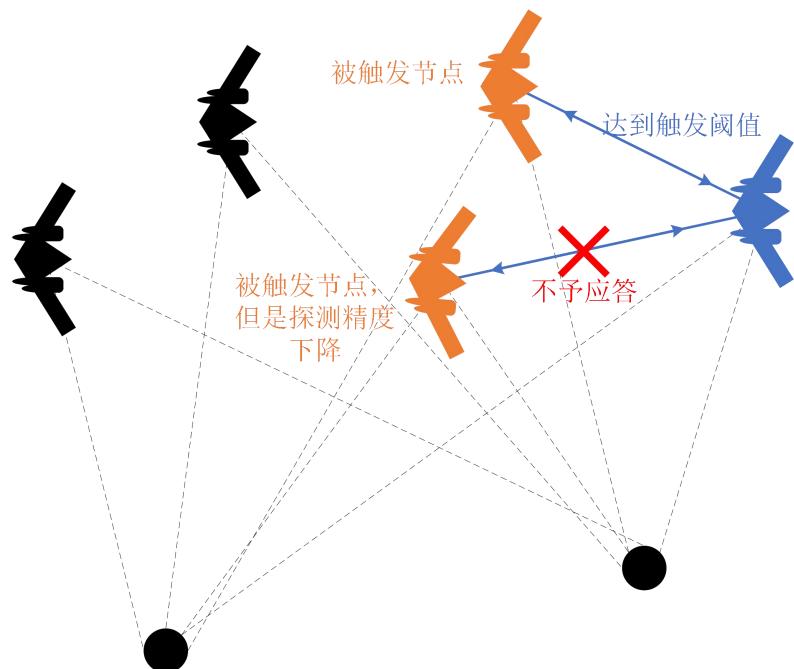


图 5.1 被触发传感器对于触发不予应答

组成无线传感器网络的传感器一般都为轻型、小成本传感器，自身所能承担的通信带宽、计算能力以及通信能源有限。而对于传感器来说，与外界进行通信交互是最耗费能量的工作，为了让传感器能够工作更长的时间，减少冗余信息的传递，设计事件触发算法，只有当前状态满足事件触发条件时，才进行信息的交互传递。在设计事件触发策略时，拟将传感器精度下降以及观测丢失条件引入，设计被触发传感器的应答策略，当此传感器精度下降时不予应答，观测丢失时进行一步预测后进行应答。对于事件触发来说，最重要的是对于事件触发阈值的设计。静态的事件触发阈值并不能反映数据的波动以及当前预测状态的性能，因此拟使用自适应事件触发阈值设计，当数据的波动小以及当前预测状态的性能好时，阈值基本保持不变，维持当前的交互频率和滤波效力。当数据出现大波动或者滤波性能差时，阈值下降，增大交互频率，改善滤波能力。仍旧使用 GMPHD 算法进行本地多目标状态估计。完成本地状态估计之后，依旧使用 IMM 融合算法进行多目标后验强度函数融合，得到最终的多目标状态估计结果。相应的算法流程图如图 5.2 所示。

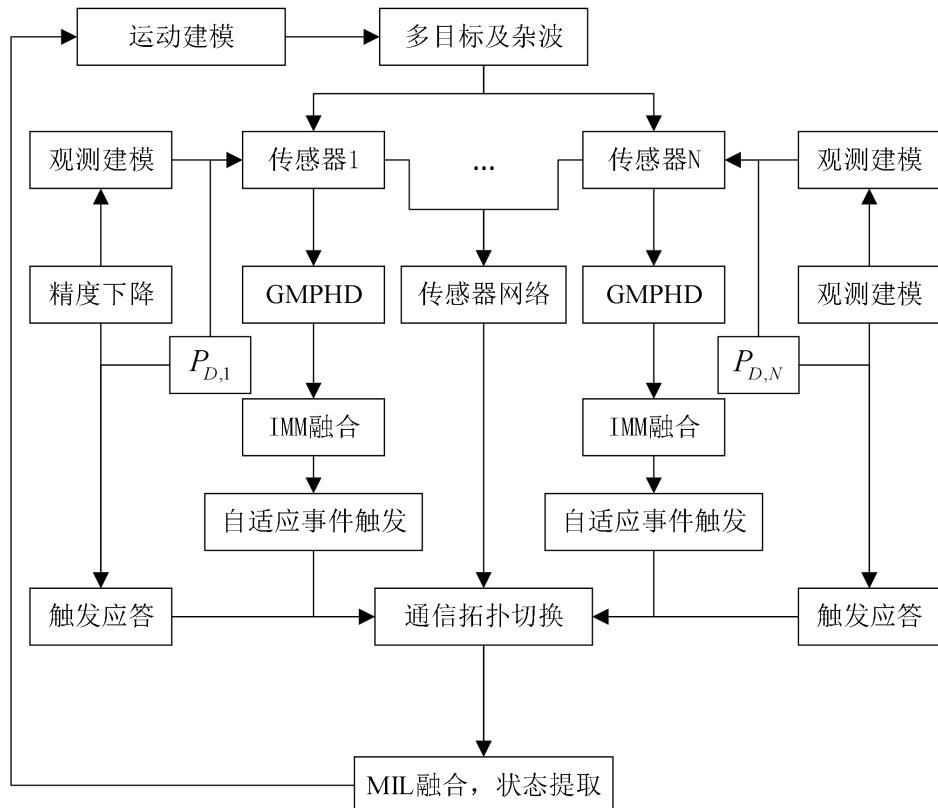


图 5.2 传感器网络通信能力受限下分布式多目标鲁棒跟踪技术设计流程图

设计自适应触发机制:

$$\begin{cases} e_i(t) = z_i(t) - H_i x_i(t), \\ g_i(t) = e_i(t_{l,i}) - e_i(t), \end{cases}, \quad (5.1)$$

$$t_{l+1,i} = \inf \left\{ t \mid t > t_{l,i} \text{ 且 } g_i^T(t) g_i(t) - \alpha_i(t) e_i^T(t) e_i(t) > 0 \right\}, \quad (5.2)$$

其中, $t_{l,i}$ 是上一个触发时刻, $z_i(t)$ 是 t 时刻的观测值, $x_i(t)$ 是 t 时刻的状态预测值, H_i 为观测矩阵, $e_i(t)$ 表示当前 t 时刻的滤波能力, $g_i(t)$ 表示上一次触发传输数据与当前数据的波动。

设计自适应触发阈值:

$$\frac{1}{\alpha_i(t)} = \frac{1}{\alpha_i(t-1)} + \frac{e_i^T(t) e_i(t) g_i^T(t) g_i(t)}{1 + g_i^T(t) g_i(t)}. \quad (5.3)$$

拟对于被触发传感器的应答情况也进行设置, 进一步减小通信负担。如果被触发的传感器存在探测精度下降或者观测丢失的情况, 那么与此被触发节点进行信息交互对于提升融合多目标状态估计精度帮助不大, 那么此被触发节点不予应答。场景示意图如图 5.1 所示。

2. 实物实验

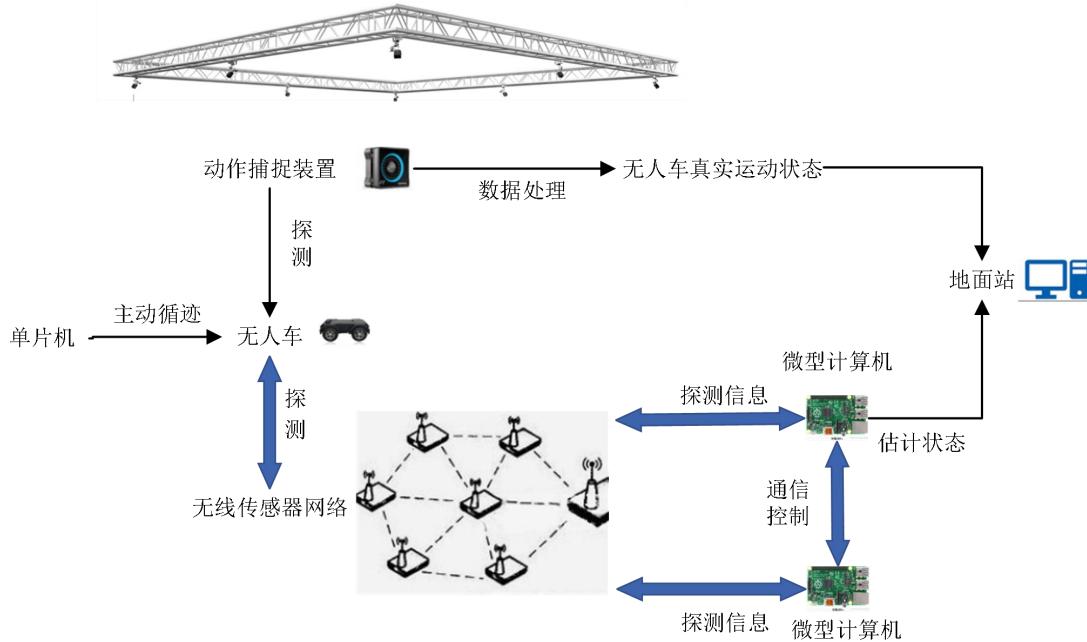


图 5.3 实物验证平台设计

拟采用实物实验的方式验证算法的有效性。首先需要构建实验场景, 目标真实运动状态由光学动态捕捉装置获得, 用于与算法得到的目标估计状态进行对比。

场景中的目标采用由单片机控制的自动寻迹小车，设置分布式的传感器网络，每个传感器均配备一个微型计算机（树莓派/nano），传感器探测得到的目标信息在微型计算机处进行数据处理，并采用设计的算法对于目标的运动状态进行估计，同时按照算法与其邻居节点进行通信，最终目标的状态估计结果和真实运动状态均上传至地面站，在地面站处评估，目标状态估计的精度情况。

6. 已发表的论文和取得的成果

论文

- [1] Zhang YJ, Zhang Z, Yu JL, et al. SOM neural network based Gaussian Mixture PHD algorithm for multi-sensor multi-target tracking [A]. in Proceedings of 2022 International Conference on Guidance, Navigation and Control [C]. Harbin, China: Springer, 2023, 3276-3285. (第一作者)
- [2] Zhang YJ, Zhang Z, Yu JL, et al. Measurement based dimension descent association algorithm for OTHR multi-detection multi-target tracking [J]. ISA Transactions 已接收 (第一作者, Q1, 影响因子 5.911)。

专利

1. 国家发明专利：一种超视距雷达多目标跟踪方法[P]。中国，申请号：202310466848.2 (已受理)
2. 国家发明专利：部分传感器探测精度下的分布式多目标容错跟踪方法。申请中。
3. 国家发明专利：基于 DBSCAN 的分布式容积信息滤波容错目标跟踪方法。申请中。
4. 国家发明专利：一种多传感器协同目标跟踪方法、系统、设备及介质。预审通过。

7. 参考文献

- [1] Chen Q, Wang W, Yin C, et al. Distributed Cubature Information Filtering Based on Weighted Average Consensus [J]. Neurocomputing, 2017, 243:115-124.

- [2] Nanda SJ, Panda G. Design of Computationally Efficient Density-Based Clustering Algorithms [J]. Data & Knowledge Engineering, 2015, 95: 23-38.
- [3] Tran TN, Drab K, Daszykowski M. Revised DBSCAN Algorithm to Cluster Data with Dense Adjacent Clusters [J]. Chemometrics and Intelligent Laboratory Systems, 2013, 120: 92-96.
- [4] Kotary DK, Nanda SJ. A Distributed Neighbourhood DBSCAN Algorithm for Effective Data Clustering in Wireless Sensor Networks [J]. Wireless Personal Communications, 2021, 121: 2545-2568.
- [5] Battistelli G, Chisci L. Kullback–Leibler Average, Consensus on Probability Densities, and Distributed State Estimation with Guaranteed Stability [J]. Automatica, 2014, 50(3): 707-718.
- [6] Godsil C, Royle G. Algebraic Graph Theory [M]. New York: Springer-Verlag, 2001.
- [7] Wang R, Dong XW, Lin QD, et al. Distributed Adaptive Time-Varying Formation for Multi-Agent Systems with General High-Order Linear Time-Invariant Dynamics [J]. Journal of the Franklin Institute, 2016, 353(10):2290-2304.
- [8] Dong XW, Zhou Y, Ren Z, et al. Time-Varying Formation Tracking for Second-Order Multi-Agent Systems Subjected to Switching Topologies With Application to Quadrotor Formation Flying [J]. IEEE Transactions on Industrial Electronics, 2017, 64 (6): 5014-5024.
- [9] Xiao L, Boyd S. Fast Linear Iterations for Distributed Averaging [J]. Systems & Control Letters, 2003, 53(1): 65-78.
- [10] Lee D. J. Nonlinear Estimation and Multiple Sensor Fusion Using Unscented Information Filtering [J]. IEEE Signal Processing Letters, 2008, 15(1): 861-864.
- [11] Kalman RE. A New Approach to Linear Filtering and Prediction Problems [J]. Journal of Fluids Engineering, 1960, 82(1): 35-45.
- [12] Huang J, Zhong J, Jiang F. A CKF Based Spatial Alignment of Radar and Infrared Sensors[A]. in Proceedings of IEEE 10th International Conference on Signal Processing[C]. Beijing, China: IEEE, 2010, 2386-2390.
- [13] Manavoglu B. Target Tracking with Passive Sensors Using CKF[A]. in Proceedings of 2018 26th Signal Processing and Communications Applications Conference[C]. Cesme, Izmir: IEEE, 2018, 1-4.
- [14] Yu YR, Yu JL, Liu YS, et al. Distributed State Estimation for Heterogeneous Mobile Sensor Networks with Stochastic Observation Loss [J]. Chinese Journal of Aeronautics, 2022, 35(2):

265-275.

- [15] Li W, Jia Y, Du J. Distributed Kalman Consensus Filter with Intermittent Observations [J]. Journal of the Franklin Institute, 2015, 352(9): 3764-3781.
- [16] Lee DJ. Nonlinear Estimation and Multiple Sensor Fusion Using Unscented Information Filtering [J]. IEEE Signal Processing Letters, 2008, 15:861-864.
- [17] Julier S, Uhlmann JK, Durrant-Whyte HF. A New Method for the Nonlinear Transformation of Means and Covariances in Filters and Estimators [J]. IEEE Transactions on Automatic Control, 2001, 45(3):477-482.
- [18] Julier SJ, Uhlmann JK. A Non-Divergent Estimation Algorithm in the Presence of Unknown Correlations [A]. American Control Conference [C]. Albuquerque, USA: 1997, 2369-2373.
- [19] Vo BN, Ma WK. The Gaussian Mixture Probability Hypothesis Density Filter [J]. IEEE Transactions on Signal Processing, 2006, 54(11): 4091-5004.
- [20] Li TC, Corchado JM, Sun SD. Partial Consensus and Conservative Fusion of Gaussian Mixtures for Distributed PHD Fusion [J]. IEEE Transactions on Aerospace and Electronic Systems, 2019, 55(5): 2150-2163.
- [21] Da K, Li TC, Zhu YF, et al. Review: Recent Advances in Multisensor Multi-Target Tracking Using Random Finite Set [J]. Frontiers of Information Technology and Electronic Engineering, 2021, 22(1): 5-24.
- [22] Li TC, Wang XX, Liang Y, et al. On Arithmetic Average Fusion and Its Application for Distributed Multi-Bernoulli Multitarget Tracking [J]. IEEE Transactions on Signal Processing, 2020, 68: 2883-2896.
- [23] Da K, Li TC, Zhu YF, et al. Kullback-Leibler Averaging for Multitarget Density Fusion [J]. Distributed Computing and Artificial Intelligence, 2019, 253-261.
- [24] Clark D, Vo BN. Convergence Analysis of the Gaussian Mixture PHD Filter [J]. IEEE Transactions on Signal Processing, 2007, 55(4): 1204-1212.